Modelado Metodológico: Clústeres Territoriales de Criminalidad y Sentometrics en Bogotá (2022-septiembre de 2026)

Taller de Programación en R - Maestría en Economía Aplicada (MECA)

Juan José Echeverry — 202616233 Miguelangel Palma — 202621481
Sergio Alejandro López Valderrama — 202111932
Gabriel Arturo Echeverry Castaño — 201016705
Olga Lucía Ramírez Contreras — 202624900
Juan Esteban Carvajal Cruz — 202614312

2026-11-11

Tabla de contenidos

1. Configuración inicial, arquitectura y datos de partida **1**

1.1. Diagrama de arquitectura del flujo analítico 2

1.2. Opciones globales, librerías y rutas relativas 4

2. Modelado y diagnóstico de tasas de hurto por 100.000 habitantes **7**

2.1. Intuición económica: por qué estandarizar por población expuesta 7

2.2. Carga y estadísticas descriptivas del panel delictivo 7

2.3. Ranking territorial de criminalidad promedio 9

3. Agrupamiento territorial de criminalidad con K-Means **10**

3.1. Intuición del algoritmo K-Means y preparación de variables 11

3.1.1. Por qué estandarizar con Z-score antes de medir distancias 11

3.1.2. Cómo encuentra los grupos el algoritmo 11

3.2. Selección del número óptimo de clústeres (K^*) 12

3.3. Estimación final y etiquetado determinístico de perfiles ($K^* = 3$) 15

3.4. Visualización tridimensional y bidimensional de los clústeres 17

4. Diagnóstico del corpus y análisis de sentimiento con `sentometrics` **24**

4.1. Cobertura temporal, geográfica y extensión léxica del corpus 24

4.2. Cómo mide y agrega el sentimiento `sentometrics`: intuición paso a paso 29

4.2.1. Paso 1: ¿Cómo calificamos una sola noticia sin que el largo del texto engañe? 29

4.2.2. Paso 2: ¿Cómo pasamos de noticias sueltas a un termómetro mensual? 30
4.2.3. Paso 3: ¿Cómo capturamos que el miedo y la agenda noticiosa persisten varios meses? 30
4.3. Construcción del sento_corpus y diagnósticos de corpus_summarize() 31
4.4. Diccionarios en español, modificadores de valencia, polaridad y noticias pico 35
4.5. Series temporales multidimensionales, índice global y fechas críticas 43

5. Modelado econométrico supervisado (Elastic Net) y atribuciones 47
5.1. Especificación del modelo regularizado (sento_model) 47
5.2. Descomposición de atribuciones marginales (attributions) 52

6. Cartografía espacial e integración para R Shiny 54
6.1. Geografía del delito por modalidad 54
6.2. Desajuste espacial entre delito registrado y cobertura periodística 58
6.3. Integración conceptual hacia el tablero R Shiny (“Dos lecturas de Bogotá”) 60

7. Verificación de consistencia, guía de estudio y conclusiones 61
7.1. Auditoría programática de los objetos calculados en memoria 61
7.2. Preguntas de estudio para sustentación 63
7.3. Conclusiones empíricas 63
7.4. Limitaciones de la investigación 64
7.5. Implicaciones de política pública 64

1. Configuración inicial, arquitectura y datos de partida

Este cuaderno funciona como la guía principal para estudiar y replicar paso a paso la metodología cuantitativa del proyecto sobre hurtos y cobertura mediática en Bogotá entre enero de 2022 y septiembre de 2026. Todo el análisis parte de los insumos ya limpios y homologados en `data/processed/` (junto con la capa cartográfica oficial en `data/raw/delitos/`) y ejecuta en vivo, dentro de la memoria de R, cada componente del modelado sin depender de internet, sin leer resultados intermedios precalculados y sin sobrescribir archivos del repositorio:

1. **Tasas delictivas por 100.000 habitantes:** estandarización demográfica de los registros de la Secretaría Distrital de Seguridad, Convivencia y Justicia (SDSCJ / SIEDCO) y la Secretaría Distrital de Salud (SDS), junto con la intuición económica del efecto de población flotante.
2. **Agrupamiento territorial no supervisado (K-Means):** réplica completa de `scripts/04_clustering_kmeans.R`, desde la normalización Z-score y la búsqueda del número óptimo de grupos ($K^* = 3$) hasta el etiquetado determinístico de centroides y su inspección tridimensional.
3. **Descriptivos del corpus y análisis de sentimiento (`sentometrics`):** réplica en vivo de `scripts/06_descriptivos_corpus.R` y de las tres primeras fases de `scripts/03_analisis_sentometrics.R`, acompañada de una explicación intuitiva de cada ecuación antes de mostrar el código que construye el `sento_corpus`, los diccionarios en español, los modificadores de valencia, las noticias pico y las 364 series mensuales.

4. **Modelado econométrico supervisado (Elastic Net) y atribuciones:** réplica de la cuarta fase de `scripts/03_analisis_sentometrics.R`, mensualizando la tasa distrital de hurto para estimar `sento_model()` y descomponer el aporte marginal de cada dimensión con `attributions()`.
5. **Cartografía espacial (`sf`), panel consolidado e integración hacia R Shiny:** cruce vectorial por localidad para contrastar la tasa oficial frente al volumen noticioso, más una síntesis de cómo el tablero interactivo consume los resultados finales.

> **Punto de partida y ejecución autocontenida**
>
> Los scripts previos de descarga (`scripts/01_ingesta/`) y depuración (`scripts/02_procesamiento/`) ya dejaron listos dos archivos base: el panel anual de delitos y población (`panel_delitos_poblacion_localidad.parquet`) y el corpus depurado de noticias (`noticias_procesadas.parquet`). En este cuaderno descartamos al inicio cualquier columna de clúster o sentimiento que pudiera existir en disco dentro de ese archivo de noticias, de modo que cada cálculo posterior se ejecute desde cero en memoria.

1.1. Diagrama de arquitectura del flujo analítico

La Figura 1 resume cómo los datos procesados alimentan los tres scripts analíticos replicados en este documento y cómo sus salidas convergen hacia la capa espacial y la aplicación Shiny.

```
digraph pipeline {
  graph [
    rankdir=TB,
    bgcolor="transparent",
    fontname="Helvetica",
    nodesep=0.55,
    ranksep=0.65,
    pad="0.2",
    splines=polyline
  ];

  node [
    shape=box,
    style="rounded,filled",
    fillcolor="#ffffff",
    color="#64748b",
    penwidth=1.2,
    fontname="Helvetica",
    fontsize=10,
    fontcolor="#1e293b",
    margin="0.18,0.10"
  ];

  edge [
    color="#475569",
    penwidth=1.2,
    arrowsize=0.8
  ];
```

```
  subgraph cluster_inputs {
    label="Insumos de partida (data/processed/ y capa cartográfica)";
    labelloc="t";
    labeljust="l";
    fontname="Helvetica-Bold";
    fontsize=11;
    fontcolor="#1e3a5f";
    style="rounded,filled,dashed";
    fillcolor="#f1f5f9";
    color="#94a3b8";
    margin=20;

    {
      rank=same;
      in_panel [label="panel_delitos_poblacion_localidad.parquet\n19 localidades urbanas x 5 años
↪  (95 filas)"];
      in_news  [label="noticias_procesadas.parquet\n3.916 noticias limpias y clasificadas por
↪  DAI"];
      in_geo   [label="localidades_bogota_raw.geojson\nPolígonos oficiales SDSCJ"];
      in_panel -> in_news -> in_geo [style=invis, weight=10];
    }
  }

  subgraph cluster_model {
    label="Modelado y análisis replicados en vivo";
    labelloc="t";
    labeljust="r";
    fontname="Helvetica-Bold";
    fontsize=11;
    fontcolor="#14532d";
    style="rounded,filled";
    fillcolor="#f0fdf4";
    color="#4ade80";
    margin=22;

    {
      rank=same;
      m_km [
        label="04_clustering_kmeans.R (Sección 3)\nZ-score + K-Means (K* = 3) + silueta",
        fillcolor="#ffffff",
        color="#15803d"
      ];
      m_sento [
        label="03_analisis_sentometrics.R (Secc. 4 y 5)\nsento_corpus + nrc_es / crimen_es +
↪  Elastic Net",
        fillcolor="#ffffff",
        color="#15803d"
      ];
    }
    m_desc [
      label="06_descriptivos_corpus.R (Sección 4)\nCobertura, extensión, tono anual y
↪  corpus_summarize()",
```

```
      fillcolor="#ffffff",
      color="#15803d"
    ];
  }

  subgraph cluster_viz {
    label="Cartografía e integración web";
    labelloc="b";
    labeljust="l";
    fontname="Helvetica-Bold";
    fontsize=11;
    fontcolor="#7c2d12";
    style="rounded,filled";
    fillcolor="#fff7ed";
    color="#fb923c";
    margin=22;

    {
      rank=same;
      v_map [
        label="Mapas vectoriales sf y panel anual (Sección 6)\nContraste entre tasa oficial y
↪  volumen de prensa",
        fillcolor="#ffffff",
        color="#c2410c"
      ];
      v_shiny [
        label="05_export_insumos_shiny.R  ->  app/app.R\nTablero interactivo 'Dos lecturas de
↪  Bogotá'",
        fillcolor="#ffffff",
        color="#c2410c",
        style="rounded,filled,dashed"
      ];
    }
  }

  in_panel -> m_km    [weight=5];
  in_panel -> m_sento;
  in_news  -> m_sento [weight=5];
  in_news  -> m_desc;
  m_km     -> m_sento;
  m_sento  -> m_desc  [weight=5];
  m_km     -> v_map;
  m_sento  -> v_map;
  in_geo   -> v_map   [weight=3];
  m_desc   -> v_shiny [weight=5];
  v_map    -> v_shiny;
}
```

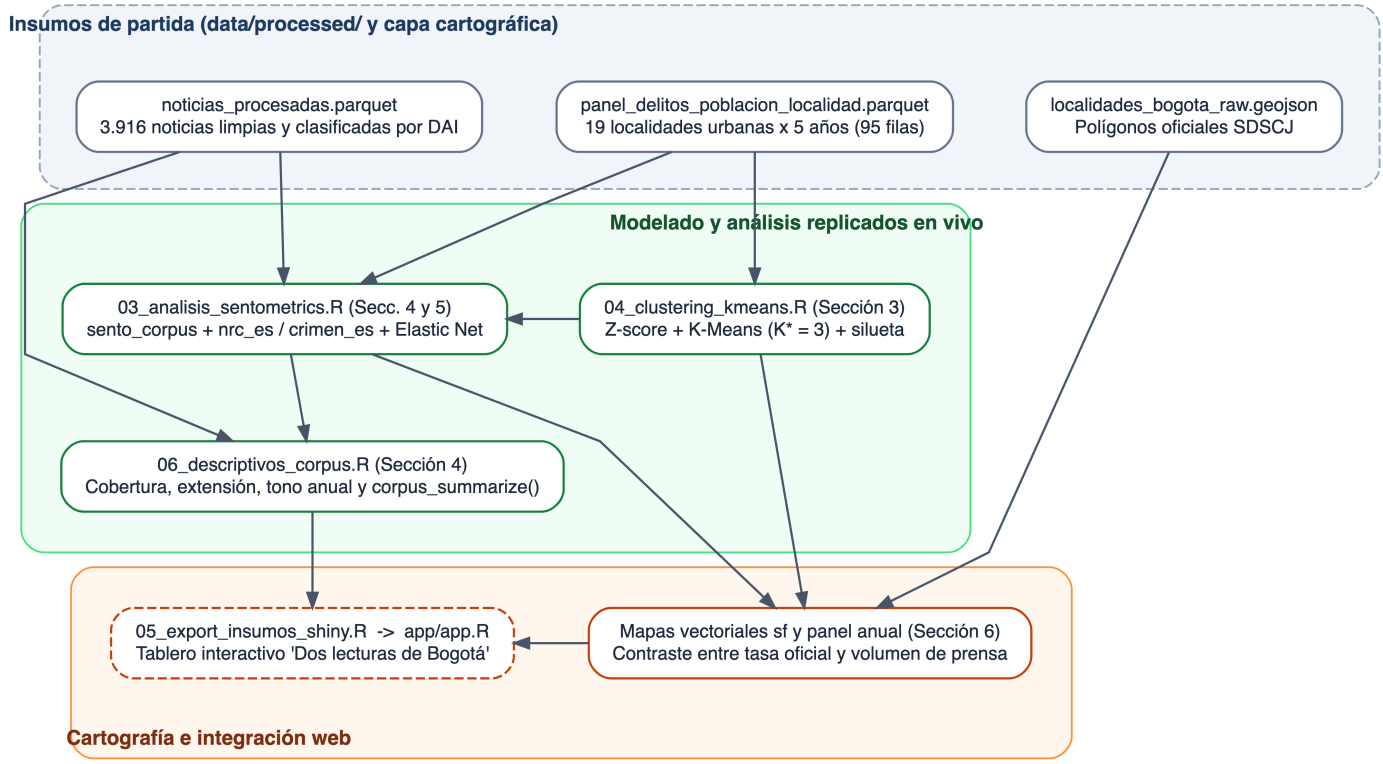


Figura 1: Flujo del modelado territorial, descriptivos, sentometrics y visualización en R Shiny a partir de los datos procesados

1.2. Opciones globales, librerías y rutas relativas

El bloque inicial reproduce las convenciones de todo el proyecto: desactivar la notación científica (`scipen = 999`), fijar la semilla global (`20261014`) para que tanto `K-Means` como cualquier rutina muestral o de optimización sean determinísticos, resolver ambigüedades entre paquetes con `{conflicted}` y construir rutas relativas portables mediante `{here}`.

```
# 1. Configuración inicial y dependencias ----

## 1.1 Opciones globales y semilla ----
rm(list = ls())
options(scipen = 999)
set.seed(20261014)

## 1.2 Carga de librerías necesarias ----
library(here)
library(conflicted)
library(arrow)
library(readr)
library(dplyr)
library(tidyr)
library(tibble)
library(stringr)
library(stringi)
library(lubridate)
library(data.table)
library(ggplot2)
library(ggrepel)
library(plotly)
library(scales)
library(knitr)
library(cluster)
library(syuzhet)
library(sentometrics)
library(glmnet)
library(sf)
library(cowplot)

## 1.3 Resolución explícita de conflictos entre paquetes ({conflicted}) ----
# Evita que funciones homónimas de stats, data.table o lubridate oculten a dplyr/plotly
conflict_prefer("filter",   "dplyr",     quiet = TRUE)
conflict_prefer("lag",      "dplyr",     quiet = TRUE)
conflict_prefer("select",   "dplyr",     quiet = TRUE)
conflict_prefer("first",    "dplyr",     quiet = TRUE)
conflict_prefer("between",  "dplyr",     quiet = TRUE)
conflict_prefer("year",     "lubridate", quiet = TRUE)
conflict_prefer("month",    "lubridate", quiet = TRUE)
conflict_prefer("layout",   "plotly",    quiet = TRUE)

## 1.4 Definición y validación de rutas de entrada ----
ruta_proc <- here::here("data", "processed")
```

```r
archivo_delitos_p  <- file.path(ruta_proc, "02_poblacion",
↪  "panel_delitos_poblacion_localidad.parquet")
archivo_noticias_p <- file.path(ruta_proc, "03_noticias", "noticias_procesadas.parquet")
archivo_geo_raw    <- here::here("data", "raw", "delitos", "localidades_bogota_raw.geojson")

# Detiene la compilación de inmediato si falta alguno de los tres insumos base
stopifnot(
  file.exists(archivo_delitos_p),
  file.exists(archivo_noticias_p),
  file.exists(archivo_geo_raw)
)
```

2. Modelado y diagnóstico de tasas de hurto por 100.000 habitantes

2.1. Intuición económica: por qué estandarizar por población expuesta

Comparar conteos absolutos de denuncias entre localidades mezcla tamaño poblacional con riesgo delictivo. Localidades con cerca de un millón de habitantes, como Suba o Kennedy, acumulan un volumen alto de denuncias simplemente porque viven allí muchas más personas. En contraste, localidades céntricas con pocos residentes permanentes pero con intensa actividad comercial, universitaria e institucional muestran un riesgo por habitante mucho mayor.

Para corregir ese sesgo de escala calculamos la **tasa anual de hurto por cada 100.000 habitantes**:

$$\text{Tasa}_{it}^{(m)} = \frac{\text{Denuncias del delito } m \text{ en la localidad } i \text{ durante el año } t}{\text{Población residente proyectada en la localidad } i \text{ durante el año } t} \times 100.000 \tag{1}$$

Aquí m recorre las tres modalidades analizadas (hurto a personas, residencias y motocicletas, además de su suma total) e $i \in \{1, \ldots, 19\}$ indexa las 19 localidades urbanas de Bogotá. Sumapaz se excluye por su carácter rural de páramo y su baja comparabilidad urbana en prensa e infraestructura.

> **!** El efecto denominador de la población flotante
>
> En la Ecuación 1, el numerador registra todos los delitos denunciados dentro del polígono de la localidad i, mientras que el denominador mide únicamente a quienes **residen** allí según las proyecciones de la SDS y el DANE. En el centro ampliado (La Candelaria, Los Mártires, Santa Fe y Chapinero), cientos de miles de trabajadores, estudiantes y compradores transitan cada día sin vivir en la zona. Al dividir las denuncias generadas por toda esa población flotante entre un número pequeño de residentes, la tasa per cápita se amplifica.

2.2. Carga y estadísticas descriptivas del panel delictivo

Importamos el panel oficial de delitos y población (19 localidades por 5 años, es decir, 95 observaciones) y el corpus procesado de 3.916 noticias. En el archivo de noticias eliminamos de entrada cualquier columna de sentimiento o clúster generada en corridas previas del pipeline, garantizando que todo lo calculado en las secciones siguientes nazca desde cero en la sesión actual.

```r
# 2. Carga de insumos base y tasas estandarizadas ----

## 2.1 Lectura de paneles y limpieza preventiva de columnas derivadas ----
panel_delitos <- arrow::read_parquet(archivo_delitos_p)

# Removemos columnas downstream para que el cuaderno recalcule clustering y sentimiento desde cero
df_noticias_base <- arrow::read_parquet(archivo_noticias_p) |>
  select(-any_of(c(
    "id", "word_count", "score_nrc_es", "score_crimen_es",
    "score_tfidf_compuesto", "sentimiento_score", "sentimiento_categoria",
    "cluster_id", "cluster_nombre", "perfil_seguridad"
  )))

# Controles de integridad de entrada
stopifnot(nrow(panel_delitos) == 95)
stopifnot(length(unique(panel_delitos$codigo_localidad)) == 19)
stopifnot(nrow(df_noticias_base) > 0)

## 2.2 Momentos descriptivos de las cuatro tasas por 100.000 habitantes ----
resumen_tasas <- tibble(
  modalidad = c(
    "Hurto a personas",
    "Hurto a residencias",
    "Hurto a motocicletas",
    "Tasa combinada total"
  ),
  media = c(
    mean(panel_delitos$tasa_hurto_personas),
    mean(panel_delitos$tasa_hurto_residencias),
    mean(panel_delitos$tasa_hurto_motos),
    mean(panel_delitos$tasa_hurto_total)
  ),
  desv_est = c(
    sd(panel_delitos$tasa_hurto_personas),
    sd(panel_delitos$tasa_hurto_residencias),
    sd(panel_delitos$tasa_hurto_motos),
    sd(panel_delitos$tasa_hurto_total)
  ),
  mediana = c(
    median(panel_delitos$tasa_hurto_personas),
    median(panel_delitos$tasa_hurto_residencias),
    median(panel_delitos$tasa_hurto_motos),
    median(panel_delitos$tasa_hurto_total)
  ),
  minimo = c(
    min(panel_delitos$tasa_hurto_personas),
    min(panel_delitos$tasa_hurto_residencias),
    min(panel_delitos$tasa_hurto_motos),
    min(panel_delitos$tasa_hurto_total)
  ),
  maximo = c(
    max(panel_delitos$tasa_hurto_personas),
```

```
    max(panel_delitos$tasa_hurto_residencias),
    max(panel_delitos$tasa_hurto_motos),
    max(panel_delitos$tasa_hurto_total)
  )
)

knitr::kable(
  resumen_tasas,
  digits    = 1,
  col.names = c("Modalidad delictiva", "Media", "Desv. est.", "Mediana", "Mínimo", "Máximo")
)
```

Tabla 1: Estadísticas descriptivas de tasas anuales de hurto por 100.000 habitantes en Bogotá (2022-septiembre de 2026)

Modalidad delictiva	Media	Desv. est.	Mediana	Mínimo	Máximo
Hurto a personas	2910.7	2905.0	1602.7	410.3	13348.3
Hurto a residencias	108.4	72.0	90.4	27.7	398.1
Hurto a motocicletas	68.2	43.2	60.0	11.4	291.2
Tasa combinada total	3087.3	2984.0	1758.9	490.8	13730.2

2.3. Ranking territorial de criminalidad promedio

Al promediar las tasas anuales del periodo 2022 a septiembre de 2026 por localidad, la concentración per cápita recae en el corredor central y comercial (Los Mártires, La Candelaria, Chapinero, Santa Fe y Teusaquillo), mientras que las localidades periféricas de mayor población exhiben tasas relativas mucho menores.

```
## 2.3 Ranking multianual promedio por localidad ----
ranking_localidades <- panel_delitos |>
  group_by(localidad) |>
  summarise(
    tasa_media_total = mean(tasa_hurto_total),
    tasa_media_pers  = mean(tasa_hurto_personas),
    poblacion_media  = mean(poblacion),
    .groups = "drop"
  ) |>
  arrange(desc(tasa_media_total))

ggplot(ranking_localidades, aes(x = reorder(localidad, tasa_media_total), y = tasa_media_total)) +
  geom_col(fill = "#1b365d", width = 0.72) +
  geom_text(
    aes(label = scales::comma(round(tasa_media_total))),
    hjust = -0.15,
    size  = 3.2,
    color = "#333333"
  ) +
  coord_flip() +
  scale_y_continuous(labels = scales::comma, expand = expansion(mult = c(0, 0.15))) +
```

```r
  labs(
    title    = "Incidencia Relativa de Hurto por Localidad en Bogotá",
    subtitle = "Promedio anual de denuncias por cada 100.000 habitantes (2022-septiembre de 2026)",
    x        = NULL,
    y        = "Tasa anual combinada por 100.000 habitantes",
    caption  = "Fuente: cálculos propios con base en SIEDCO (SDSCJ) y proyecciones poblacionales
    ↪  (SDS)."
  ) +
  theme_minimal(base_size = 11) +
  theme(
    panel.grid.minor   = element_blank(),
    panel.grid.major.y = element_blank(),
    plot.title         = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle      = element_text(size = 10, color = "grey30", margin = margin(b = 10))
  )
```

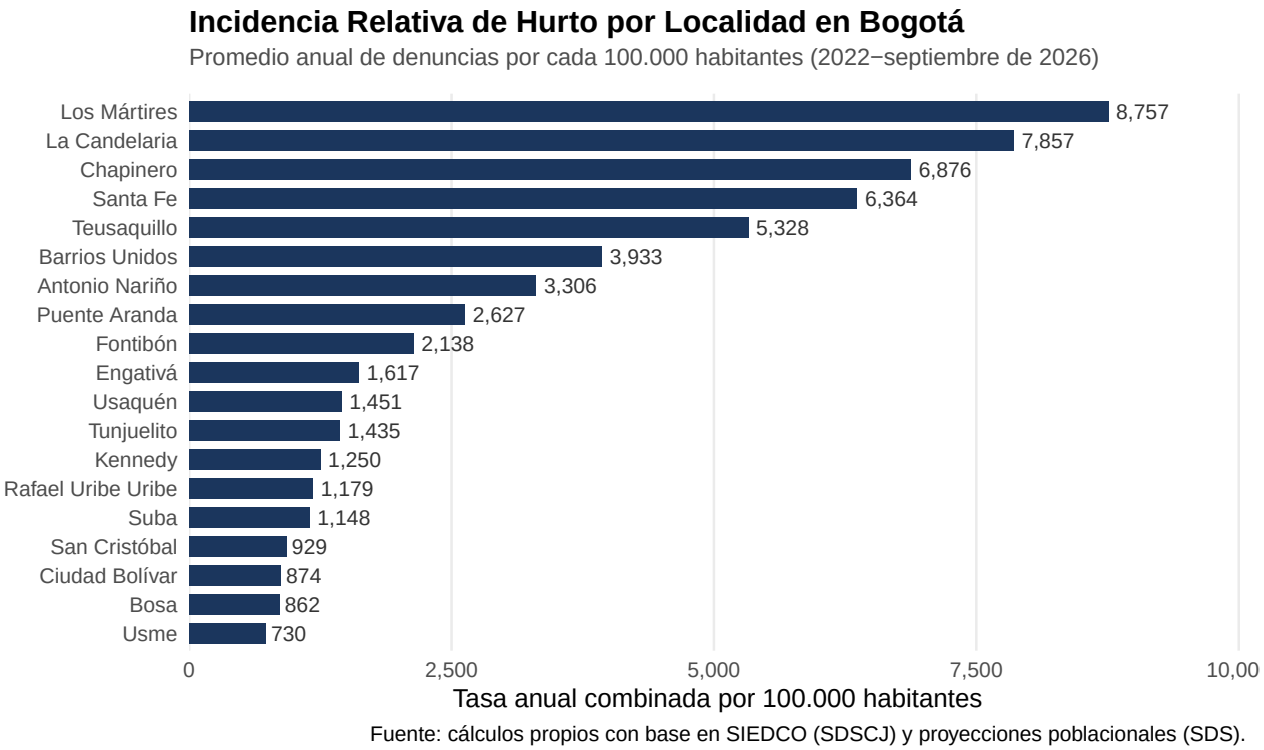


Figura 2: Tasa promedio anual de hurto total por cada 100.000 habitantes por localidad (2022-septiembre de 2026)

3. Agrupamiento territorial de criminalidad con K-Means

En esta sección replicamos íntegramente `scripts/04_clustering_kmeans.R`. El objetivo es pasar de un ranking unidimensional a una tipología territorial que reconozca en qué modalidades delictivas se especializa cada zona de la ciudad.

3.1. Intuición del algoritmo K-Means y preparación de variables

El algoritmo K-**Means** es un método de aprendizaje no supervisado que clasifica observaciones sin etiquetas previas (en nuestro caso, las 19 localidades urbanas) en K grupos o clústeres ($C_1, \ldots, C_K$). Busca equilibrar dos propósitos:

1. **Cohesión interna:** las localidades dentro de un mismo grupo deben tener perfiles delictivos parecidos.
2. **Separación externa:** cada grupo debe diferenciarse con claridad de los demás.

Cada localidad i se representa mediante el vector tridimensional de sus tasas promedio anuales por 100.000 habitantes:

$$\mathbf{x}_i = (\text{Hurto a personas}_i,\ \text{Hurto a residencias}_i,\ \text{Hurto a motocicletas}_i) \in \mathbb{R}^3$$

3.1.1. Por qué estandarizar con Z-score antes de medir distancias

En la Tabla 1 vimos que la tasa media de hurto a personas (2,911) supera más de 26 veces a la de hurto a residencias (108.4) y más de 42 veces a la de hurto a motocicletas (68.2). Como K-Means mide la cercanía entre localidades con distancia euclidiana en línea recta, introducir las variables en sus escalas originales haría que diferencias de miles de unidades en hurto a personas aplastaran por completo cualquier variación en residencias o motocicletas.

Para dar el mismo peso a las tres dimensiones estandarizamos cada variable $j \in \{1, 2, 3\}$ restando su promedio distrital $\bar{X}_j$ y dividiendo por su desviación estándar s_j:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j} \tag{2}$$

De este modo, cada tasa queda expresada en **desviaciones estándar respecto al promedio de Bogotá** (media 0 y desviación estándar 1). Por ejemplo, $Z_{ij} = +2{,}0$ significa que la localidad i está dos desviaciones estándar por encima del promedio distrital en esa modalidad.

3.1.2. Cómo encuentra los grupos el algoritmo

En el espacio estandarizado $\mathbf{z}_i = (Z_{i,\text{pers}}, Z_{i,\text{resid}}, Z_{i,\text{motos}})$, el algoritmo de Hartigan-Wong minimiza la **suma de cuadrados intra-clúster** (*Within-Cluster Sum of Squares*, WSS), que mide qué tan dispersas quedan las localidades alrededor del centroide (centro de gravedad) $\boldsymbol{\mu}_k$ de su grupo:

$$\min_{C_1,\ldots,C_K} WSS(K) = \sum_{k=1}^{K} \sum_{i \in C_k} \|\mathbf{z}_i - \boldsymbol{\mu}_k\|_2^2 = \sum_{k=1}^{K} \sum_{i \in C_k} \sum_{j=1}^{3} (Z_{ij} - \mu_{kj})^2 \tag{3}$$

Para resolver esta optimización, `kmeans()` repite cuatro pasos:

1. **Inicialización (`nstart = 50`):** ubica K centroides iniciales al azar; repetir el arranque desde 50 configuraciones aleatorias distintas evita quedar atrapado en un mínimo local deficiente y conserva la partición con menor WSS.

2. **Asignación:** mide la distancia euclidiana de cada localidad a los K centroides y la asigna al más cercano.
3. **Actualización:** recalcula cada centroide $\boldsymbol{\mu}_k$ como el promedio aritmético de las coordenadas de las localidades asignadas a ese grupo.
4. **Convergencia:** alterna asignación y actualización hasta que ninguna localidad cambia de grupo.

3.2. Selección del número óptimo de clústeres (K^*)

Como el número de grupos K se fija de antemano, evaluamos $K \in \{2, 3, 4, 5\}$ mediante dos criterios complementarios:

- **Varianza explicada (BSS/TSS):** mide qué porcentaje de la heterogeneidad total entre las 19 localidades (TSS) se explica por las diferencias entre clústeres ($BSS = TSS - WSS$).
- **Ancho de silueta (*Silhouette Width*):** para cada localidad i, compara qué tan cerca está de sus compañeras de grupo ($a(i)$, distancia media intra-clúster) frente a qué tan lejos está del grupo vecino más cercano ($b(i)$, distancia media al clúster ajeno más próximo):

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1] \tag{4}$$

Un valor $S(i)$ cercano a $+1$ indica que la localidad encaja bien en su grupo y está bien separada del resto; cercano a 0 indica frontera entre dos perfiles; y negativo advierte que, en una o más dimensiones, la localidad se aproxima a un grupo vecino. Elegimos el K^* que maximiza la silueta promedio $\bar{S}(K)$.

```
# 3. Réplica de scripts/04_clustering_kmeans.R ----

## 3.1 Agregación multianual por localidad y normalización Z-score ----
matriz_localidad <- panel_delitos |>
  group_by(codigo_localidad, localidad) |>
  summarise(
    tasa_personas_prom = mean(tasa_hurto_personas, na.rm = TRUE),
    tasa_resid_prom    = mean(tasa_hurto_residencias, na.rm = TRUE),
    tasa_motos_prom    = mean(tasa_hurto_motos, na.rm = TRUE),
    tasa_total_prom    = mean(tasa_hurto_total, na.rm = TRUE),
    poblacion_prom     = mean(poblacion, na.rm = TRUE),
    .groups = "drop"
  )

# Convertimos las 3 tasas delictivas en matriz numérica etiquetada por localidad
mat_clustering <- matriz_localidad |>
  select(tasa_personas_prom, tasa_resid_prom, tasa_motos_prom) |>
  as.matrix()
rownames(mat_clustering) <- matriz_localidad$localidad

# scale() aplica (X - media) / desv_est por columna para equilibrar escalas
matriz_scale <- scale(mat_clustering)

# Verificamos numéricamente que las 3 columnas tengan media 0 y desv. est. 1
stopifnot(all(abs(colMeans(matriz_scale)) < 1e-10))
```

```r
stopifnot(all(abs(apply(matriz_scale, 2, sd) - 1) < 1e-10))

## 3.2 Evaluación diagnóstica de K entre 2 y 5 con 50 arranques aleatorios ----
dist_euclidea <- dist(matriz_scale)

diagnostico_k <- tibble(
  k             = 2:5,
  silueta_media = numeric(4),
  wss           = numeric(4),
  bss_tss_pct   = numeric(4)
)

for (i in seq_along(2:5)) {
  k_val <- (2:5)[i]
  # Fijamos la semilla antes de cada K para garantizar reproducibilidad exacta
  set.seed(20261014)
  km_temp  <- kmeans(matriz_scale, centers = k_val, nstart = 50)
  sil_temp <- silhouette(km_temp$cluster, dist_euclidea)

  diagnostico_k$silueta_media[i] <- round(mean(sil_temp[, 3]), 4)
  diagnostico_k$wss[i]           <- round(km_temp$tot.withinss, 4)
  diagnostico_k$bss_tss_pct[i]   <- round((km_temp$betweenss / km_temp$totss) * 100, 2)
}

# Selección automática del óptimo global según la máxima silueta promedio
k_optimo <- diagnostico_k$k[which.max(diagnostico_k$silueta_media)]
stopifnot(k_optimo == 3L)

knitr::kable(
  diagnostico_k,
  digits    = c(0, 4, 2, 2),
  col.names = c(
    "Número de clústeres (K)",
    "Silueta promedio",
    "WSS (inercia interna)",
    "Varianza explicada (BSS/TSS %)"
  )
)
```

Tabla 2: Diagnóstico de K-Means para K entre 2 y 5 mediante coeficiente de silueta e inercia interna

Número de clústeres (K)	Silueta promedio	WSS (inercia interna)	Varianza explicada (BSS/TSS %)
2	0.5153	23.31	56.82
3	0.5416	13.58	74.85
4	0.4786	8.15	84.90
5	0.3792	5.90	89.07

Como muestra la Tabla 2 y se grafica en la Figura 3, la silueta promedio alcanza su máximo en $K^* = 3$ ($\bar{S} = 0.5416$), reduciendo la inercia interna (WSS) a 13.5797 y capturando el **74.85 %** de la varianza tridimensional.

```r
## 3.3 Curva del coeficiente de silueta promedio ----
ggplot(diagnostico_k, aes(x = k, y = silueta_media)) +
  geom_line(color = "#2980b9", linewidth = 1) +
  geom_point(color = "#2980b9", size = 3.5) +
  geom_vline(xintercept = k_optimo, linetype = "dashed", color = "#c0392b") +
  annotate(
    "text",
    x        = k_optimo + 0.12,
    y        = max(diagnostico_k$silueta_media) - 0.006,
    label    = paste0("Óptimo global:\nK* = ", k_optimo, " (", max(diagnostico_k$silueta_media),
    ↪  ")"),
    hjust    = 0,
    color    = "#c0392b",
    fontface = "bold",
    size     = 3.4
  ) +
  scale_x_continuous(breaks = 2:5) +
  labs(
    title    = "Determinación del Número Óptimo de Clústeres",
    subtitle = paste0("Máximo global alcanzado en K* = ", k_optimo, " con silueta promedio de ",
    ↪  max(diagnostico_k$silueta_media)),
    x        = "Número de clústeres (K)",
    y        = "Coeficiente de silueta promedio"
  ) +
  theme_minimal(base_size = 11)
```

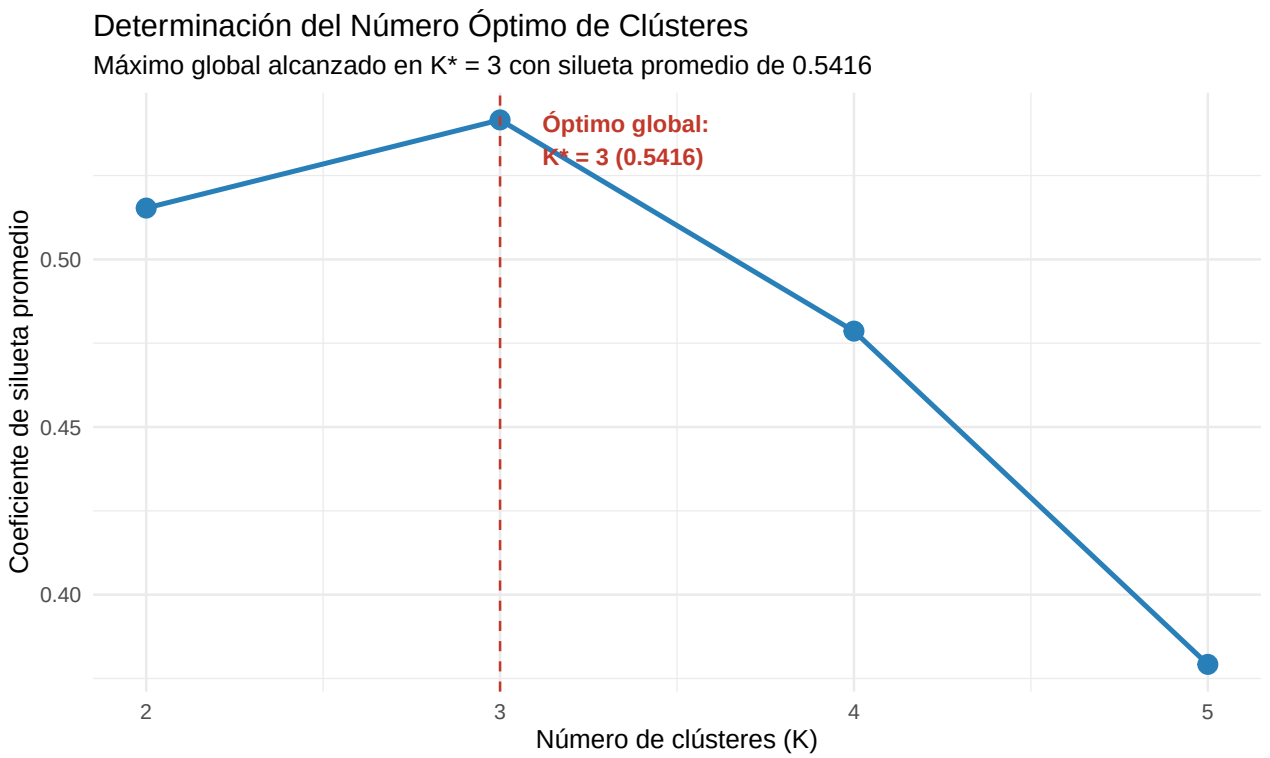


Figura 3: Coeficiente de silueta promedio para K entre 2 y 5 con máximo global en K* = 3

3.3. Estimación final y etiquetado determinístico de perfiles ($K^* = 3$)

Un detalle técnico importante en `kmeans()` es que los números enteros asignados a los clústeres (`1`, `2`, `3`) cambian de orden según el arranque aleatorio. Para que **Clúster 1** sea siempre el perfil céntrico, **Clúster 2** el automotor y **Clúster 3** el residencial, en lugar de asignar etiquetas a mano según el orden de salida, las identificamos directamente por la geometría de sus centroides en `km_final$centers`: primero aislamos el grupo con mayor tasa estandarizada de hurto a motocicletas (`id_comercial`), luego entre los dos restantes elegimos el de mayor hurto a personas (`id_centro`) y el tercero queda como perfil residencial (`id_residencial`).

```
## 3.4 Ajuste del modelo final K* = 3 e identificación determinística por centroides ----
set.seed(20261014)
km_final  <- kmeans(matriz_scale, centers = k_optimo, nstart = 50)
sil_final <- silhouette(km_final$cluster, dist_euclidea)

# Identificamos cada perfil según la posición económica de su centroide estandarizado
centroides_df <- as_tibble(km_final$centers) |>
  mutate(cluster_raw = row_number())

id_comercial <- centroides_df |>
  slice_max(tasa_motos_prom, n = 1) |>
  pull(cluster_raw)

id_centro <- centroides_df |>
  filter(cluster_raw != id_comercial) |>
  slice_max(tasa_personas_prom, n = 1) |>
  pull(cluster_raw)

id_residencial <- setdiff(1:3, c(id_comercial, id_centro))

# Consolidamos la tabla maestra de clústeres y silueta individual por localidad
df_clusters <- matriz_localidad |>
  mutate(
    cluster_raw       = km_final$cluster,
    silueta_localidad = round(as.numeric(sil_final[, 3]), 4),
    cluster_id = case_when(
      cluster_raw == id_centro      ~ 1L,
      cluster_raw == id_comercial   ~ 2L,
      cluster_raw == id_residencial ~ 3L
    ),
    cluster_nombre = case_when(
      cluster_id == 1L ~ "Céntrico e Institucional",
      cluster_id == 2L ~ "Comercial y Automotor",
      cluster_id == 3L ~ "Residencial y Periférico"
    ),
    perfil_seguridad = case_when(
      cluster_id == 1L ~ "Alta criticidad en hurto a personas y residencias (núcleo céntrico)",
      cluster_id == 2L ~ "Alta concentración de hurto automotor y motocicletas (corredor
↪  comercial)",
      cluster_id == 3L ~ "Tasa per cápita moderada en zonas de alta densidad residencial"
    )
  ) |>
```

```r
  select(-cluster_raw) |>
  arrange(cluster_id, desc(tasa_total_prom))

stopifnot(nrow(df_clusters) == 19)
stopifnot(length(unique(df_clusters$cluster_nombre)) == 3)

## 3.5 Resumen tabular de los tres perfiles territoriales ----
perfiles_resumen <- df_clusters |>
  group_by(cluster_id, cluster_nombre) |>
  summarise(
    num_localidades        = n(),
    tasa_media_personas    = mean(tasa_personas_prom),
    tasa_media_residencias = mean(tasa_resid_prom),
    tasa_media_motos       = mean(tasa_motos_prom),
    tasa_media_total       = mean(tasa_total_prom),
    localidades_miembros   = paste(localidad, collapse = ", "),
    .groups = "drop"
  ) |>
  arrange(cluster_id)

knitr::kable(
  perfiles_resumen |> select(-cluster_id),
  digits    = 1,
  col.names = c(
    "Perfil territorial", "N° localidades", "Hurto personas",
    "Hurto residencias", "Hurto motos", "Tasa total", "Localidades miembro"
  )
)
```

Tabla 3: Perfiles delictivos promedio por clúster territorial (tasas anuales por 100.000 habitantes)

Perfil territorial	N° localidades	Hurto personas	Hurto residencias	Hurto motos	Tasa total	Localidades miembro
Céntrico e Institucional	5	5834.7	175.9	60.8	6071.4	La Candelaria, Chapinero, Santa Fe, Teusaquillo, Barrios Unidos
Comercial y Automotor	2	5727.9	150.9	153.0	6031.8	Los Mártires, Antonio Nariño
Residencial y Periférico	12	1222.8	73.3	57.1	1353.2	Puente Aranda, Fontibón, Engativá, Usaquén, Tunjuelito, Kennedy, Rafael Uribe Uribe, Suba, San Cristóbal, Ciudad Bolívar, Bosa, Usme

Los tres perfiles revelan una clara especialización urbana:

- **Clúster 1: Céntrico e Institucional (5 localidades):** La Candelaria, Chapinero, Santa Fe, Teusaquillo y

Barrios Unidos concentran las tasas más altas de hurto a personas (5,835 por 100.000 hab.) y hurto a residencias (175.9), impulsadas por la población flotante diaria sobre una base residencial acotada.

- **Clúster 2: Comercial y Automotor (2 localidades):** Los Mártires y Antonio Nariño presentan el pico extremo en hurto de motocicletas (153 por 100.000 hab.), más del doble que los otros grupos, asociado a corredores de comercio mayorista, talleres y autopartes. Un matiz interesante es que Antonio Nariño registra una silueta individual negativa (-0.2116), pues comparte la especialidad motera de Los Mártires (`127,8`) pero con una tasa de hurto a personas mucho más moderada (`3.065,9` frente a `8.389,9`), ubicándose geométricamente en la frontera entre perfiles.
- **Clúster 3: Residencial y Periférico (12 localidades):** Puente Aranda, Fontibón, Engativá, Usaquén, Tunjuelito, Kennedy, Rafael Uribe Uribe, Suba, San Cristóbal, Ciudad Bolívar, Bosa y Usme mantienen tasas relativas moderadas (1,223 en personas) debido a sus grandes denominadores demográficos.

3.4. Visualización tridimensional y bidimensional de los clústeres

La Figura 4 muestra las 19 localidades y los 3 centroides en el espacio completo de las tres modalidades delictivas (interactivo en HTML y en perspectiva 3D en PDF). La Figura 5 proyecta ese espacio en dos dimensiones usando el tamaño del punto para representar el hurto a residencias.

```
## 3.6 Cubo tridimensional interactivo (HTML) y proyección perspectiva (PDF) ----
centroides_3d <- df_clusters |>
  group_by(cluster_nombre) |>
  summarise(
    centro_pers  = mean(tasa_personas_prom),
    centro_resid = mean(tasa_resid_prom),
    centro_motos = mean(tasa_motos_prom),
    .groups = "drop"
  )

df_plot_3d <- df_clusters |>
  left_join(centroides_3d, by = "cluster_nombre") |>
  mutate(
    tooltip_localidad = paste0(
      "<b>", localidad, "</b><br>",
      "Clúster: ", cluster_nombre, "<br>",
      "Hurto personas: ", scales::comma(round(tasa_personas_prom, 1)), " por 100k hab.<br>",
      "Hurto residencias: ", scales::comma(round(tasa_resid_prom, 1)), " por 100k hab.<br>",
      "Hurto motos: ", scales::comma(round(tasa_motos_prom, 1)), " por 100k hab.<br>",
      "Silueta S(i): ", round(silueta_localidad, 3)
    )
  )

# Construimos segmentos con NA separador para dibujar los radios localidad -> centroide
segmentos_3d <- bind_rows(
  lapply(seq_len(nrow(df_plot_3d)), function(i) {
    fila <- df_plot_3d[i, ]
    tibble(
      x = c(fila$tasa_personas_prom, fila$centro_pers, NA_real_),
      y = c(fila$tasa_resid_prom,    fila$centro_resid, NA_real_),
      z = c(fila$tasa_motos_prom,    fila$centro_motos, NA_real_),
      cluster_nombre = fila$cluster_nombre
```

```
    )
  })
)

colores_clusters <- c(
  "Céntrico e Institucional" = "#c0392b",
  "Comercial y Automotor"    = "#e67e22",
  "Residencial y Periférico" = "#27ae60"
)

if (knitr::is_html_output()) {
  plotly::plot_ly() |>
    plotly::add_trace(
      data         = df_plot_3d,
      x            = ~tasa_personas_prom,
      y            = ~tasa_resid_prom,
      z            = ~tasa_motos_prom,
      color        = ~cluster_nombre,
      colors       = colores_clusters,
      text         = ~localidad,
      hovertext    = ~tooltip_localidad,
      hoverinfo    = "text",
      type         = "scatter3d",
      mode         = "markers",
      textposition = "top center",
      textfont     = list(size = 9, color = "#2c3e50"),
      marker       = list(
        size    = 7,
        opacity = 0.92,
        line    = list(color = "white", width = 1.2)
      )
    ) |>
    plotly::add_trace(
      data       = segmentos_3d,
      x          = ~x,
      y          = ~y,
      z          = ~z,
      color      = ~cluster_nombre,
      colors     = colores_clusters,
      type       = "scatter3d",
      mode       = "lines",
      line       = list(width = 2, dash = "solid"),
      opacity    = 0.35,
      hoverinfo  = "none",
      showlegend = FALSE
    ) |>
    plotly::add_trace(
      data      = centroides_3d,
      x         = ~centro_pers,
      y         = ~centro_resid,
      z         = ~centro_motos,
      color     = ~cluster_nombre,
```

```
    colors    = colores_clusters,
    hovertext = ~paste0(
      "<b>★ Centroide: ", cluster_nombre, "</b><br>",
      "Media personas: ", scales::comma(round(centro_pers, 1)), " por 100k hab.<br>",
      "Media residencias: ", scales::comma(round(centro_resid, 1)), " por 100k hab.<br>",
      "Media motos: ", scales::comma(round(centro_motos, 1)), " por 100k hab."
    ),
    hoverinfo  = "text",
    type       = "scatter3d",
    mode       = "markers",
    showlegend = FALSE,
    marker     = list(
      size   = 11,
      symbol = "diamond",
      line   = list(color = "#1a1a1a", width = 2)
    )
  ) |>
  plotly::layout(
    title = list(
      text    = "<b>Espacio Tridimensional de Clústeres K-Means (K* = 3)</b><br><sup>Esferas: 19
      ↪  localidades | Diamantes: centroides μ_k (pase el cursor para detalles)</sup>",
      x       = 0.5,
      xanchor = "center",
      y       = 0.98,
      font    = list(size = 13)
    ),
    margin = list(l = 10, r = 10, b = 25, t = 75),
    scene = list(
      aspectmode = "cube",
      xaxis = list(
        title           = list(text = "Hurto personas (tasa/100k)", font = list(size = 11)),
        tickfont        = list(size = 9),
        showbackground  = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor       = "#ffffff",
        zerolinecolor   = "#dcdde1"
      ),
      yaxis = list(
        title           = list(text = "Hurto residencias (tasa/100k)", font = list(size = 11)),
        tickfont        = list(size = 9),
        showbackground  = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor       = "#ffffff",
        zerolinecolor   = "#dcdde1"
      ),
      zaxis = list(
        title           = list(text = "Hurto motos (tasa/100k)", font = list(size = 11)),
        tickfont        = list(size = 9),
        showbackground  = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor       = "#ffffff",
        zerolinecolor   = "#dcdde1"
```

```
        ),
        camera = list(eye = list(x = 1.45, y = -1.45, z = 0.75))
      ),
      updatemenus = list(
        list(
          type        = "buttons",
          direction   = "right",
          x           = 0.5,
          xanchor     = "center",
          y           = -0.06,
          bgcolor     = "#ffffff",
          bordercolor = "#cccccc",
          font        = list(size = 10),
          buttons     = list(
            list(
              method = "restyle",
              args   = list("mode", list("markers", "markers", "markers", "lines", "lines",
              ↪  "lines", "markers", "markers", "markers")),
              label  = "Ocultar nombres"
            ),
            list(
              method = "restyle",
              args   = list("mode", list("markers+text", "markers+text", "markers+text", "lines",
              ↪  "lines", "lines", "markers", "markers", "markers")),
              label  = "Mostrar nombres"
            )
          )
        )
      ),
      legend = list(orientation = "h", x = 0.5, xanchor = "center", y = -0.16)
    )
} else {
  par(mar = c(3.2, 2, 2.5, 2), xpd = TRUE)
  rango_x <- range(df_plot_3d$tasa_personas_prom) * c(0.9, 1.08)
  rango_y <- range(df_plot_3d$tasa_resid_prom)    * c(0.9, 1.08)
  rango_z <- range(df_plot_3d$tasa_motos_prom)    * c(0.9, 1.08)

  matriz_3d <- persp(
    x        = rango_x,
    y        = rango_y,
    z        = matrix(rango_z[1], nrow = 2, ncol = 2),
    zlim     = rango_z,
    theta    = -38,
    phi      = 22,
    expand   = 0.75,
    col      = "#f4f6f9",
    border   = "#bdc3c7",
    ticktype = "detailed",
    nticks   = 4,
    xlab     = "Hurto personas (tasa/100k)",
    ylab     = "Hurto residencias (tasa/100k)",
    zlab     = "Hurto motos (tasa/100k)",
```

```
    main     = "Espacio Tridimensional de Clústeres K-Means (K* = 3)"
  )

  for (i in seq_len(nrow(df_plot_3d))) {
    seg_proj <- trans3d(
      x    = c(df_plot_3d$tasa_personas_prom[i], df_plot_3d$centro_pers[i]),
      y    = c(df_plot_3d$tasa_resid_prom[i],    df_plot_3d$centro_resid[i]),
      z    = c(df_plot_3d$tasa_motos_prom[i],    df_plot_3d$centro_motos[i]),
      pmat = matriz_3d
    )
    lines(seg_proj, col = colores_clusters[df_plot_3d$cluster_nombre[i]], lwd = 1.1)
  }

  pts_loc <- trans3d(
    df_plot_3d$tasa_personas_prom,
    df_plot_3d$tasa_resid_prom,
    df_plot_3d$tasa_motos_prom,
    pmat = matriz_3d
  )
  points(
    pts_loc,
    pch = 21,
    bg  = colores_clusters[df_plot_3d$cluster_nombre],
    col = "white",
    cex = 1.5
  )

  pts_cen <- trans3d(
    centroides_3d$centro_pers,
    centroides_3d$centro_resid,
    centroides_3d$centro_motos,
    pmat = matriz_3d
  )
  points(
    pts_cen,
    pch = 23,
    bg  = colores_clusters[centroides_3d$cluster_nombre],
    col = "black",
    cex = 2.2,
    lwd = 1.5
  )
  legend(
    "bottom",
    inset  = -0.10,
    legend = names(colores_clusters),
    pt.bg  = colores_clusters,
    pch    = 21,
    horiz  = TRUE,
    bty    = "n",
    cex    = 0.85
  )
}
```

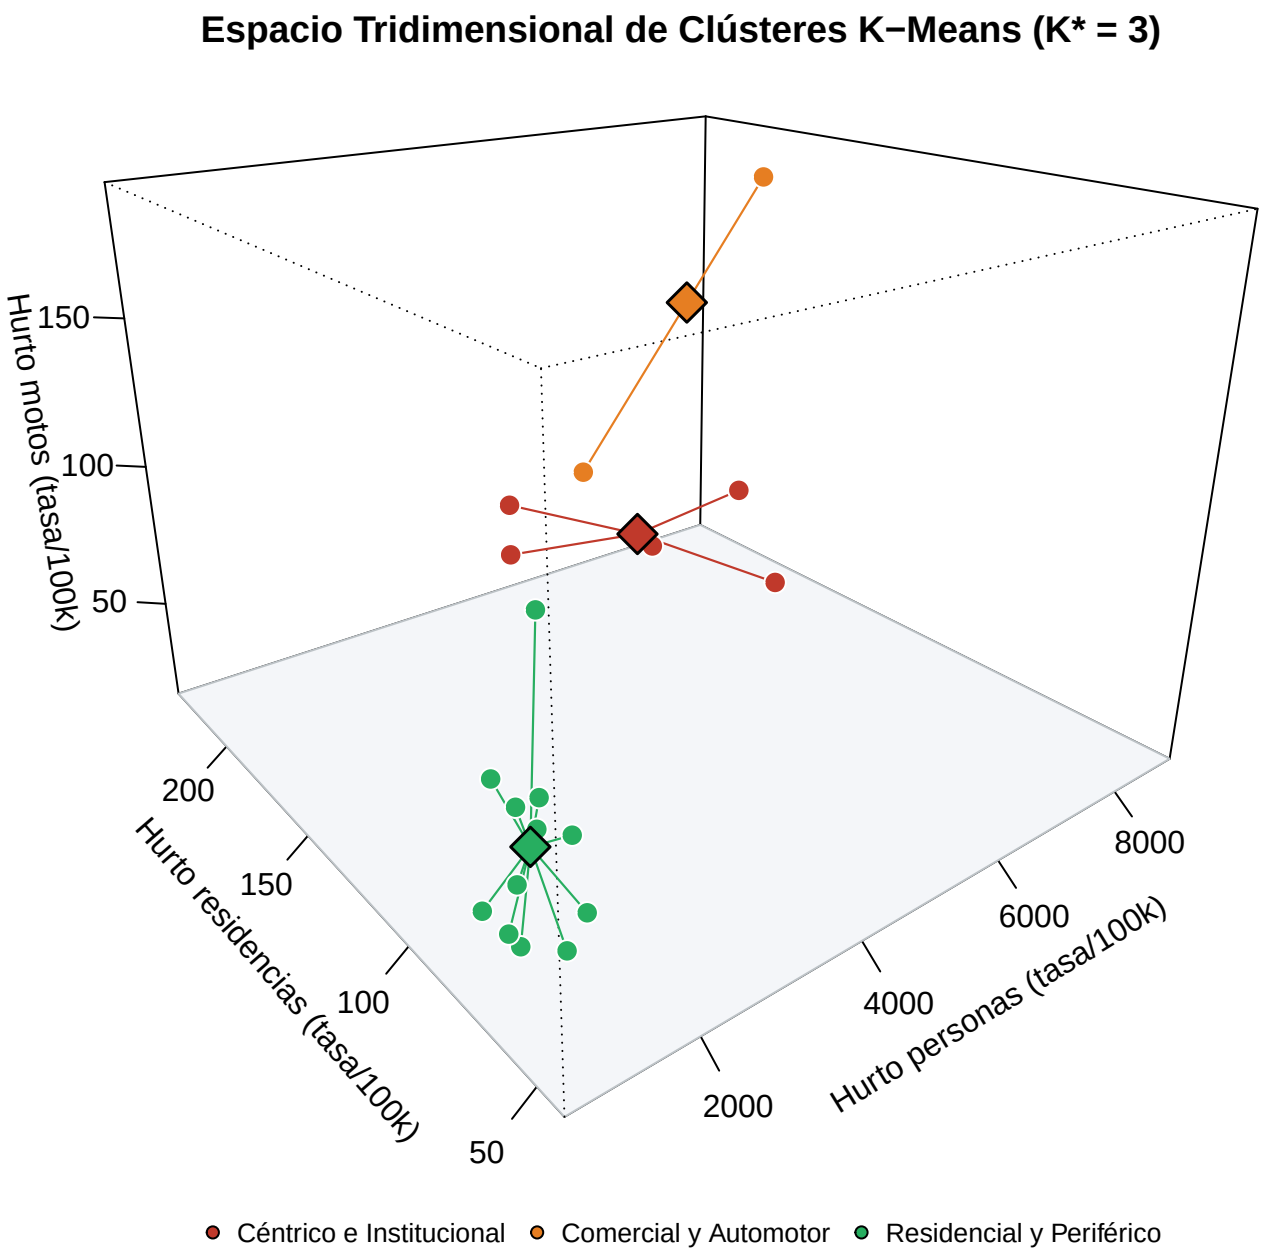


Figura 4: Representación tridimensional de las 19 localidades, sus radios de pertenencia y los 3 centroides de K-Means

```
## 3.7 Proyección bidimensional estática con etiquetas sin solapamiento ----
ggplot(
  df_clusters,
  aes(
    x     = tasa_personas_prom,
    y     = tasa_motos_prom,
    color = cluster_nombre,
    size  = tasa_resid_prom
```

```
  )
) +
  geom_point(alpha = 0.88) +
  geom_text_repel(
    aes(label = localidad),
    size          = 3.2,
    fontface      = "bold",
    box.padding   = 0.4,
    point.padding = 0.3,
    max.overlaps  = 20,
    show.legend   = FALSE
  ) +
  scale_color_manual(values = colores_clusters) +
  scale_size_continuous(range = c(3, 8.5), name = "Hurto residencias\n(por 100.000 hab.)") +
  scale_x_continuous(labels = scales::comma) +
  scale_y_continuous(labels = scales::comma) +
  labs(
    title    = "Tipología Territorial del Hurto en Bogotá",
    subtitle = "Agrupamiento no supervisado con K-Means (K* = 3)",
    x        = "Tasa promedio de hurto a personas (por 100.000 hab.)",
    y        = "Tasa promedio de hurto a motocicletas (por 100.000 hab.)",
    color    = "Clúster territorial"
  ) +
  theme_minimal(base_size = 11) +
  theme(legend.position = "bottom", plot.title = element_text(face = "bold", size = 13))
```

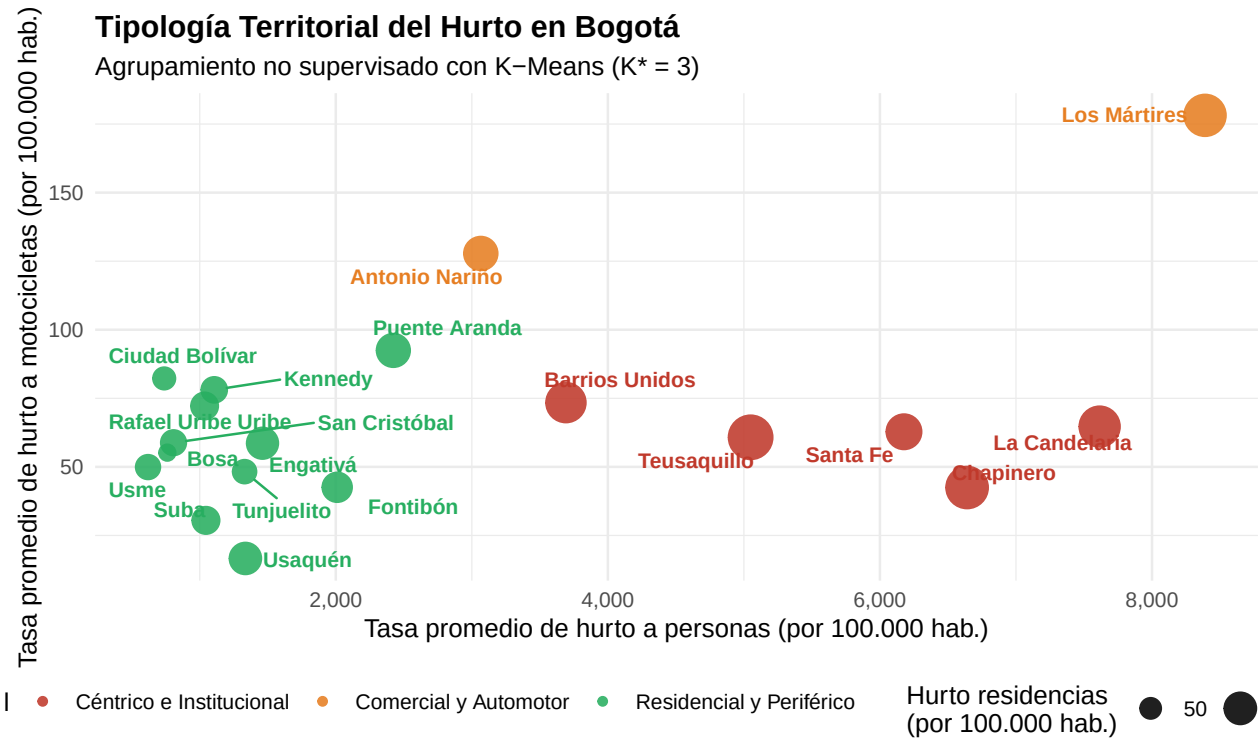


Figura 5: Proyección bidimensional de las 19 localidades en el espacio de tasas de hurto (el tamaño del punto representa el hurto a residencias)

4. Diagnóstico del corpus y análisis de sentimiento con `sentometrics`

Esta sección integra en vivo el código de `scripts/06_descriptivos_corpus.R` y las tres primeras fases de `scripts/03_analisis_sentometrics.R`. Primero auditamos la cobertura temporal, geográfica y léxica de las 3.916 noticias; luego explicamos con intuición cotidiana las ecuaciones con que `sentometrics` puntúa y agrega esas noticias; y por último replicamos en R la construcción del corpus, los léxicos en español, las puntuaciones documentales, las noticias pico y las 364 series temporales.

4.1. Cobertura temporal, geográfica y extensión léxica del corpus

Antes de calcular puntajes emocionales conviene verificar cuántas noticias hay por año y por localidad, si existen vacíos en algún cruce localidad-año y qué tan largos son los textos. Como las estadísticas oficiales de 2026 tienen corte a septiembre, nos aseguramos explícitamente de restringir el corpus a esa misma ventana temporal.

```
# 4. Réplica de scripts/06_descriptivos_corpus.R y 03_analisis_sentometrics.R ----

## 4.1 Tema común y filtro de corte temporal hasta septiembre de 2026 ----
tema_limpio <- theme_minimal(base_size = 11) +
  theme(
    panel.grid.major = element_blank(),
    panel.grid.minor = element_blank(),
    axis.line        = element_line(color = "#cccccc", linewidth = 0.4),
    plot.title       = element_text(face = "bold")
  )

noticias_desc <- df_noticias_base |>
  mutate(año = as.integer(año), mes = as.integer(mes)) |>
  filter(!(año == 2026 & mes > 9))

stopifnot(nrow(noticias_desc) > 0, length(unique(noticias_desc$localidad)) == 19)

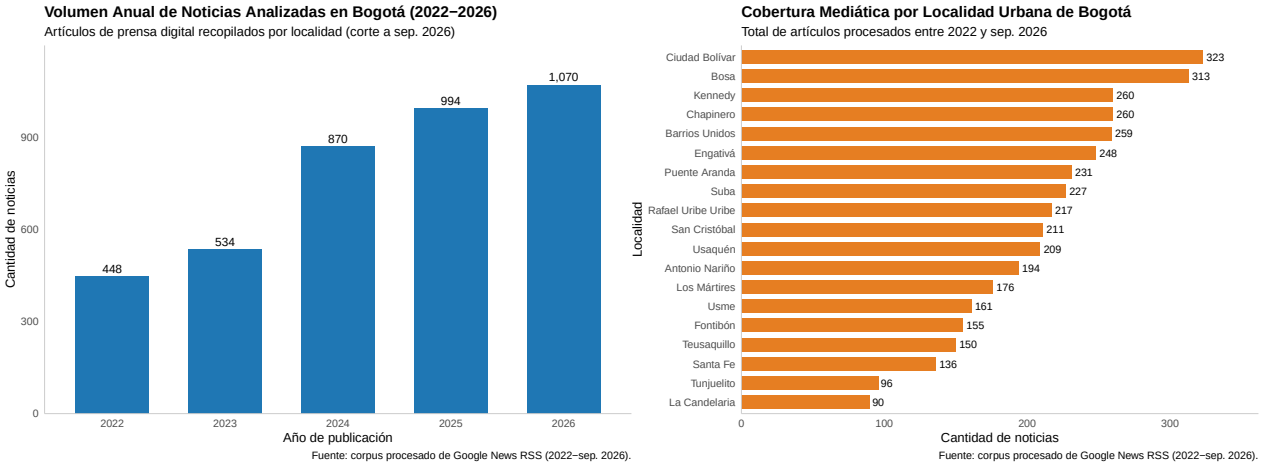
## 4.1.1 Volumen de noticias por año ----
noticias_por_anio <- noticias_desc |>
  group_by(año) |>
  summarise(conteo = n(), .groups = "drop")

p_fig3 <- ggplot(noticias_por_anio, aes(x = factor(año), y = conteo)) +
  geom_col(fill = "#1f77b4", width = 0.65) +
  geom_text(aes(label = scales::comma(conteo)), vjust = -0.4, size = 3.6) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.12))) +
  labs(
    title    = "Volumen Anual de Noticias Analizadas en Bogotá (2022-2026)",
    subtitle = "Artículos de prensa digital recopilados por localidad (corte a sep. 2026)",
    x        = "Año de publicación",
    y        = "Cantidad de noticias",
    caption  = "Fuente: corpus procesado de Google News RSS (2022-sep. 2026)."
  ) +
  tema_limpio
```

```
## 4.1.2 Volumen acumulado de noticias por localidad ----
noticias_por_localidad <- noticias_desc |>
  group_by(localidad) |>
  summarise(conteo = n(), .groups = "drop") |>
  arrange(desc(conteo))

p_fig4 <- ggplot(noticias_por_localidad, aes(x = reorder(localidad, conteo), y = conteo)) +
  geom_col(fill = "#e67e22", width = 0.7) +
  geom_text(aes(label = scales::comma(conteo)), hjust = -0.2, size = 3.3) +
  coord_flip() +
  scale_y_continuous(expand = expansion(mult = c(0, 0.12))) +
  labs(
    title    = "Cobertura Mediática por Localidad Urbana de Bogotá",
    subtitle = "Total de artículos procesados entre 2022 y sep. 2026",
    x        = "Localidad",
    y        = "Cantidad de noticias",
    caption  = "Fuente: corpus procesado de Google News RSS (2022-sep. 2026)."
  ) +
  tema_limpio

print(p_fig3)
print(p_fig4)
```



(a) Volumen anual de artículos recopilados

(b) Distribución acumulada por localidad urbana

Figura 6: Cobertura anual y geográfica del corpus de noticias de seguridad en Bogotá (2022-septiembre de 2026)

Para comprobar que ninguna localidad quede vacía en algún año y entender la extensión léxica de los artículos, replicamos también el mapa de calor Localidad x Año y el histograma de palabras del cuerpo limpio.

```
## 4.1.3 Mapa de calor Localidad x Año ----
heatmap_df <- noticias_desc |>
  group_by(localidad, año) |>
  summarise(conteo = n(), .groups = "drop")
```

```r
p_fig5 <- ggplot(heatmap_df, aes(x = factor(año), y = reorder(localidad, conteo, FUN = sum), fill =
↪  conteo)) +
  geom_tile(color = "white", linewidth = 0.4) +
  geom_text(
    aes(label = conteo, color = conteo > 55),
    size        = 3.3,
    fontface    = "bold",
    show.legend = FALSE
  ) +
  scale_fill_viridis_c(option = "plasma", name = "N° noticias") +
  scale_color_manual(values = c("FALSE" = "white", "TRUE" = "#1a1a1a")) +
  labs(
    title    = "Intensidad de Cobertura Periodística: Localidad x Año",
    subtitle = "Número de artículos por localidad y año (2022-sep. 2026)",
    x        = "Año",
    y        = "Localidad",
    caption  = "Fuente: corpus procesado de Google News RSS (2022-sep. 2026)."
  ) +
  tema_limpio +
  theme(axis.line = element_blank())

print(p_fig5)
```

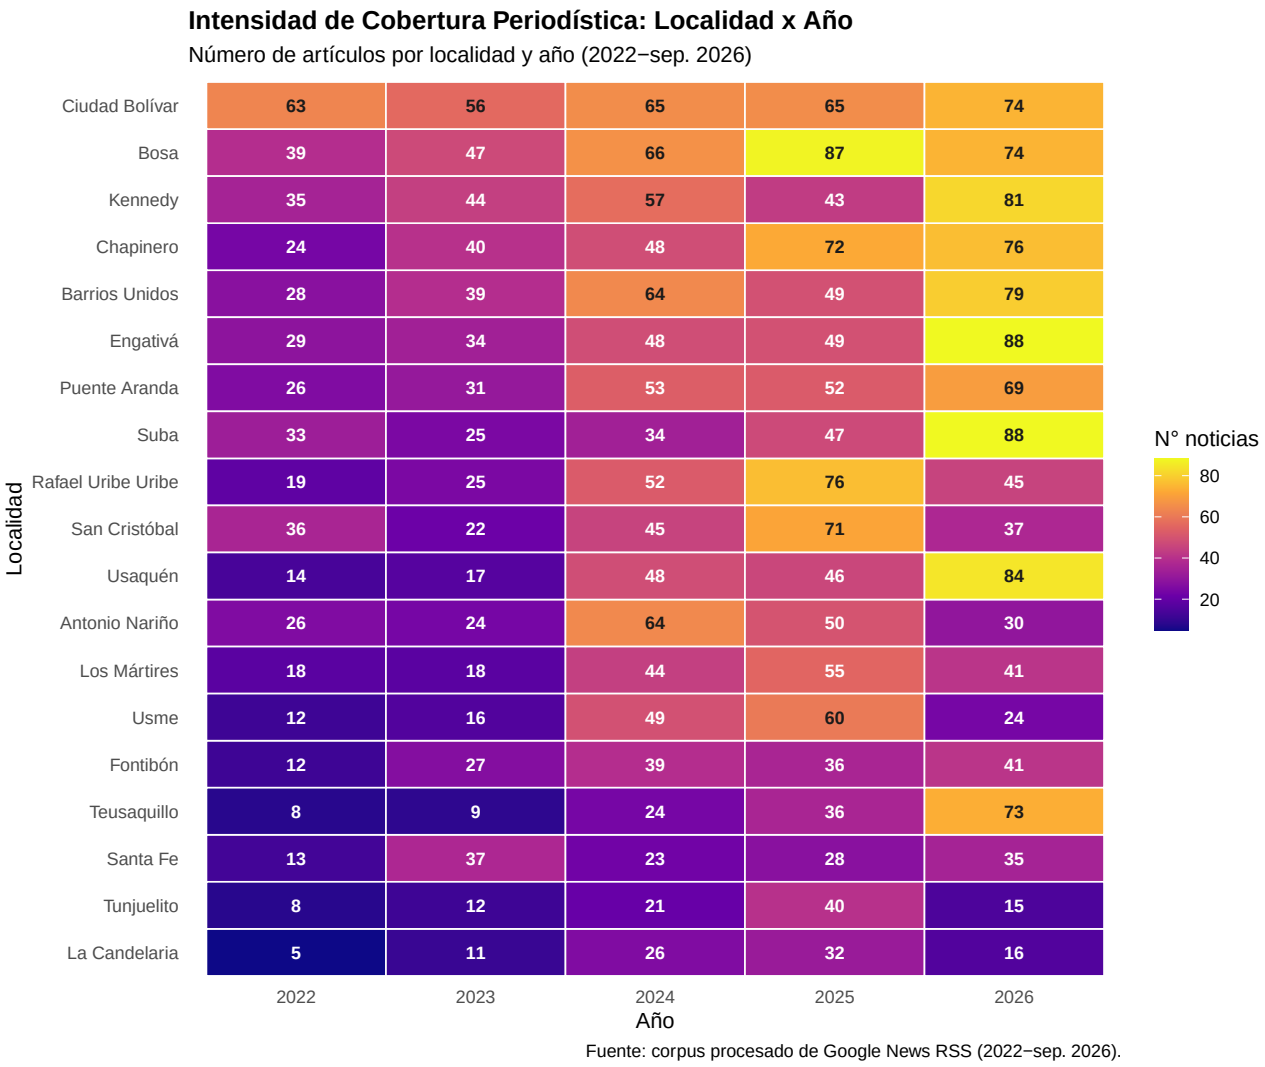


Figura 7: Intensidad de cobertura periodística por localidad y año (2022-septiembre de 2026)

```
## 4.1.4 Distribución de extensión léxica (media y mediana de palabras) ----
estadisticas_longitud <- tibble(
  estadistico = c(
    paste0("Mediana (", round(median(noticias_desc$palabras_cuerpo, na.rm = TRUE), 1), "
    ↪  palabras)"),
    paste0("Media (", round(mean(noticias_desc$palabras_cuerpo, na.rm = TRUE), 1), " palabras)")
  ),
  valor = c(
    median(noticias_desc$palabras_cuerpo, na.rm = TRUE),
    mean(noticias_desc$palabras_cuerpo, na.rm = TRUE)
  )
)

p_fig6 <- ggplot(noticias_desc, aes(x = palabras_cuerpo)) +
  geom_histogram(binwidth = 50, fill = "#2980b9", color = "white") +
  geom_vline(
    data      = estadisticas_longitud,
```

```
    aes(xintercept = valor, color = estadistico, linetype = estadistico),
    linewidth = 0.8
  ) +
  scale_color_manual(
    name   = "Referencia",
    values = setNames(c("#e67e22", "#c0392b"), estadisticas_longitud$estadistico)
  ) +
  scale_linetype_manual(
    name   = "Referencia",
    values = setNames(c("dashed", "dotdash"), estadisticas_longitud$estadistico)
  ) +
  labs(
    title    = "Distribución de la Extensión Léxica por Artículo",
    subtitle = "Extensión del cuerpo de las noticias en palabras (2022-sep. 2026)",
    x        = "Número de palabras en el cuerpo limpio",
    y        = "Frecuencia de artículos",
    caption  = "Fuente: corpus procesado de Google News RSS (2022-sep. 2026)."
  ) +
  tema_limpio +
  theme(legend.position = "top")

print(p_fig6)
```

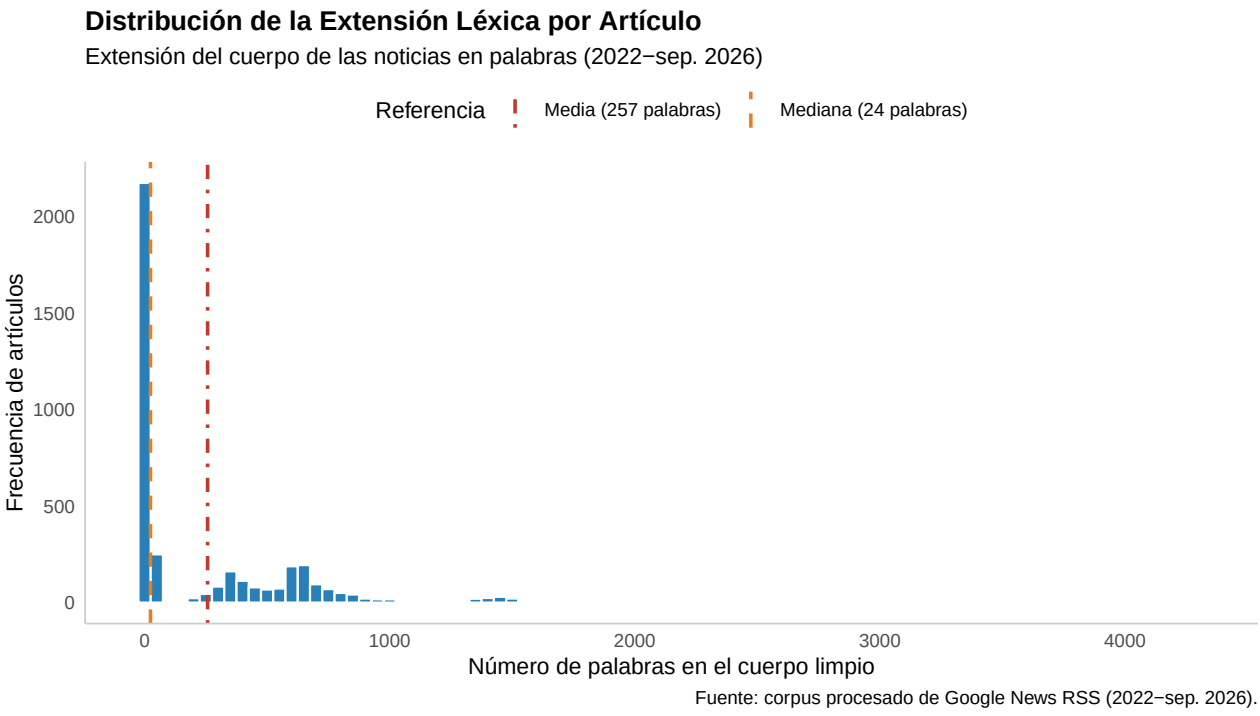


Figura 8: Distribución de la extensión léxica en palabras del cuerpo limpio de las noticias

La Figura 8 revela un hecho práctico que condiciona toda la medición posterior: en el corpus conviven artículos extensos de prensa web (de 300 a 900 palabras) con despachos RSS muy breves (de alrededor de 20 palabras, frecuentes en el corte de 2026). Si midiéramos el sentimiento con una regla ingenua que no controle esta

diferencia de longitud, mezclaríamos el tono de una noticia con su tamaño. La siguiente subsección explica paso a paso cómo resuelve este problema `sentometrics`.

4.2. Cómo mide y agrega el sentimiento `sentometrics`: intuición paso a paso

En lugar de leer las ecuaciones como símbolos abstractos, conviene imaginar el trabajo de `sentometrics` en tres preguntas concretas que van desde una sola palabra hasta una serie mensual completa.

4.2.1. Paso 1: ¿Cómo calificamos una sola noticia sin que el largo del texto engañe?

Supón que tenemos dos noticias sobre un mismo atraco en Kennedy: una nota corta de 25 palabras (*"Violento atraco armado en Kennedy dejó dos heridos y sin capturas"*) y una crónica de 600 palabras llena de contexto descriptivo (*"en horas de la mañana, frente a la estación, según testigos del sector…"*). Si solo sumáramos puntos positivos y negativos sin dividir, la crónica larga podría sumar más palabras emocionales únicamente por tener más texto. Por otro lado, si dividiéramos por las 600 palabras totales, el relleno informativo neutro diluiría la alarma real del hecho y haría que la crónica pareciera casi neutra frente a la nota corta.

Para resolver ambas trampas, `sentometrics` calcula el puntaje de la noticia i en la fecha t, usando el diccionario ℓ y el filtro temático o territorial k, de esta manera:

$$s_{i,t}^{(\ell,k)} = f_{i,k} \cdot \frac{\sum_{w \in d_i} v_w \cdot m_w^{(\ell)}}{N_{\text{pol}}(d_i)} \tag{5}$$

Cada pieza de la Ecuación 5 cumple una tarea intuitiva:

- $m_w^{(\ell)}$ **(el peso base de cada palabra en el diccionario):** cuando una palabra w de la noticia d_i aparece en el diccionario ℓ (ya sea el general `nrc_es` o el especializado en delitos urbanos `crimen_es`), aporta su carga emocional base. Términos como *"homicidio"* o *"atraco"* restan (valores negativos), mientras palabras de respuesta institucional como *"captura"* o *"incautación"* suman (valores positivos).
- v_w **(el contexto inmediato, `valenceIn`):** las palabras no se leen aisladas. Antes de sumar, `sentometrics` revisa los vecinos cercanos de cada palabra dentro de una ventana local y aplica un factor multiplicador v_w:
  - **Negadores ($t = 1$, por ejemplo `no`, `sin`, `nunca`):** invierten el signo. Así, *"operativo **sin** capturas"* convierte el aporte positivo de *"capturas"* en negativo.
  - **Amplificadores ($t = 2$, por ejemplo `brutalmente`, `muy`, `gravemente`):** multiplican la intensidad por $1{,}8$ (o $1{,}5$ en grados intermedios).
  - **Atenuadores ($t = 3$, por ejemplo `poco`, `levemente`, `apenas`):** rebajan el peso a $0{,}2$, moderando el puntaje cuando el suceso se describe como menor o aislado.
  - **Adversativos ($t = 4$, por ejemplo `pero`, `aunque`, `embargo`):** dan mayor peso a la idea posterior al conector y atenúan la anterior (*"se reforzó el patrullaje, **pero** aumentaron los fleteos"*).
- $N_{\text{pol}}(d_i)$ **(el denominador `proportionalPol`):** en vez de dividir entre todas las palabras del artículo, dividimos únicamente entre el número de palabras que **sí tuvieron carga en el diccionario**. De ese modo comparamos la intensidad promedio del lenguaje emocional de cada noticia sin castigar a los reportajes largos por incluir contexto neutro, ni inflar las notas cortas.
- $f_{i,k}$ **(el interruptor de tema o territorio):** vale 1 si la noticia trata sobre esa localidad, clúster o delito (por ejemplo, `loc_kennedy = 1`) y 0 en caso contrario. Su función es dejar pasar hacia cada serie únicamente las noticias que pertenecen a ese grupo.

4.2.2. Paso 2: ¿Cómo pasamos de noticias sueltas a un termómetro mensual?

Dentro de un mismo mes t se publican D_t noticias distintas. Para resumirlas en un único valor mensual $\bar{S}_t^{(\ell,k)}$ necesitamos decidir cuánto pesa cada artículo en el promedio del mes:

$$\bar{S}_t^{(\ell,k)} = \sum_{i=1}^{D_t} \theta_{i,t}\, s_{i,t}^{(\ell,k)}, \qquad \text{con } \theta_{i,t} = \frac{\text{palabras}(d_i)}{\sum_{r=1}^{D_t} \text{palabras}(d_r)} \tag{6}$$

La lógica de la Ecuación 6 responde a dos criterios de sentido común:

- **Ponderación por extensión (`howDocs = "proportional"`):** en una nota breve de dos líneas y un reportaje completo de 500 palabras, el segundo aporta mayor cobertura informativa al debate mensual. El peso $\theta_{i,t}$ es simplemente la fracción de palabras que aporta la noticia i sobre el total de palabras publicadas ese mes. (Nota: el texto corto ya se protegió en el Paso 1 al usar `proportionalPol` para no diluir el puntaje unitario; aquí el tamaño determina cuánto espacio mediático ocupó esa nota dentro del mes).
- **Ignorar ceros puros (`do.ignoreZeros = TRUE`):** si una noticia resulta neutra ($s = 0$) porque ninguna de sus palabras coincidió con el diccionario, no entra a promediar hacia cero la temperatura emocional del mes; el promedio mensual se calcula solo entre las noticias que sí expresan algún tono. Cuando en todo un mes ninguna noticia toca cierta localidad o tema, rellenamos con cero mediante `measures_fill(..., fill = "zero")` para mantener la serie continua.

4.2.3. Paso 3: ¿Cómo capturamos que el miedo y la agenda noticiosa persisten varios meses?

La opinión pública no borra su memoria el primer día de cada mes. Una ola de atracos cubierta en abril sigue pesando sobre la percepción ciudadana y el clima político en mayo o junio, aunque ese efecto se vaya desvaneciendo. Por eso la Ecuación 7 suaviza el sentimiento mensual usando una ventana móvil de 6 meses (el mes actual $j = 0$ y los 5 meses anteriores $j = 1, \ldots, 5$, configurado con `lag = 6`):

$$S_t^{(\ell,k,\tau)} = \sum_{j=0}^{5} b_j^{(\tau)}\, \bar{S}_{t-j}^{(\ell,k)} \tag{7}$$

Los pesos temporales $b_j^{(\tau)}$ siempre suman 1 y funcionan como una curva de memoria: dicen qué proporción de la lectura de hoy viene del mes actual frente a uno, dos o cinco meses atrás. Como no sabemos de antemano si la agenda mediática olvida rápido o recuerda varios meses, generamos **siete curvas de memoria distintas** (τ):

1. **Lineal (1 esquema):** la memoria cae de manera pareja mes tras mes.
2. **Exponencial (`alphasExp = 0.2` y `0.5`, 2 esquemas):** el peso cae rápido al principio y deja una cola suave. Con $\alpha = 0{,}5$ casi toda la señal se concentra en el mes presente y el inmediatamente anterior; con $\alpha = 0{,}2$ el pasado pesa durante más tiempo.
3. **Curvas Beta (`aBeta = 1, 2` x `bBeta = 2, 3`, 4 esquemas):** son curvas flexibles que pueden concentrar el peso en el presente, repartirlo suavemente o formar una pequeña "campana" donde el impacto alcanza su pico uno o dos meses después de la noticia.

Al combinar **2 diccionarios** (ℓ) x **26 filtros binarios** (k) x **7 esquemas de memoria** (τ), construimos $2 \times 26 \times 7 = 364$ series mensuales que resumen la narrativa mediática desde ángulos complementarios. Luego, en la Sección 5, Elastic Net se encarga de seleccionar cuáles de esas memorias ayudan realmente a predecir la dinámica del hurto.

4.3. Construcción del `sento_corpus` y diagnósticos de `corpus_summarize()`

Replicamos ahora la Fase 1 de `scripts/03_analisis_sentometrics.R` y los diagnósticos de cobertura temporal por *feature* de `scripts/06_descriptivos_corpus.R`. Una regla estricta de `sentometrics` exige que los nombres de las características binarias no contengan guiones medios (-), ya que el paquete usa internamente doble guion (--) como separador entre diccionario, característica y esquema temporal. Por eso normalizamos los nombres de las 19 localidades a `snake_case` con el prefijo `loc_`.

```
## 4.3 Construcción del objeto sento_corpus y sus 26 características binarias ----

# Función de normalización a snake_case sin tildes ni guiones medios '-'
normalizar_nombre_feature <- function(x) {
  x |>
    stringi::stri_trans_general("Latin-ASCII") |>
    str_to_lower() |>
    str_replace_all("[\\s\\-]+", "_") |>
    str_replace_all("[^a-z0-9_]", "")
}

# Cruzamos cada noticia con el clúster territorial calculado en la Sección 3
# y creamos el texto combinado (titular + resumen + primeros 800 caracteres del cuerpo)
df_base_corpus <- df_noticias_base |>
  left_join(
    df_clusters |> select(localidad, cluster_id, cluster_nombre),
    by = "localidad"
  ) |>
  mutate(
    id    = paste0("doc_", row_number()),
    date  = as.Date(fecha),
    texts = str_squish(paste(
      coalesce(titulo, ""),
      coalesce(resumen, ""),
      str_sub(coalesce(cuerpo, ""), 1, 800),
      sep = ". "
    )),
    txt_norm = stringi::stri_trans_general(str_to_lower(texts), "Latin-ASCII"),
    # 3 variables binarias para los clústeres de K-Means
    c_centro      = as.numeric(cluster_nombre == "Céntrico e Institucional"),
    c_comercial   = as.numeric(cluster_nombre == "Comercial y Automotor"),
    c_residencial = as.numeric(cluster_nombre == "Residencial y Periférico"),
    # 4 variables binarias temáticas basadas en la clasificación DAI y palabras clave
    tema_hurto_personas = as.numeric(
      delito_sdscj == "Hurto a personas" |
        str_detect(
          txt_norm,
```

```
          paste0(
            "\\b(transmilenio|sitp|peaton|transeunte|celular|",
            "raponazo|cosquilleo|fleteo|escopolamina)\\b"
          )
        )
    ),
    tema_hurto_patrimonial = as.numeric(
      delito_sdscj %in% c(
        "Hurto a residencias", "Hurto a comercio", "Hurto de automotores",
        "Hurto de motocicletas", "Hurto a entidades financieras",
        "Hurto (modalidad no identificada)"
      )
    ),
    tema_violencia_vida = as.numeric(
      delito_sdscj %in% c(
        "Homicidio", "Lesiones personales", "Extorsión",
        "Delitos sexuales", "Violencia intrafamiliar"
      )
    ),
    tema_institucional = as.numeric(
      modalidad_dai %in% c("nodai_operatividad", "nodai_politica_seguridad") |
        str_detect(
          txt_norm,
          paste0(
            "\\b(captur|desarticul|operativ|patrullaj|incaut|",
            "megatoma|secretaria de seguridad|policia)\\b"
          )
        )
    )
  )

# Añadimos las 19 variables binarias por localidad con prefijo loc_
localidades_unicas <- sort(unique(df_base_corpus$localidad))
nombres_feat_loc   <- character(length(localidades_unicas))

for (i in seq_along(localidades_unicas)) {
  loc_actual <- localidades_unicas[i]
  col_feat   <- paste0("loc_", normalizar_nombre_feature(loc_actual))
  nombres_feat_loc[i] <- col_feat
  df_base_corpus[[col_feat]] <- as.numeric(df_base_corpus$localidad == loc_actual)
}

cols_features <- c(
  "c_centro", "c_comercial", "c_residencial",
  "tema_hurto_personas", "tema_hurto_patrimonial",
  "tema_violencia_vida", "tema_institucional",
  nombres_feat_loc
)

# Controles de contrato para sentometrics: cero guiones '-' y cero valores faltantes
stopifnot(!any(str_detect(cols_features, "-")))
stopifnot(all(!is.na(df_base_corpus$date)))
```

```r
stopifnot(all(!is.na(df_base_corpus$texts)))

# do.clean = FALSE preserva nuestra limpieza textual previa sin alterar tildes o tokens clave
df_sento_input <- df_base_corpus |>
  select(id, date, texts, all_of(cols_features)) |>
  as.data.frame()

corpus_sento <- sentometrics::sento_corpus(
  corpusdf = df_sento_input,
  do.clean = FALSE
)

stopifnot(inherits(corpus_sento, "sento_corpus"))
cat("Objeto sento_corpus creado en memoria con", nrow(df_sento_input), "documentos y",
↪  length(cols_features), "features.\n")
```

```
Objeto sento_corpus creado en memoria con 3916 documentos y 26 features.
```

Con el objeto `corpus_sento` ya en memoria, aplicamos `sentometrics::corpus_summarize()` para auditar la frecuencia mensual de artículos y el peso relativo de cada una de las 26 características a lo largo del tiempo.

```r
## 4.3.1 Diagnóstico mensual del volumen de documentos (corpus_summarize) ----
summary_mes  <- suppressWarnings(sentometrics::corpus_summarize(corpus_sento, by = "month"))
summary_anio <- suppressWarnings(sentometrics::corpus_summarize(corpus_sento, by = "year"))

p_fig8 <- summary_mes$plots$doc_plot +
  labs(
    title    = "Evolución Mensual del Volumen de Documentos en el Corpus",
    subtitle = "Diagnóstico temporal del objeto sento_corpus (enero 2022-septiembre 2026)",
    x        = "Fecha (mes)",
    y        = "Número de documentos por mes",
    caption  = "Fuente: diagnóstico S3 con sentometrics::corpus_summarize()."
  ) +
  tema_limpio +
  theme(legend.position = "none")

sc_x8 <- p_fig8$scales$get_scales("x")
sc_y8 <- p_fig8$scales$get_scales("y")
if (!is.null(sc_x8)) sc_x8$name <- "Fecha (mes)"
if (!is.null(sc_y8)) sc_y8$name <- "Número de documentos por mes"

print(p_fig8)
```

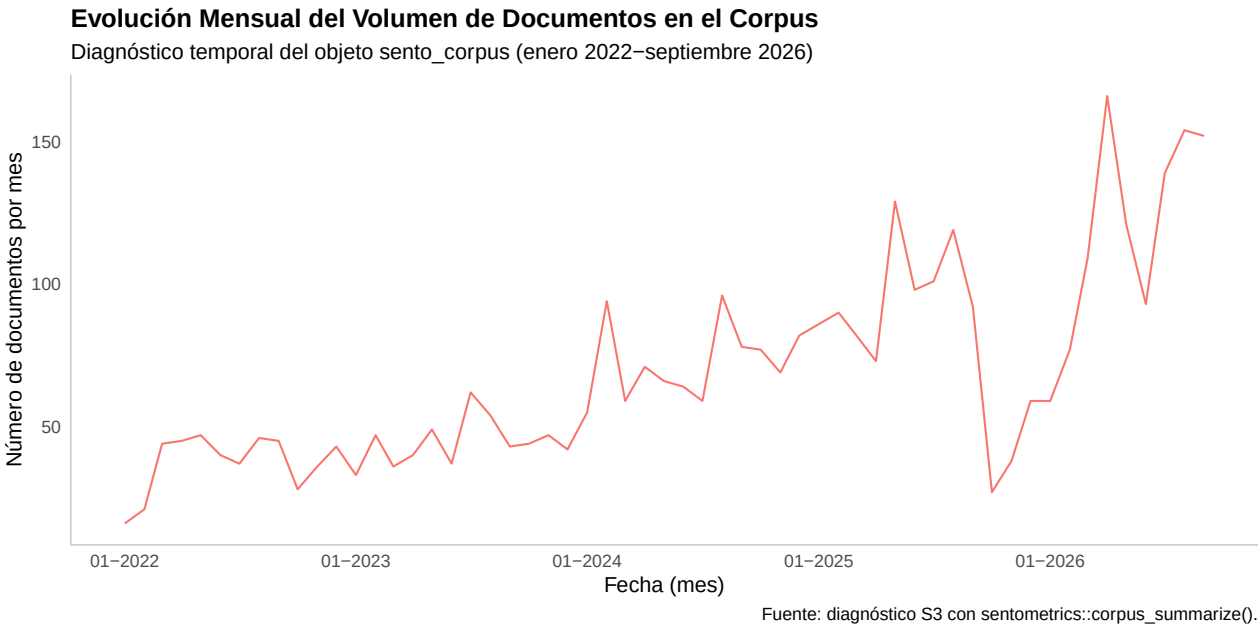


Figura 9: Evolución mensual del volumen de documentos en el objeto sento_corpus

```
## 4.3.2 Diagnóstico mensual de frecuencia por característica ----
p_fig9 <- summary_mes$plots$feature_plot +
  labs(
    title    = "Evolución Mensual de Frecuencia por Feature en el Corpus",
    subtitle = "Menciones mensuales por localidad, clúster y categoría delictiva (2022-sep. 2026)",
    x        = "Fecha (mes)",
    y        = "Conteo mensual por feature",
    color    = "Feature",
    caption  = "Fuente: diagnóstico S3 con sentometrics::corpus_summarize()."
  ) +
  tema_limpio +
  guides(color = guide_legend(ncol = 2)) +
  theme(legend.text = element_text(size = 8))

sc_x9 <- p_fig9$scales$get_scales("x")
sc_y9 <- p_fig9$scales$get_scales("y")
sc_c9 <- p_fig9$scales$get_scales("colour")
if (!is.null(sc_x9)) sc_x9$name <- "Fecha (mes)"
if (!is.null(sc_y9)) sc_y9$name <- "Conteo mensual por feature"
if (!is.null(sc_c9)) sc_c9$name <- "Feature"

print(p_fig9)
```

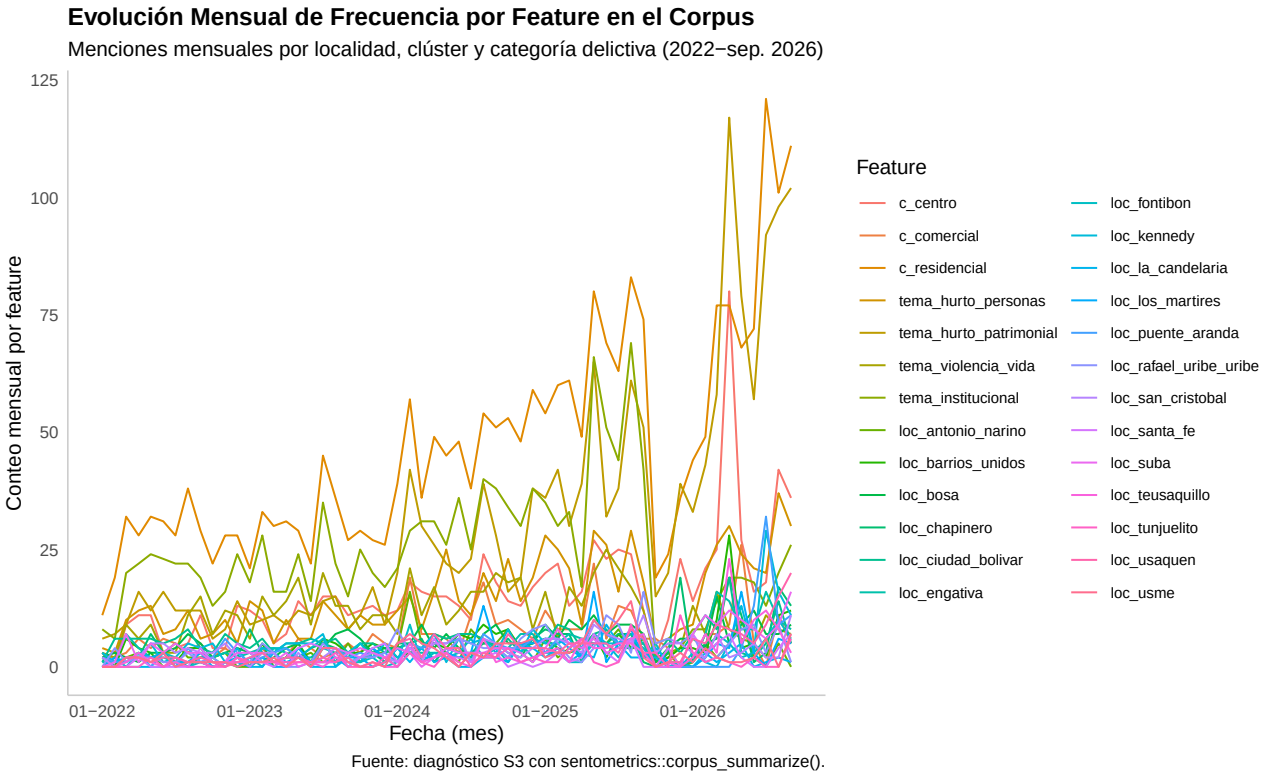


Figura 10: Evolución mensual de menciones por característica (localidad, clúster y tema DAI)

4.4. Diccionarios en español, modificadores de valencia, polaridad y noticias pico

Replicamos la Fase 2 de `scripts/03_analisis_sentometrics.R`. Combinamos dos diccionarios complementarios: `nrc_es` (extraído del diccionario emocional NRC en español mediante `{syuzhet}`) y `crimen_es` (construido específicamente para capturar jerga de criminalidad y respuesta operativa en Bogotá, como *"fleteo"*, *"cosquilleo"*, *"escopolamina"*, *"sicariato"*, *"desarticulación"* o *"captura"*). A ambos les acoplamos la tabla de modificadores de valencia en español `tabla_valence_es` ($t \in \{1, 2, 3, 4\}$).

Después calculamos los puntajes documentales con `how = "proportionalPol"`, los contrastamos frente a `how = "TFIDF"` como prueba de robustez, enriquecemos la tabla de noticias para generar el gráfico anual de tono y la tabla descriptiva del corpus (`06_descriptivos_corpus.R`), y extraemos las noticias extremas con `peakdocs()`.

```
## 4.4 Construcción de léxicos, valenceIn y cómputo de polaridad por documento ----

# Diccionario general NRC en español (filtrado a palabras simples con polaridad neta distinta de
↪  cero)
nrc_es_crudo <- syuzhet::get_sentiment_dictionary("nrc", language = "spanish")
lex_nrc_es <- nrc_es_crudo |>
  filter(sentiment %in% c("positive", "negative")) |>
  mutate(
    x = str_to_lower(str_trim(word)),
    y = ifelse(sentiment == "positive", 1.0, -1.0)
  ) |>
```

```r
  filter(!str_detect(x, "\\s+"), nchar(x) > 1) |>
  group_by(x) |>
  summarise(y = round(mean(y), 4), .groups = "drop") |>
  filter(y != 0) |>
  as.data.frame()

# Diccionario especializado en seguridad ciudadana y criminalidad urbana de Bogotá
lex_crimen_bogota <- tribble(
  ~x,                ~y,
  # Términos de alta negatividad (delitos y violencia)
  "homicidio",      -1.0,  "homicidios",     -1.0,  "asesinato",      -1.0,
  "asesinado",      -1.0,  "asesinada",      -1.0,  "sicariato",      -1.0,
  "sicario",        -1.0,  "sicarios",       -1.0,  "feminicidio",    -1.0,
  "masacre",        -1.0,  "cadaver",        -0.9,  "cadaveres",      -0.9,
  "embolsado",      -1.0,  "embolsados",     -1.0,  "balacera",       -0.9,
  "tiroteo",        -0.9,  "baleado",        -0.9,  "apunalado",      -0.9,
  "punalada",       -0.8,  "extorsion",      -0.9,  "extorsiones",    -0.9,
  "secuestro",      -1.0,  "violacion",      -1.0,  "abuso",          -0.8,
  "atraco",         -0.9,  "atracos",        -0.9,  "atracador",      -0.9,
  "atracadores",    -0.9,  "robo",           -0.8,  "robos",          -0.8,
  "robaron",        -0.8,  "hurtaron",       -0.8,  "hurto",          -0.7,
  "hurtos",         -0.7,  "asalto",         -0.8,  "asaltantes",     -0.8,
  "fleteo",         -0.9,  "fleteros",       -0.9,  "escopolamina",   -0.9,
  "burundanga",     -0.9,  "cosquilleo",     -0.7,  "raponazo",       -0.7,
  "rompevidrios",   -0.7,  "apartamenteros", -0.8,  "halado",         -0.7,
  "desguazadero",   -0.8,  "microtrafico",   -0.8,  "narcomenudeo",   -0.8,
  "delincuencia",   -0.8,  "delincuentes",   -0.8,  "criminales",     -0.8,
  "banda",          -0.6,  "bandas",         -0.6,  "inseguridad",    -0.8,
  "miedo",          -0.7,  "temor",          -0.7,  "panico",         -0.8,
  "zozobra",        -0.8,  "impunidad",      -0.8,  "victima",        -0.6,
  "victimas",       -0.6,  "herido",         -0.7,  "heridos",        -0.7,
  "lesionado",      -0.6,  "peligro",        -0.7,  "amenaza",        -0.7,
  "amenazas",       -0.7,  "denuncia",       -0.4,  "denuncias",      -0.4,
  # Términos positivos de respuesta institucional, judicialización y prevención
  "captura",         0.7,  "capturas",        0.7,  "capturado",       0.7,
  "capturados",      0.7,  "desarticulacion", 0.9,  "desarticulada",   0.9,
  "desarticulan",    0.9,  "recuperacion",    0.8,  "recuperado",      0.8,
  "recuperados",     0.8,  "incautacion",     0.7,  "incautaron",      0.7,
  "rescate",         0.8,  "rescatado",       0.8,  "judicializacion", 0.8,
  "judicializados",  0.8,  "condena",         0.6,  "condenado",       0.6,
  "esclarecimiento", 0.8,  "reduccion",       0.8,  "disminucion",     0.8,
  "disminuyo",       0.8,  "bajo",            0.4,  "prevencion",      0.7,
  "proteccion",      0.7,  "seguridad",       0.5,  "seguro",          0.7,
  "segura",          0.7,  "patrullaje",      0.6,  "operativo",       0.5,
  "operativos",      0.5,  "megatoma",        0.6,  "convivencia",     0.8,
  "tranquilidad",    0.8,  "justicia",        0.7,  "apoyo",           0.5
) |>
  group_by(x) |>
  summarise(y = mean(y), .groups = "drop") |>
  as.data.frame()

# Tabla de modificadores de valencia en español siguiendo la convención de sentometrics:
```

```
# t = 1 negadores, t = 2 amplificadores, t = 3 atenuadores, t = 4 adversativos
tabla_valence_es <- tribble(
  ~x,               ~y,   ~t,
  "no",            -1.0,  1L,
  "nunca",         -1.0,  1L,
  "jamas",         -1.0,  1L,
  "sin",           -1.0,  1L,
  "ni",            -1.0,  1L,
  "tampoco",       -1.0,  1L,
  "ningun",        -1.0,  1L,
  "ninguna",       -1.0,  1L,
  "muy",            1.8,  2L,
  "altamente",      1.8,  2L,
  "sumamente",      1.8,  2L,
  "extremadamente", 1.8,  2L,
  "demasiado",      1.8,  2L,
  "gravemente",     1.8,  2L,
  "brutalmente",    1.8,  2L,
  "masivamente",    1.8,  2L,
  "totalmente",     1.8,  2L,
  "completamente",  1.8,  2L,
  "bastante",       1.5,  2L,
  "fuerte",         1.5,  2L,
  "poco",           0.2,  3L,
  "apenas",         0.2,  3L,
  "levemente",      0.2,  3L,
  "ligeramente",    0.2,  3L,
  "parcialmente",   0.2,  3L,
  "casi",           0.4,  3L,
  "pero",          -1.0,  4L,
  "aunque",        -1.0,  4L,
  "obstante",      -1.0,  4L,
  "embargo",       -1.0,  4L
) |>
  as.data.frame()

lexicons_es <- sentometrics::sento_lexicons(
  lexiconsIn = list(
    nrc_es    = lex_nrc_es,
    crimen_es = lex_crimen_bogota
  ),
  valenceIn = tabla_valence_es
)

# Cómputo de sentimiento documental: principal (proportionalPol) y sensibilidad (TFIDF)
sentiment_scores <- sentometrics::compute_sentiment(
  x           = corpus_sento,
  lexicons    = lexicons_es,
  how         = "proportionalPol",
  do.sentence = FALSE
)
```

```r
sentiment_tfidf <- sentometrics::compute_sentiment(
  x           = corpus_sento,
  lexicons    = lexicons_es,
  how         = "TFIDF",
  do.sentence = FALSE
)

# Como los 3 clústeres son exhaustivos y excluyentes, la suma de sus 3 columnas
# recupera exactamente el puntaje neto de cada documento en cada diccionario
df_sent_doc <- as_tibble(sentiment_scores) |>
  transmute(
    id = id,
    word_count = word_count,
    score_nrc_es = round(
      `nrc_es--c_centro` + `nrc_es--c_comercial` + `nrc_es--c_residencial`,
      4
    ),
    score_crimen_es = round(
      `crimen_es--c_centro` + `crimen_es--c_comercial` + `crimen_es--c_residencial`,
      4
    ),
    sentimiento_score = round(0.5 * score_nrc_es + 0.5 * score_crimen_es, 4)
  ) |>
  left_join(
    as_tibble(sentiment_tfidf) |>
      transmute(
        id = id,
        score_tfidf_compuesto = round(
          0.5 * (`nrc_es--c_centro` + `nrc_es--c_comercial` + `nrc_es--c_residencial`) +
            0.5 * (`crimen_es--c_centro` + `crimen_es--c_comercial` + `crimen_es--c_residencial`),
          4
        )
      ),
    by = "id"
  )

comp_metodo <- list(
  correlacion_propPol_tfidf = cor(
    df_sent_doc$sentimiento_score,
    df_sent_doc$score_tfidf_compuesto,
    use = "complete.obs"
  ),
  media_nrc_es    = mean(df_sent_doc$score_nrc_es, na.rm = TRUE),
  media_crimen_es = mean(df_sent_doc$score_crimen_es, na.rm = TRUE),
  media_combinada = mean(df_sent_doc$sentimiento_score, na.rm = TRUE)
)

# Enriquecemos las noticias en memoria con el puntaje neto, su categoría y su clúster
df_noticias_enriquecida <- df_noticias_base |>
  mutate(id = paste0("doc_", row_number())) |>
  left_join(df_sent_doc, by = "id") |>
  left_join(
```

```
    df_clusters |> select(localidad, cluster_id, cluster_nombre, perfil_seguridad),
    by = "localidad"
  ) |>
  mutate(
    sentimiento_categoria = case_when(
      sentimiento_score < -0.02 ~ "Negativo",
      sentimiento_score >  0.02 ~ "Positivo",
      TRUE                      ~ "Neutro"
    )
  )

cat(
  "Correlación entre proportionalPol y TFIDF:", round(comp_metodo$correlacion_propPol_tfidf, 4),
  ↪  "\n",
  "Media léxico general (nrc_es):", round(comp_metodo$media_nrc_es, 4), "\n",
  "Media léxico criminalidad (crimen_es):", round(comp_metodo$media_crimen_es, 4), "\n",
  "Media compuesta:", round(comp_metodo$media_combinada, 4), "\n"
)
```

```
Correlación entre proportionalPol y TFIDF: 0.7383
 Media léxico general (nrc_es): -0.0859
 Media léxico criminalidad (crimen_es): -0.3063
 Media compuesta: -0.1961
```

Al comparar ambos diccionarios se aprecia por qué conviene mantenerlos juntos: el diccionario general `nrc_es` tiene una media cercana a la neutralidad (-0.0859), mientras que el vocabulario especializado `crimen_es` capta con mucha mayor nitidez el tono negativo de los hechos delictivos (-0.3063). A su vez, `proportionalPol` mantiene una correlación positiva de 0.7383 frente al esquema alternativo `TFIDF`.

Con los puntajes documentales listos, ejecutamos ahora la segunda mitad de `scripts/06_descriptivos_corpus.R` (tabla anual resumen y distribución de tono por año) y la extracción de documentos pico con `sentometrics::peakdocs()`.

```
## 4.4.1 Tabla descriptiva anual del corpus ----
tabla_corpus_anual <- df_noticias_enriquecida |>
  mutate(año = as.integer(año), mes = as.integer(mes)) |>
  filter(!(año == 2026 & mes > 9)) |>
  group_by(año) |>
  summarise(
    noticias         = n(),
    noticias_dai     = sum(es_dai_estricto, na.rm = TRUE),
    localidades      = n_distinct(localidad),
    media_palabras   = round(mean(palabras_cuerpo, na.rm = TRUE), 1),
    mediana_palabras = round(median(palabras_cuerpo, na.rm = TRUE), 1),
    sentimiento_prom = round(mean(sentimiento_score, na.rm = TRUE), 4),
    .groups = "drop"
  )

stopifnot(nrow(tabla_corpus_anual) == 5)
```

```
knitr::kable(
  tabla_corpus_anual,
  col.names = c(
    "Año", "Noticias totales", "Noticias 11 DAI (estricto)",
    "Localidades cubiertas", "Media palabras", "Mediana palabras",
    "Sentimiento neto promedio"
  )
)
```

Tabla 4: Resumen anual del corpus de noticias de seguridad en Bogotá (2022-septiembre de 2026)

Año	Noticias totales	Noticias 11 DAI (estricto)	Localidades cubiertas	Media palabras	Mediana palabras	Sentimiento neto promedio
2022	448	264	19	212.1	24.0	-0.0512
2023	534	347	19	403.8	354.5	-0.1210
2024	870	589	19	376.7	354.5	-0.1040
2025	994	683	19	350.5	312.0	-0.1437
2026	1070	699	19	18.3	18.0	-0.4178

```
## 4.4.2 Proporción anual del tono de las noticias ----
tono_por_anio <- df_noticias_enriquecida |>
  mutate(año = as.integer(año), mes = as.integer(mes)) |>
  filter(!(año == 2026 & mes > 9)) |>
  group_by(año, sentimiento_categoria) |>
  summarise(conteo = n(), .groups = "drop") |>
  group_by(año) |>
  mutate(pct = conteo / sum(conteo) * 100) |>
  ungroup()

p_fig7 <- ggplot(tono_por_anio, aes(x = factor(año), y = pct, fill = sentimiento_categoria)) +
  geom_col(position = position_dodge(width = 0.78), width = 0.7) +
  geom_text(
    aes(label = paste0(round(pct, 1), "%")),
    position = position_dodge(width = 0.78),
    vjust    = -0.4,
    size     = 3.0
  ) +
  scale_fill_manual(
    values = c("Negativo" = "#c0392b", "Neutro" = "#7f8c8d", "Positivo" = "#27ae60")
  ) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.12))) +
  labs(
    title    = "Distribución Anual del Tono de las Noticias sobre Seguridad",
    subtitle = "Porcentaje de artículos según categoría de polaridad (2022-sep. 2026)",
    x        = "Año",
    y        = "% de noticias",
    fill     = "Polaridad",
    caption  = "Fuente: cálculos con sentometrics (nrc_es + crimen_es)."
  ) +
```

```
  tema_limpio

print(p_fig7)
```

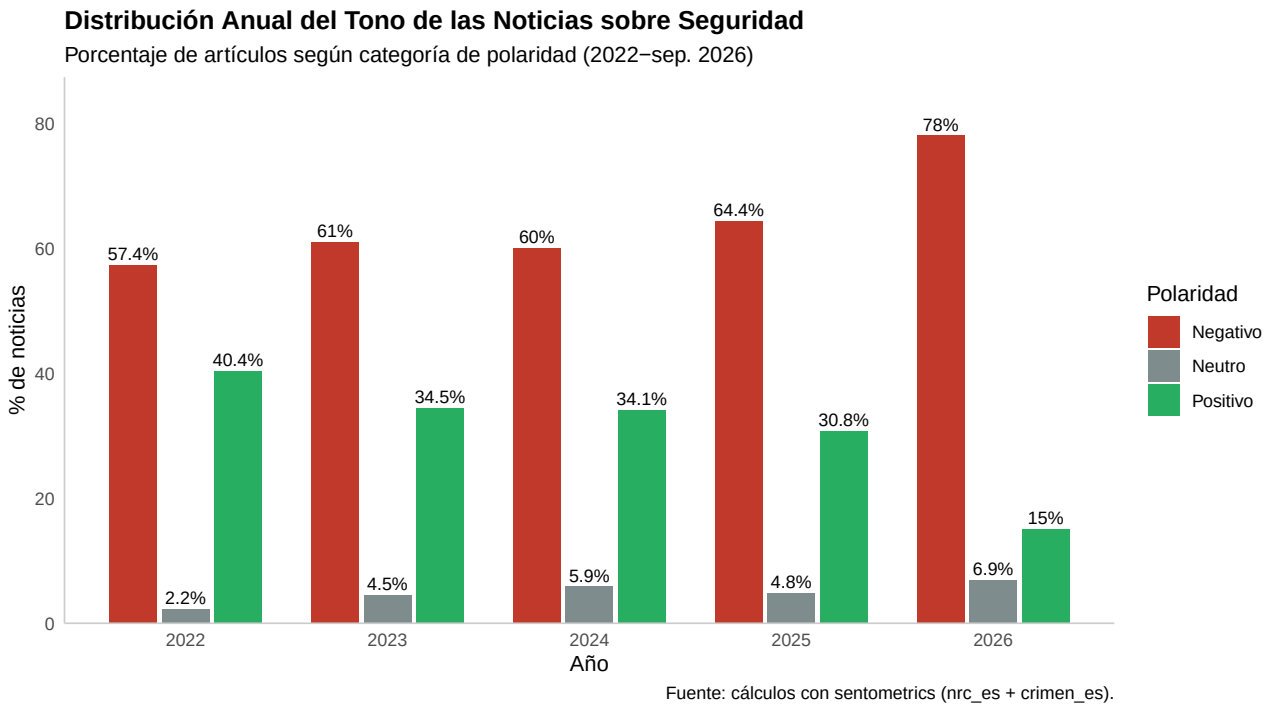


Figura 11: Distribución porcentual anual de noticias según categoría de polaridad (2022-septiembre de 2026)

```
## 4.4.3 Extracción de documentos extremos con peakdocs() ----
stopifnot(min(table(df_noticias_enriquecida$localidad)) >= 5)

ids_peak_both <- sentometrics::peakdocs(sentiment_scores, n = 25, type = "both")
ids_peak_neg  <- sentometrics::peakdocs(sentiment_scores, n = 25, type = "neg")
ids_peak_pos  <- sentometrics::peakdocs(sentiment_scores, n = 25, type = "pos")

# Identificamos también los 5 artículos más negativos y 5 más positivos de cada localidad
peak_por_localidad <- df_noticias_enriquecida |>
  group_by(localidad) |>
  arrange(sentimiento_score) |>
  slice(unique(c(1:5, (n() - 4):n()))) |>
  ungroup()

tabla_peak_docs <- df_noticias_enriquecida |>
  mutate(
    es_pico_global = id %in% unique(c(ids_peak_both, ids_peak_neg, ids_peak_pos)),
    tipo_pico = case_when(
      id %in% ids_peak_neg ~ "Pico Negativo Global",
      id %in% ids_peak_pos ~ "Pico Positivo Global",
      id %in% peak_por_localidad$id & sentimiento_score < 0 ~ "Extremo Negativo Local",
      id %in% peak_por_localidad$id & sentimiento_score > 0 ~ "Extremo Positivo Local",
```

```
      TRUE ~ "Regular"
    )
  ) |>
  select(
    id, fecha, año, mes, localidad, cluster_nombre, fuente,
    delito_sdscj, modalidad_dai, es_dai_estricto, confianza_dai,
    titulo, resumen, enlace, word_count,
    score_nrc_es, score_crimen_es, sentimiento_score,
    sentimiento_categoria, es_pico_global, tipo_pico
  ) |>
  arrange(sentimiento_score)

objeto_peak_docs <- list(
  peak_ids_both  = ids_peak_both,
  peak_ids_neg   = ids_peak_neg,
  peak_ids_pos   = ids_peak_pos,
  tabla_completa = as.data.table(tabla_peak_docs),
  top_criticas   = as.data.table(tabla_peak_docs |> filter(tipo_pico != "Regular"))
)

muestra_picos <- as_tibble(objeto_peak_docs$top_criticas) |>
  filter(es_pico_global) |>
  slice_head(n = 8) |>
  transmute(
    Fecha     = as.character(fecha),
    Localidad = localidad,
    Delito    = delito_sdscj,
    Titular   = str_trunc(titulo, 65),
    Score     = round(sentimiento_score, 3),
    Tipo      = tipo_pico
  )

knitr::kable(
  muestra_picos,
  col.names = c("Fecha", "Localidad", "Modalidad SDSCJ", "Titular", "Score neto", "Clasificación")
)
```

Tabla 5: Muestra de noticias con polaridad más extrema identificadas mediante peakdocs()

Fecha	Localidad	Modalidad SDSCJ	Titular	Score neto	Clasificación
2023-09-01	Usaquén	Homicidio	Hombre murió tras ataque a disparos en un billar de Usaquén	-1.087	Pico Negativo Global
2022-12-01	Bosa	Homicidio	A la cárcel 22 integrantes de la banda multicrimen 'Los Camilo...	-0.933	Pico Negativo Global
2026-05-06	Los Mártires	Hurto a comercio	Video captó violento robo en un D1 de Bogotá: criminales desat...	-0.917	Pico Negativo Global

Tabla 5: Muestra de noticias con polaridad más extrema identificadas mediante peakdocs()

Fecha	Localidad	Modalidad SDSCJ	Titular	Score neto	Clasificación
2023-11-07	Antonio Nariño	Hurto a personas	Violento asalto a mano armada a un restaurante en Bogotá: un d...	-0.900	Pico Negativo Global
2026-04-01	Antonio Nariño	Hurto a comercio	Comensales frustraron violento asalto en un restaurante de Bog...	-0.900	Pico Negativo Global
2026-04-17	Barrios Unidos	Hurto (modalidad no identificada)	Capturan a dos extranjeros tras violento robo en Bogotá: perse...	-0.900	Pico Negativo Global
2026-08-03	Barrios Unidos	Hurto (modalidad no identificada)	En video: capturan a ladrón que tenía 19 anotaciones judiciale...	-0.900	Pico Negativo Global
2025-12-01	Chapinero	Hurto a comercio	Violento asalto a joyería en Chapinero: se llevaron $30 millon...	-0.900	Pico Negativo Global

4.5. Series temporales multidimensionales, índice global y fechas críticas

Replicamos la Fase 3 de `scripts/03_analisis_sentometrics.R`. Aquí traducimos las tres ecuaciones intuitivas de la Sección 4.2 directamente a código: `ctr_agg()` define cómo puntuar palabras, pesar documentos y aplicar los siete perfiles de memoria; `sento_measures()` construye las 364 series; `measures_fill()` rellena eventuales meses vacíos; `aggregate(..., do.global = TRUE)` resume el pulso distrital global; y `peakdates()` detecta los meses más críticos.

```
## 4.5 Agregación tridimensional (sento_measures), formato long y peakdates() ----
control_agg <- sentometrics::ctr_agg(
  howWithin      = "proportionalPol",
  howDocs        = "proportional",
  howTime        = c("linear", "exponential", "beta"),
  by             = "month",
  lag            = 6,
  alphasExp      = c(0.2, 0.5),
  aBeta          = c(1, 2),
  bBeta          = c(2, 3),
  do.ignoreZeros = TRUE,
  fill           = "zero"
)

medidas_sento <- sentometrics::sento_measures(
  sento_corpus = corpus_sento,
  lexicons     = lexicons_es,
  ctr          = control_agg
)
```

```r
# Aseguramos que ningún mes quede con NA cuando una feature no tiene menciones en ese mes
medidas_sento <- sentometrics::measures_fill(medidas_sento, fill = "zero")
stopifnot(inherits(medidas_sento, "sento_measures"))

# Convertimos la matriz ancha (57 meses x 364 series) a formato largo legible
dt_measures_wide <- data.table::as.data.table(medidas_sento)

mapa_etiquetas_features <- c(
  c_centro               = "Clúster: Céntrico e Institucional",
  c_comercial            = "Clúster: Comercial y Automotor",
  c_residencial          = "Clúster: Residencial y Periférico",
  tema_hurto_personas    = "Tema: Hurto a Personas y Transporte",
  tema_hurto_patrimonial = "Tema: Hurto Patrimonial y Vehículos",
  tema_violencia_vida    = "Tema: Violencia, Homicidio y Extorsión",
  tema_institucional     = "Tema: Operatividad y Política de Seguridad"
)
for (i in seq_along(localidades_unicas)) {
  mapa_etiquetas_features[nombres_feat_loc[i]] <- localidades_unicas[i]
}

df_measures_long <- as_tibble(dt_measures_wide) |>
  pivot_longer(
    cols      = -date,
    names_to  = "serie_id",
    values_to = "valor"
  ) |>
  separate(
    col    = serie_id,
    into   = c("lexicon", "feature", "time"),
    sep    = "--",
    remove = FALSE
  ) |>
  mutate(
    grupo_feature = case_when(
      str_starts(feature, "c_")    ~ "Clúster Territorial",
      str_starts(feature, "tema_") ~ "Tópico / Modalidad DAI",
      str_starts(feature, "loc_")  ~ "Localidad",
      TRUE                         ~ "Otro"
    ),
    feature_label = coalesce(unname(mapa_etiquetas_features[feature]), feature),
    lexicon_label = case_when(
      lexicon == "nrc_es"    ~ "Léxico General (NRC Español)",
      lexicon == "crimen_es" ~ "Léxico Seguridad y Crimen Bogotá",
      TRUE                   ~ lexicon
    )
  )

stopifnot(all(df_measures_long$grupo_feature != "Otro"))

# Índice global distrital y detección de los 8 meses de alarma más extrema
medidas_global_dt <- stats::aggregate(medidas_sento, do.global = TRUE)
fechas_pico_ambas <- sentometrics::peakdates(medidas_sento, n = 8, type = "both")
```

```r
fechas_pico_neg   <- sentometrics::peakdates(medidas_sento, n = 8, type = "neg")
fechas_pico_pos   <- sentometrics::peakdates(medidas_sento, n = 8, type = "pos")

df_global_index <- as_tibble(medidas_global_dt) |>
  mutate(
    date      = as.Date(date),
    es_pico   = date %in% as.Date(c(fechas_pico_ambas, fechas_pico_neg)),
    tipo_pico = case_when(
      date %in% as.Date(fechas_pico_neg) ~ "Pico de Alarma / Negatividad",
      date %in% as.Date(fechas_pico_pos) ~ "Pico Positivo / Operatividad",
      TRUE                               ~ "Normal"
    )
  )

objeto_global_index <- list(
  serie_global   = as.data.table(df_global_index),
  peakdates_both = as.Date(fechas_pico_ambas),
  peakdates_neg  = as.Date(fechas_pico_neg),
  peakdates_pos  = as.Date(fechas_pico_pos)
)

medidas_sento
```

```
A sento_measures object (364 textual sentiment time series, 52 observations).
```

La Figura 12 visualiza las series mensuales para los tres clústeres territoriales bajo el diccionario especializado `crimen_es` y el esquema de memoria exponencial ($\alpha = 0{,}5$), marcando con líneas verticales los meses de mayor negatividad detectados por `peakdates()`.

```r
## 4.5.1 Series mensuales por clúster territorial y fechas pico ----
df_series_cluster <- df_measures_long |>
  filter(
    grupo_feature == "Clúster Territorial",
    lexicon       == "crimen_es",
    time          == "exponential0.5"
  ) |>
  mutate(
    cluster_limpio = str_remove(feature_label, "^Clúster: ")
  )

ggplot(df_series_cluster, aes(x = date, y = valor, color = cluster_limpio)) +
  geom_hline(yintercept = 0, linetype = "dotted", color = "gray50") +
  geom_vline(
    xintercept = as.numeric(objeto_global_index$peakdates_neg),
    linetype   = "dashed",
    color      = "#c0392b",
    alpha      = 0.3
  ) +
  geom_line(linewidth = 0.95) +
  scale_color_manual(
```

```
    values = c(
      "Céntrico e Institucional" = "#c0392b",
      "Comercial y Automotor"    = "#e67e22",
      "Residencial y Periférico" = "#27ae60"
    )
  ) +
  scale_x_date(date_breaks = "6 months", date_labels = "%b %Y") +
  labs(
    title    = "Sentimiento Mediático sobre Seguridad por Clúster Territorial en Bogotá",
    subtitle = "Léxico crimen_es con decaimiento exponencial (alpha = 0.5, lag = 6m) y fechas
    ↪  críticas (peakdates)",
    x        = "Fecha de agregación mensual",
    y        = "Índice de sentimiento ponderado",
    color    = "Clúster territorial"
  ) +
  theme_minimal(base_size = 11) +
  theme(
    legend.position = "bottom",
    plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
  )
```

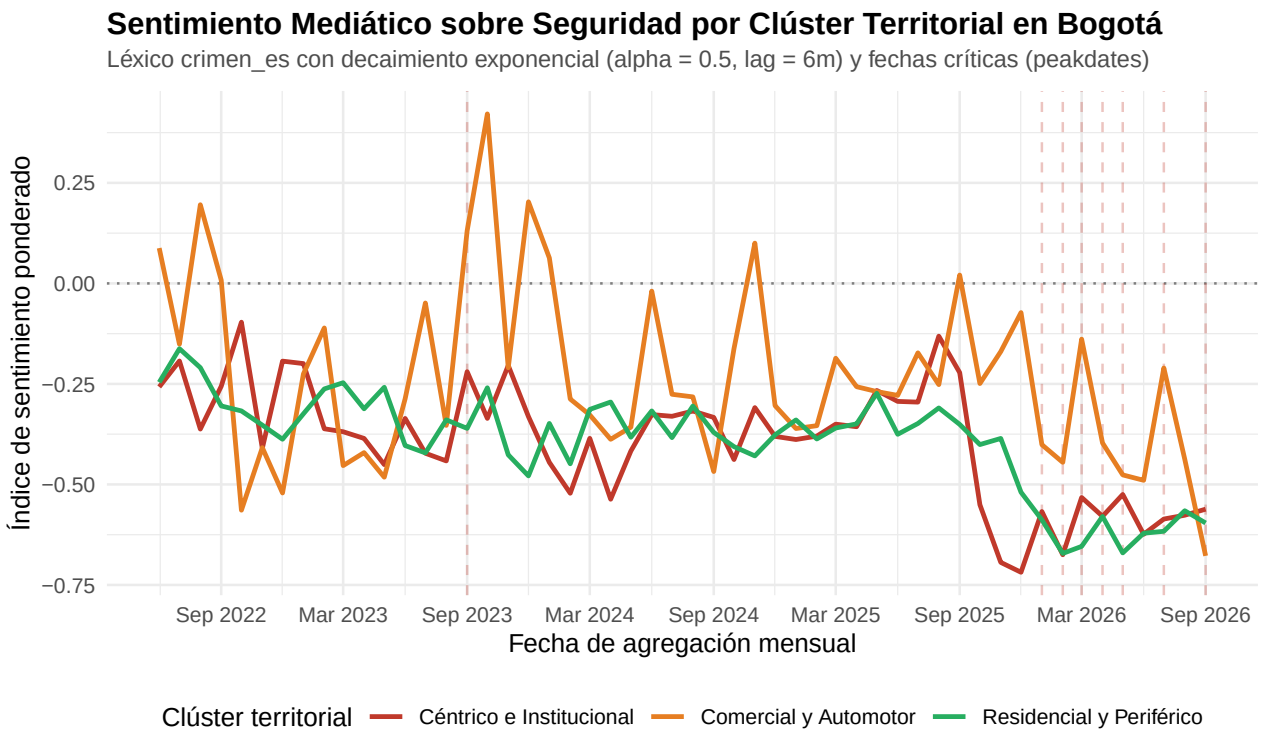


Figura 12: Evolución mensual del sentimiento mediático sobre criminalidad por clúster territorial (2022-2026)

5. Modelado econométrico supervisado (Elastic Net) y atribuciones

En esta sección replicamos la Fase 4 de `scripts/03_analisis_sentometrics.R`. El reto econométrico consiste en conectar las 364 series mensuales de sentimiento mediático con la evolución real del hurto en la ciudad.

5.1. Especificación del modelo regularizado (`sento_model`)

Como las denuncias oficiales en `panel_delitos` tienen frecuencia anual mientras que nuestras series de sentimiento son mensuales, mensualizamos la tasa distrital de hurto cada año repartiéndola según la participación mensual observada de noticias sobre delitos de alto impacto estrictos (`prop_mensual_dai`), con suavizamiento de Laplace (`+ 1`) para evitar divisiones por cero y preservando la suma anual oficial.

Con esa serie objetivo y_t lista, buscamos predecir el nivel de intensidad delictiva un mes adelante (y_{t+1}, horizonte $h = 1$) usando las $M = 364$ series de sentimiento $S_{t,m}$:

$$\min_{\beta_0,\beta} \left\{ \frac{1}{2N} \sum_{t=1}^{N} \left(y_{t+1} - \beta_0 - \sum_{m=1}^{M} \beta_m S_{t,m} \right)^2 + \lambda \left[\frac{1-\alpha}{2} \|\beta\|_2^2 + \alpha \|\beta\|_1 \right] \right\} \tag{8}$$

> **Intuición econométrica: por qué Elastic Net cuando hay 364 predictores y 51 meses**
>
> En una regresión lineal tradicional (MCO), tener más variables ($M = 364$) que observaciones ($N = 51$) hace imposible estimar un coeficiente único para cada serie; además, distintas curvas de memoria de una misma localidad están muy correlacionadas entre sí. **Elastic Net** resuelve esto añadiendo un presupuesto de penalización (λ) que combina dos fuerzas: 1. El componente **Ridge** ($1 - \alpha$) reparte el peso de forma estable entre series correlacionadas en lugar de disparar coeficientes opuestos. 2. El componente **LASSO** (α) empuja exactamente a cero ($\beta_m = 0$) los coeficientes de las series redundantes, conservando únicamente el subconjunto informativo seleccionado por el Criterio de Información Bayesiano (BIC).

```
# 5. Réplica de la Fase 4 de scripts/03_analisis_sentometrics.R ----

## 5.1 Construcción de la serie mensual empírica de intensidad delictiva (y_t) ----
# Calculamos primero la tasa anual distrital agregando las 19 localidades
tasas_anuales_distrito <- panel_delitos |>
  group_by(año) |>
  summarise(
    hurto_personas_total  = sum(hurto_personas, na.rm = TRUE),
    hurto_total_denuncias = sum(hurto_personas + hurto_residencias + hurto_motos, na.rm = TRUE),
    poblacion_distrito    = sum(poblacion, na.rm = TRUE),
    tasa_anual_personas   = (hurto_personas_total / poblacion_distrito) * 100000,
    tasa_anual_total      = (hurto_total_denuncias / poblacion_distrito) * 100000,
    .groups = "drop"
  )

# Obtenemos el perfil mensual intra-anual según noticias estrictas de los 11 DAI
pesos_mensuales_dai <- df_noticias_enriquecida |>
  mutate(
    date_mes = as.Date(format(as.Date(fecha), "%Y-%m-01")),
```

```
    año      = as.integer(format(date_mes, "%Y"))
  ) |>
  group_by(año, date_mes) |>
  summarise(
    n_noticias_mes = n(),
    n_dai_mes      = sum(es_dai_estricto, na.rm = TRUE),
    .groups = "drop"
  ) |>
  group_by(año) |>
  mutate(
    # Suavizamiento + 1 evita pesos nulos en meses con muy baja cobertura DAI
    prop_mensual_dai = (n_dai_mes + 1) / sum(n_dai_mes + 1)
  ) |>
  ungroup()

fechas_medidas <- as.Date(sentometrics::get_dates(medidas_sento))

serie_objetivo_mensual <- tibble(
  date     = fechas_medidas,
  date_mes = as.Date(format(fechas_medidas, "%Y-%m-01")),
  año      = as.integer(format(fechas_medidas, "%Y"))
) |>
  left_join(tasas_anuales_distrito, by = "año") |>
  left_join(pesos_mensuales_dai, by = c("año", "date_mes")) |>
  mutate(
    prop_mensual_dai     = coalesce(prop_mensual_dai, 1 / 12),
    y_tasa_hurto_mensual = round(tasa_anual_total * prop_mensual_dai, 2),
    y_tasa_pers_mensual  = round(tasa_anual_personas * prop_mensual_dai, 2)
  )

y_vector <- serie_objetivo_mensual$y_tasa_hurto_mensual
stopifnot(length(y_vector) == nrow(medidas_sento$measures))
stopifnot(all(!is.na(y_vector)))

## 5.2 Estimación de sento_model() con selección BIC y horizonte h = 1 ----
control_modelo <- sentometrics::ctr_model(
  model       = "gaussian",
  type        = "BIC",
  alphas      = c(0.2, 0.5, 0.8),
  h           = 1,
  do.iter     = FALSE,
  do.progress = FALSE
)

modelo_elasticnet <- sentometrics::sento_model(
  sento_measures = medidas_sento,
  y              = y_vector,
  ctr            = control_modelo
)

## 5.3 Cálculo de atribuciones marginales y valores ajustados ----
atribuciones_raw <- sentometrics::attributions(
```

```
  model          = modelo_elasticnet,
  sento_measures = medidas_sento,
  do.lags        = TRUE,
  do.normalize   = FALSE
)

atribuciones_norm <- sentometrics::attributions(
  model          = modelo_elasticnet,
  sento_measures = medidas_sento,
  do.lags        = TRUE,
  do.normalize   = TRUE
)

# Alineamos los predictores en t (idx_x) con el objetivo en t + h (idx_y)
n_total_m <- nrow(medidas_sento$measures)
idx_x     <- 1:(n_total_m - control_modelo$h)
idx_y     <- (1 + control_modelo$h):n_total_m

mat_x_alineada   <- as.matrix(medidas_sento$measures[idx_x, -1])
y_alineado       <- y_vector[idx_y]
fechas_alineadas <- fechas_medidas[idx_y]

pred_matriz <- as.numeric(predict(
  modelo_elasticnet,
  newx = mat_x_alineada
))

df_ajuste_modelo <- tibble(
  date      = fechas_alineadas,
  observado = y_alineado,
  predicho  = round(pred_matriz, 2),
  residual  = round(y_alineado - pred_matriz, 2)
)

# Extraemos las series cuyo coeficiente sobrevivió a la penalización L1
coefs_sparse <- coef(modelo_elasticnet$reg)
df_coeficientes <- tibble(
  variable    = rownames(coefs_sparse),
  coeficiente = as.numeric(coefs_sparse[, 1])
) |>
  filter(variable != "(Intercept)", abs(coeficiente) > 1e-8) |>
  arrange(desc(abs(coeficiente)))

convertir_attr_long <- function(attr_obj, dimension) {
  dt_dim <- attr_obj[[dimension]]
  if (is.null(dt_dim)) return(tibble())
  as_tibble(dt_dim) |>
    mutate(date = as.Date(date)) |>
    pivot_longer(
      cols      = -date,
      names_to  = "componente",
      values_to = "atribucion"
```

```
    ) |>
    mutate(
      dimension        = dimension,
      componente_label = coalesce(unname(mapa_etiquetas_features[componente]), componente)
    )
}

df_attr_long_raw <- bind_rows(
  convertir_attr_long(atribuciones_raw, "features"),
  convertir_attr_long(atribuciones_raw, "lexicons"),
  convertir_attr_long(atribuciones_raw, "time")
)

df_attr_long_norm <- bind_rows(
  convertir_attr_long(atribuciones_norm, "features"),
  convertir_attr_long(atribuciones_norm, "lexicons"),
  convertir_attr_long(atribuciones_norm, "time")
)

metricas_mod <- list(
  alpha_optimo    = modelo_elasticnet$alpha,
  lambda_optimo   = modelo_elasticnet$lambda,
  horizonte_h     = control_modelo$h,
  criterio        = control_modelo$type,
  # R^2 descriptivo dentro de muestra medido como el cuadrado de la correlación lineal
  r2_in_sample    = round(cor(df_ajuste_modelo$observado, df_ajuste_modelo$predicho)^2, 4),
  rmse            = round(sqrt(mean(df_ajuste_modelo$residual^2)), 3),
  n_observaciones = nrow(df_ajuste_modelo),
  n_predictores   = sum(modelo_elasticnet$nVar),
  n_activos       = nrow(df_coeficientes)
)

objeto_attributions <- list(
  modelo            = modelo_elasticnet,
  attributions_raw  = atribuciones_raw,
  attributions_norm = atribuciones_norm,
  attr_long_raw     = as.data.table(df_attr_long_raw),
  attr_long_norm    = as.data.table(df_attr_long_norm),
  ajuste_temporal   = df_ajuste_modelo,
  coeficientes      = df_coeficientes,
  metricas_modelo   = metricas_mod
)

cat(
  "Parámetro alpha óptimo:", metricas_mod$alpha_optimo, "\n",
  "Parámetro lambda óptimo:", round(metricas_mod$lambda_optimo, 4), "\n",
  "R^2 dentro de muestra (h = 1):", scales::percent(metricas_mod$r2_in_sample, accuracy = 0.01),
  ↪  "\n",
  "RMSE:", metricas_mod$rmse, "\n",
  "Series activas seleccionadas:", metricas_mod$n_activos, "de", metricas_mod$n_predictores, "\n"
)
```

```
Parámetro alpha óptimo: 0.2
 Parámetro lambda óptimo: 13.4649
 R^2 dentro de muestra (h = 1): 87.53%
 RMSE: 21.593
 Series activas seleccionadas: 46 de 364
```

El criterio BIC selecciona $\alpha = 0.2$ (predominio de estabilización Ridge con selección dispersa) y $\lambda = 13.46$, reteniendo **46 de las 364 series** y explicando el **87.53 %** de la varianza dentro de muestra ($RMSE = 21.593$). La Tabla 6 muestra las diez series con mayor magnitud estimada.

```
knitr::kable(
  df_coeficientes |> slice_head(n = 10),
  digits    = 3,
  col.names = c("Serie seleccionada (diccionario--feature--memoria)", "Coeficiente estimado")
)
```

Tabla 6: Diez series de sentimiento con mayor peso absoluto en la regresión Elastic Net

Serie seleccionada (diccionario–feature–memoria)	Coeficiente estimado
crimen_es–tema_hurto_personas–exponential0.5	55.485
nrc_es–loc_usme–linear	-40.304
crimen_es–loc_kennedy–beta23	33.621
nrc_es–loc_usme–exponential0.2	-31.158
crimen_es–loc_bosa–exponential0.5	26.428
crimen_es–loc_los_martires–exponential0.2	21.176
crimen_es–loc_kennedy–exponential0.5	20.438
crimen_es–loc_los_martires–linear	19.755
nrc_es–loc_los_martires–beta13	19.330
crimen_es–loc_barrios_unidos–beta22	-18.102

```
## 5.4 Visualización del ajuste predictivo ----
df_aj <- df_ajuste_modelo |>
  select(date, `Observada` = observado, `Predicha (Elastic Net)` = predicho) |>
  pivot_longer(cols = -date, names_to = "serie", values_to = "valor")

ggplot(df_aj, aes(x = date, y = valor, color = serie, linetype = serie)) +
  geom_line(linewidth = 0.95) +
  scale_color_manual(
    values = c("Observada" = "#1b365d", "Predicha (Elastic Net)" = "#c0392b")
  ) +
  scale_x_date(date_breaks = "6 months", date_labels = "%b%Y") +
  labs(
    title    = "Ajuste Predictivo del Modelo de Sentimiento Mediático (sento_model)",
    subtitle = paste0(
      "Regresión Elastic Net (alpha = ", metricas_mod$alpha_optimo,
      ", lambda = ", round(metricas_mod$lambda_optimo, 2),
      ", R^2 = ", scales::percent(metricas_mod$r2_in_sample, accuracy = 0.1), ")"
```

```
    ),
    x        = "Mes de pronóstico (h = 1)",
    y        = "Tasa mensualizada por 100.000 hab.",
    color    = NULL,
    linetype = NULL
  ) +
  theme_minimal(base_size = 11) +
  theme(
    legend.position = "bottom",
    plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
  )
```

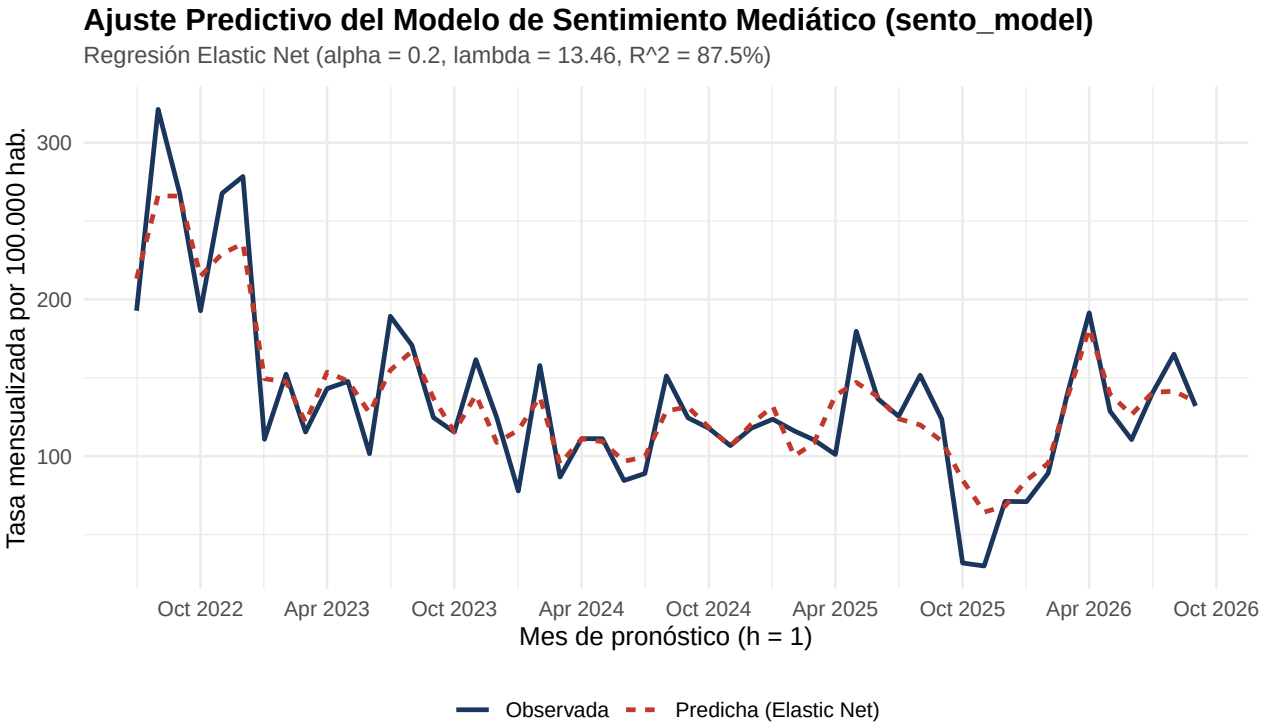


Figura 13: Comparación entre la tasa mensualizada de hurto observada y la predicción un paso adelante con Elastic Net

5.2. Descomposición de atribuciones marginales (`attributions`)

Al tratarse de un modelo lineal sobre las series suavizadas, `attributions()` descompone exactamente cada pronóstico mensual en la contribución marginal que aporta cada diccionario (`nrc_es` frente a `crimen_es`), cada característica o cada esquema de memoria temporal.

```
## 5.5 Gráfico de atribuciones por dimensión léxica ----
suppressMessages(
  plot(atribuciones_raw, group = "lexicons") +
    scale_fill_manual(
```

```
      values = c("nrc_es" = "#5b8fb9", "crimen_es" = "#d96b52"),
      labels = c("nrc_es" = "NRC en español (nrc_es)", "crimen_es" = "Criminalidad Bogotá
      ↪  (crimen_es)"),
      name   = NULL
    ) +
    scale_color_manual(
      values = c("nrc_es" = "#2c5b84", "crimen_es" = "#9c321d"),
      labels = c("nrc_es" = "NRC en español (nrc_es)", "crimen_es" = "Criminalidad Bogotá
      ↪  (crimen_es)"),
      name   = NULL
    ) +
    scale_x_date(name = "Fecha", date_breaks = "6 months", date_labels = "%b %Y") +
    scale_y_continuous(name = "Aporte marginal al pronóstico") +
    labs(
      title    = "Descomposición de Atribuciones por Diccionario Léxico (attributions)",
      subtitle = "Contribución marginal del léxico general (nrc_es) vs. criminalidad en Bogotá
      ↪  (crimen_es)"
    ) +
    theme_minimal(base_size = 11) +
    theme(
      legend.position = "bottom",
      plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
      plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
    )
)
```

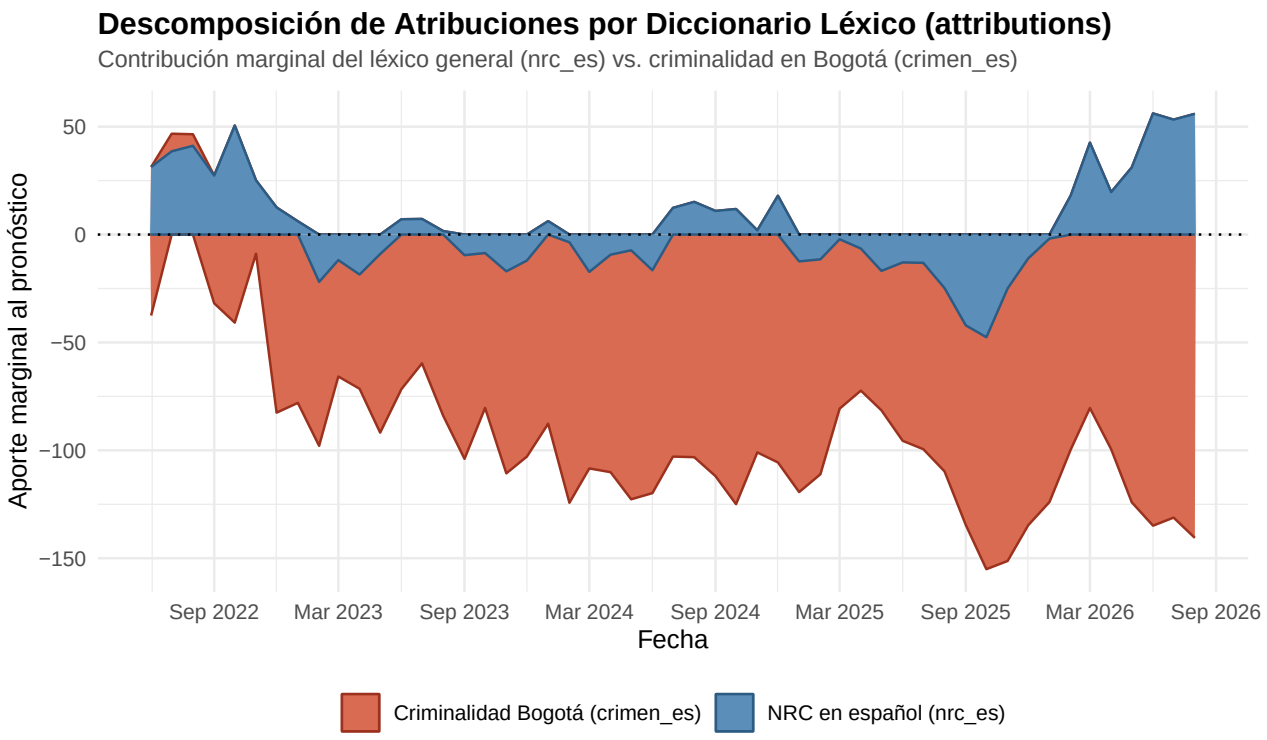


Figura 14: Descomposición temporal de atribuciones del modelo por diccionario léxico

6. Cartografía espacial e integración para R Shiny

Clasificar las 19 localidades en tres clústeres resume los grandes perfiles de seguridad, pero oculta dónde se concentra cada modalidad delictiva en el mapa y si la prensa cubre esos territorios en la misma proporción. En esta sección consolidamos en memoria el panel anual Localidad x Año (Fase 5 de `scripts/03_analisis_sentometrics.R`), proyectamos los mapas vectoriales con `{sf}` y resumimos la conexión hacia la aplicación Shiny.

6.1. Geografía del delito por modalidad

```
# 6. Consolidación anual, cartografía vectorial (sf) e integración Shiny ----

## 6.1 Consolidación del panel anual Localidad x Año (Fase 5 de 03_analisis_sentometrics.R) ----
noticias_agg <- df_noticias_enriquecida |>
  filter(año >= 2022 & año <= 2026) |>
  group_by(localidad, año) |>
  summarise(
    noticias_conteo      = n(),
    noticias_dai_conteo  = sum(es_dai_estricto, na.rm = TRUE),
    sentimiento_promedio = round(mean(sentimiento_score, na.rm = TRUE), 4),
    sentimiento_nrc      = round(mean(score_nrc_es, na.rm = TRUE), 4),
    sentimiento_crimen   = round(mean(score_crimen_es, na.rm = TRUE), 4),
    sentimiento_mediana  = round(median(sentimiento_score, na.rm = TRUE), 4),
    prop_negativas       = round(mean(sentimiento_categoria == "Negativo", na.rm = TRUE) * 100, 2),
    prop_positivas       = round(mean(sentimiento_categoria == "Positivo", na.rm = TRUE) * 100, 2),
    prop_neutras         = round(mean(sentimiento_categoria == "Neutro", na.rm = TRUE) * 100, 2),
    .groups = "drop"
  )

panel_consolidado <- panel_delitos |>
  left_join(noticias_agg, by = c("localidad", "año")) |>
  mutate(
    noticias_conteo      = replace_na(noticias_conteo, 0L),
    noticias_dai_conteo  = replace_na(noticias_dai_conteo, 0L),
    sentimiento_promedio = replace_na(sentimiento_promedio, 0),
    sentimiento_nrc      = replace_na(sentimiento_nrc, 0),
    sentimiento_crimen   = replace_na(sentimiento_crimen, 0),
    sentimiento_mediana  = replace_na(sentimiento_mediana, 0),
    prop_negativas       = replace_na(prop_negativas, 0),
    prop_positivas       = replace_na(prop_positivas, 0),
    prop_neutras         = replace_na(prop_neutras, 0)
  )

stopifnot(nrow(panel_consolidado) == 95)

## 6.2 Preparación de polígonos oficiales (sf) y mapas por modalidad ----
geo_bogota <- sf::st_read(archivo_geo_raw, quiet = TRUE) |>
  mutate(codigo_localidad = sprintf("%02d", as.integer(CMIULOCAL))) |>
  filter(!codigo_localidad %in% c("20", "99")) |>
```

```r
  left_join(df_clusters, by = "codigo_localidad")

stopifnot(nrow(geo_bogota) == 19)

generar_mapa_delito <- function(df, var_col, titulo, etiqueta_leyenda, paleta = "magma") {
  df$tooltip <- paste0(
    "<b>", df$localidad, "</b><br>",
    titulo, ": <b>", scales::comma(round(df[[var_col]], 1)), "</b> por 100k hab.<br>",
    "Clúster: ", df$cluster_nombre
  )

  ggplot(df) +
    geom_sf(aes(fill = .data[[var_col]], text = tooltip), color = "white", linewidth = 0.25) +
    scale_fill_viridis_c(
      option    = paleta,
      direction = -1,
      name      = etiqueta_leyenda,
      labels    = scales::comma
    ) +
    labs(title = titulo) +
    theme_void(base_size = 11) +
    theme(
      plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b =
      ↪  6)),
      legend.position = "right",
      legend.title    = element_text(size = 8.5, face = "bold"),
      legend.text     = element_text(size = 8),
      plot.margin     = margin(6, 6, 6, 6)
    )
}

fijar_colorbar <- function(ply, x_pos, y_pos = 0.5, len_val = 0.65, thick = 14, titulo = NULL) {
  for (i in seq_along(ply$x$data)) {
    if (!is.null(ply$x$data[[i]]$marker$colorbar)) {
      ply$x$data[[i]]$marker$colorbar$x         <- x_pos
      ply$x$data[[i]]$marker$colorbar$y         <- y_pos
      ply$x$data[[i]]$marker$colorbar$len       <- len_val
      ply$x$data[[i]]$marker$colorbar$thickness <- thick
      ply$x$data[[i]]$marker$colorbar$xanchor   <- "left"
      ply$x$data[[i]]$marker$colorbar$yanchor   <- "middle"
      if (!is.null(titulo)) {
        ply$x$data[[i]]$marker$colorbar$title <- titulo
      }
    }
  }
  ply
}

p_pers  <- generar_mapa_delito(geo_bogota, "tasa_personas_prom", "Hurto a Personas", "Tasa
↪  por\n100k hab.")
p_resid <- generar_mapa_delito(geo_bogota, "tasa_resid_prom", "Hurto a Residencias", "Tasa
↪  por\n100k hab.")
```

```r
p_motos <- generar_mapa_delito(geo_bogota, "tasa_motos_prom", "Hurto de Motocicletas", "Tasa
↪  por\n100k hab.")
p_total <- generar_mapa_delito(geo_bogota, "tasa_total_prom", "Tasa Total de Hurtos", "Tasa
↪  por\n100k hab.")

if (knitr::is_html_output()) {
  ply1 <- plotly::ggplotly(p_pers,  tooltip = "text") |> fijar_colorbar(0.44, 0.77, 0.35, 11, "Tasa
↪  / 100k")
  ply2 <- plotly::ggplotly(p_resid, tooltip = "text") |> fijar_colorbar(1.00, 0.77, 0.35, 11, "Tasa
↪  / 100k")
  ply3 <- plotly::ggplotly(p_motos, tooltip = "text") |> fijar_colorbar(0.44, 0.22, 0.35, 11, "Tasa
↪  / 100k")
  ply4 <- plotly::ggplotly(p_total, tooltip = "text") |> fijar_colorbar(1.00, 0.22, 0.35, 11, "Tasa
↪  / 100k")

  anotaciones_4 <- list(
    list(x = 0.20, y = 1.02, text = "<b>Hurto a Personas</b>",      showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.74, y = 1.02, text = "<b>Hurto a Residencias</b>",   showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.20, y = 0.48, text = "<b>Hurto de Motocicletas</b>", showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.74, y = 0.48, text = "<b>Tasa Total de Hurtos</b>",  showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11))
  )

  plotly::subplot(ply1, ply2, ply3, ply4, nrows = 2, margin = c(0.06, 0.06, 0.08, 0.08)) |>
    plotly::layout(
      annotations = anotaciones_4,
      margin      = list(l = 10, r = 50, t = 40, b = 10)
    )
} else {
  grid_delitos <- cowplot::plot_grid(p_pers, p_resid, p_motos, p_total, ncol = 2, align = "hv")

  titulo_facetas <- cowplot::ggdraw() +
    cowplot::draw_label(
      "Distribución Espacial de las Tasas de Hurto por Modalidad",
      fontface = "bold", size = 13, hjust = 0.5, x = 0.5, y = 0.65
    ) +
    cowplot::draw_label(
      "Tasas anuales promedio por 100.000 habitantes en las 19 localidades urbanas de Bogotá
      ↪  (2022-2026)",
      size = 10, color = "grey35", hjust = 0.5, x = 0.5, y = 0.25
    )

  cowplot::plot_grid(titulo_facetas, grid_delitos, ncol = 1, rel_heights = c(0.08, 1))
}
```

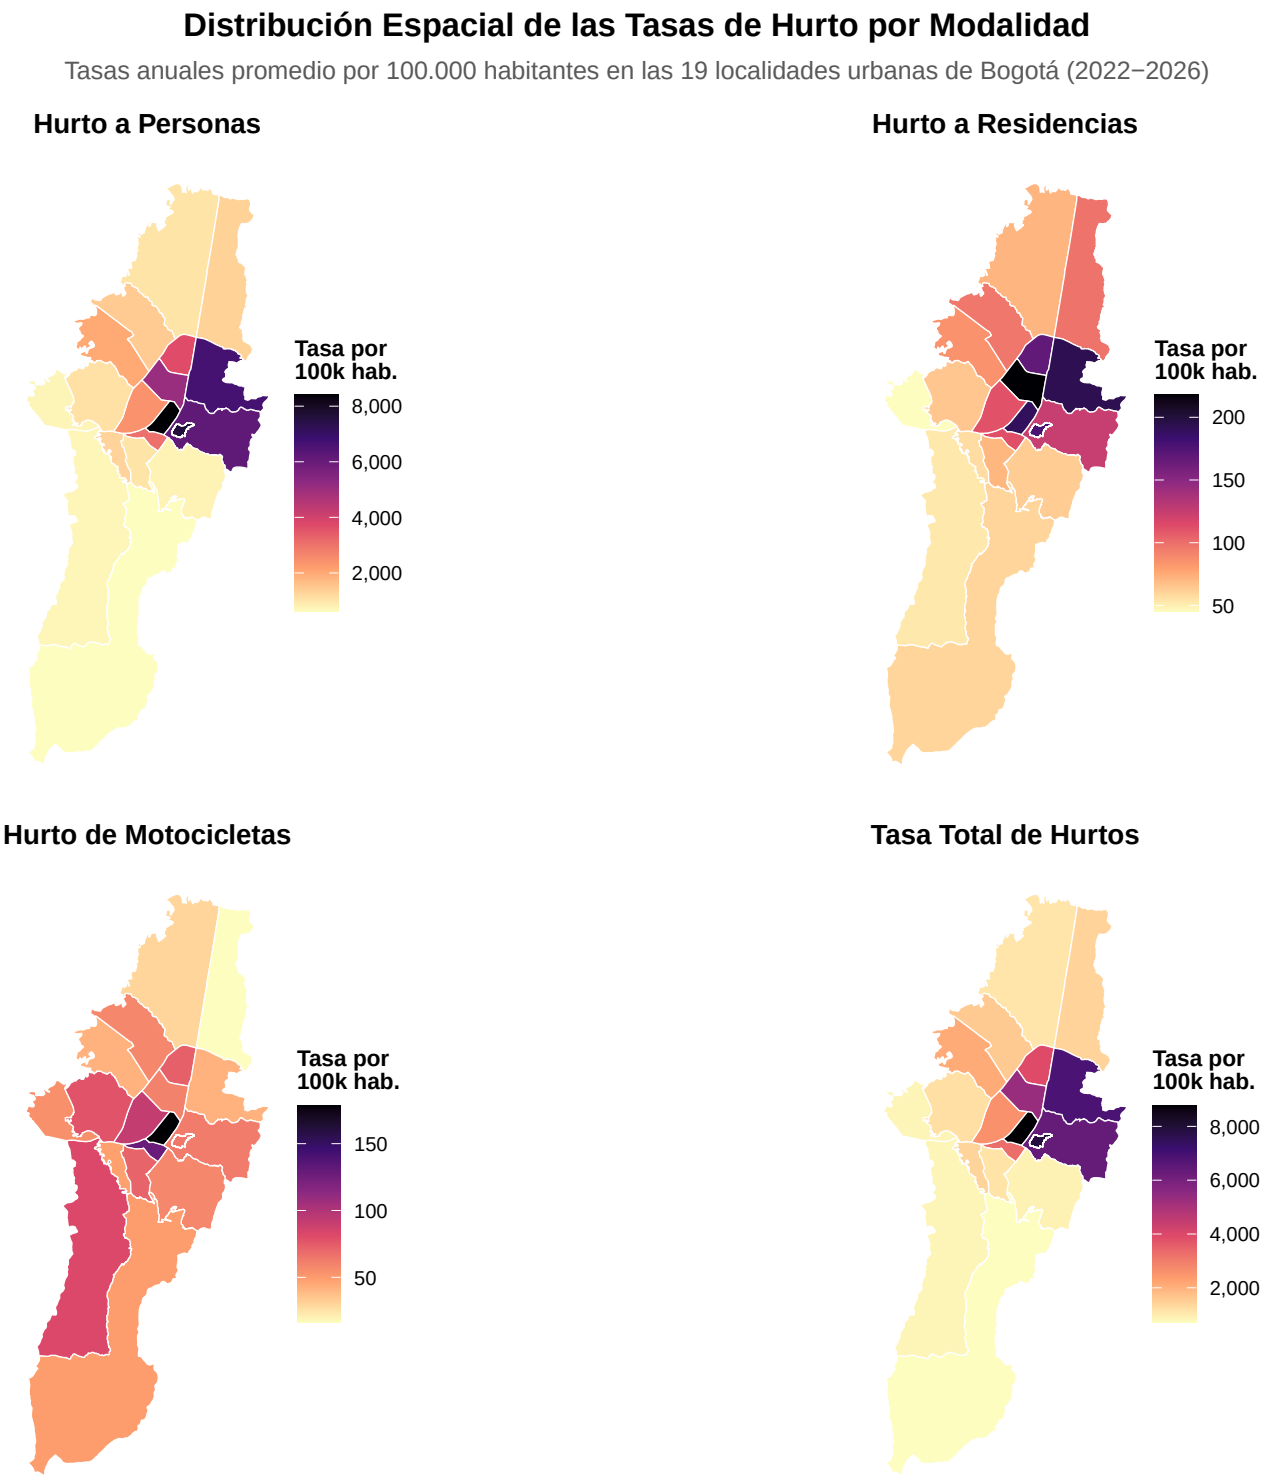


Figura 15: Distribución espacial de las tasas de hurto por 100.000 habitantes en las 19 localidades urbanas de Bogotá (2022-2026)

Los mapas confirman que cada modalidad sigue una geografía distinta. El hurto a personas alcanza sus tasas más altas en el centro ampliado y el eje oriental: Los Mártires registra 8.390 casos por 100.000 habitantes, La Candelaria 7.615, Chapinero 6.641 y Santa Fe 6.177, impulsado por la concentración comercial y la población

flotante diurna. En cambio, el hurto de motocicletas se concentra en Los Mártires (178 por 100.000 habitantes) y Antonio Nariño (128), zonas vinculadas a talleres y comercio de repuestos. El hurto a residencias muestra mayor presencia en sectores consolidados como Teusaquillo (217), Chapinero (192) y Barrios Unidos (168).

6.2. Desajuste espacial entre delito registrado y cobertura periodística

Para contrastar la señal de las denuncias policiales frente a la atención de la prensa digital, comparamos lado a lado la tasa promedio de hurtos y el conteo acumulado de noticias por localidad.

```
## 6.3 Contraste espacial entre tasa oficial y cobertura mediática ----
noticias_conteo <- df_noticias_enriquecida |>
  count(localidad, name = "total_noticias")

geo_bogota_dual <- geo_bogota |>
  left_join(noticias_conteo, by = "localidad")

geo_bogota_dual$tooltip_delito <- paste0(
  "<b>", geo_bogota_dual$localidad, "</b><br>",
  "Tasa real: <b>", scales::comma(round(geo_bogota_dual$tasa_total_prom, 1)), "</b> por 100k
  ↪  hab.<br>",
  "Clúster: ", geo_bogota_dual$cluster_nombre
)

geo_bogota_dual$tooltip_noticias <- paste0(
  "<b>", geo_bogota_dual$localidad, "</b><br>",
  "Noticias en el corpus: <b>", scales::comma(geo_bogota_dual$total_noticias), "</b>
  ↪  artículos<br>",
  "Clúster: ", geo_bogota_dual$cluster_nombre
)

p_delito_real <- ggplot(geo_bogota_dual) +
  geom_sf(aes(fill = tasa_total_prom, text = tooltip_delito), color = "white", linewidth = 0.3) +
  scale_fill_viridis_c(
    option    = "magma",
    direction = -1,
    name      = "Tasa por\n100k hab.",
    labels    = scales::comma
  ) +
  labs(title = "Tasa Delictiva Real (Policía SDSCJ)") +
  theme_void(base_size = 11) +
  theme(
    plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b = 6)),
    legend.position = "right",
    legend.title    = element_text(size = 8.5, face = "bold"),
    legend.text     = element_text(size = 8),
    plot.margin     = margin(6, 6, 6, 6)
  )

p_prensa_vol <- ggplot(geo_bogota_dual) +
  geom_sf(aes(fill = total_noticias, text = tooltip_noticias), color = "white", linewidth = 0.3) +
  scale_fill_viridis_c(
```

```
    option    = "magma",
    direction = -1,
    name      = "Total\nnoticias",
    labels    = scales::comma
  ) +
  labs(title = "Cobertura Noticiosa (Google News)") +
  theme_void(base_size = 11) +
  theme(
    plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b = 6)),
    legend.position = "right",
    legend.title    = element_text(size = 8.5, face = "bold"),
    legend.text     = element_text(size = 8),
    plot.margin     = margin(6, 6, 6, 6)
  )

if (knitr::is_html_output()) {
  ply_delito   <- plotly::ggplotly(p_delito_real, tooltip = "text") |> fijar_colorbar(0.44, 0.5,
↪  0.65, 13, "Tasa / 100k")
  ply_noticias <- plotly::ggplotly(p_prensa_vol,  tooltip = "text") |> fijar_colorbar(1.00, 0.5,
↪  0.65, 13, "Noticias")

  anotaciones_dual <- list(
    list(x = 0.20, y = 1.03, text = "<b>Tasa Delictiva Real (Policía SDSCJ)</b>", showarrow =
    ↪  FALSE, xref = "paper", yref = "paper", xanchor = "center", font = list(size = 12)),
    list(x = 0.74, y = 1.03, text = "<b>Cobertura Noticiosa (Google News)</b>", showarrow = FALSE,
    ↪  xref = "paper", yref = "paper", xanchor = "center", font = list(size = 12))
  )

  plotly::subplot(ply_delito, ply_noticias, nrows = 1, margin = 0.08) |>
    plotly::layout(
      annotations = anotaciones_dual,
      margin      = list(l = 10, r = 50, t = 35, b = 10)
    )
} else {
  grid_dual <- cowplot::plot_grid(p_delito_real, p_prensa_vol, ncol = 2, align = "hv")

  titulo_dual <- cowplot::ggdraw() +
    cowplot::draw_label(
      "Contraste Espacial: Criminalidad Registrada frente a Cobertura Noticiosa",
      fontface = "bold", size = 13, hjust = 0.5, x = 0.5, y = 0.65
    ) +
    cowplot::draw_label(
      "Tasas de denuncia por 100.000 hab. (SIEDCO) vs. número total de noticias en el corpus
      ↪  (2022-2026)",
      size = 10, color = "grey35", hjust = 0.5, x = 0.5, y = 0.25
    )

  cowplot::plot_grid(titulo_dual, grid_dual, ncol = 1, rel_heights = c(0.12, 1))
}
```

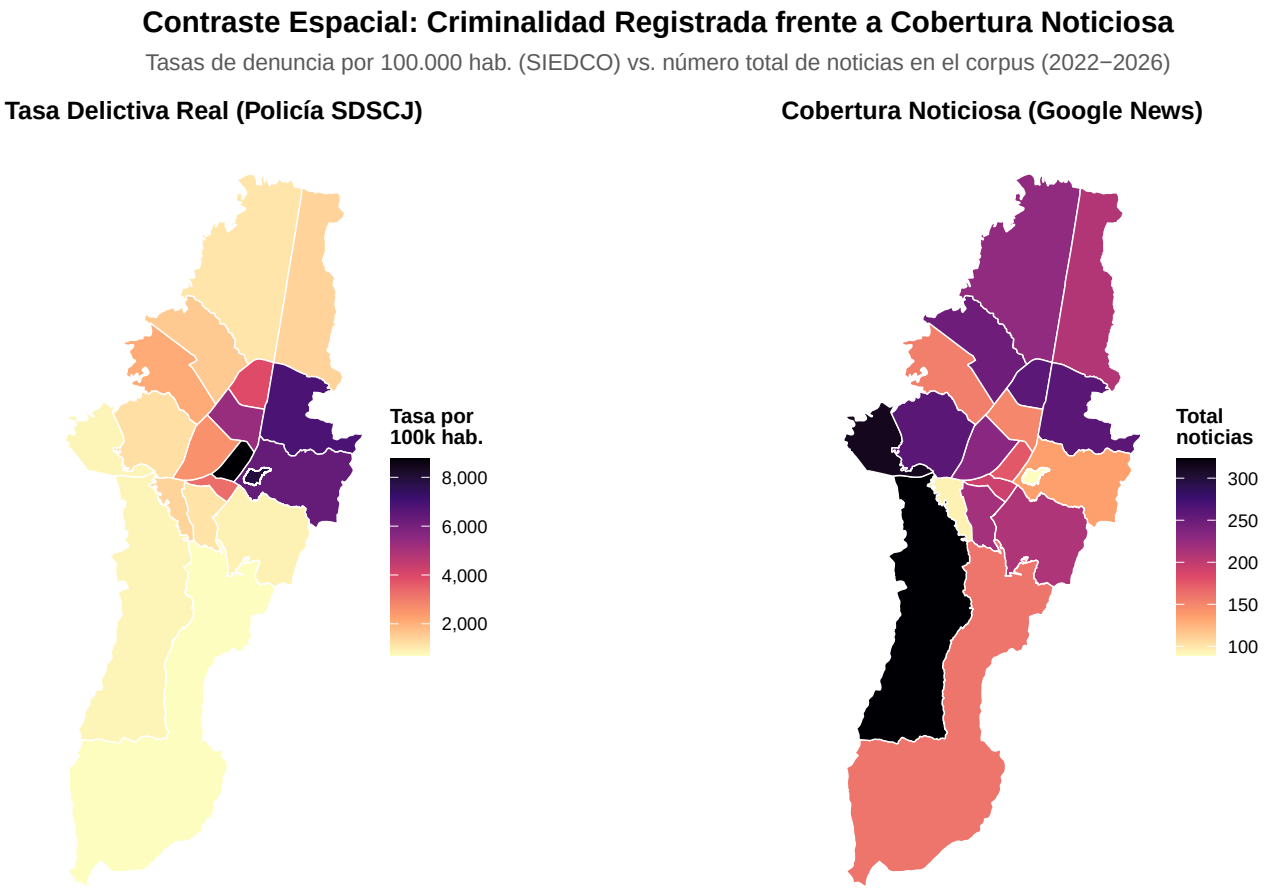


Figura 16: Comparación entre la tasa delictiva oficial y el volumen de noticias sobre delincuencia por localidad

El contraste evidencia una asimetría clara entre el riesgo relativo registrado y el foco noticioso. Localidades con tasas per cápita muy altas, como La Candelaria y Santa Fe, concentran un volumen modesto de noticias (90 y 136 artículos). Por el contrario, localidades muy pobladas como Ciudad Bolívar (323), Bosa (313) y Kennedy (260) reciben mucha más cobertura en términos absolutos aunque sus tasas por 100.000 habitantes sean bastante más bajas que las del centro histórico.

6.3. Integración conceptual hacia el tablero R Shiny (“Dos lecturas de Bogotá”)

Para que la aplicación interactiva (`app/app.R`) responda en milisegundos sin recalcular modelos ni leer archivos GeoJSON en cada sesión de usuario, la arquitectura separa el cómputo pesado del tablero web:

- **Empaquetado único (`scripts/05_export_insumos_shiny.R`):** reúne el panel anual consolidado, los clústeres de K-Means, los polígonos simplificados en coordenadas WGS84, las estadísticas del corpus, las series largas y los resultados de Elastic Net dentro de un único archivo binario (`datos_consolidados_shiny.rds`).
- **Renderizado cartográfico con Leaflet:** las pestañas *Panorama* y *Clusters* cargan las geometrías directamente sobre un mapa base oscuro de OpenStreetMap para comparar la lectura de las denuncias (en ámbar) frente a la lectura mediática (en azul).

- **Sincronización reactiva por clics:** al seleccionar una localidad en el mapa o en el gráfico de dispersión, los observadores `input$mapa_panorama_shape_click` y `plotly_click` actualizan de inmediato la ficha territorial con sus series mensuales, distribución de tono y artículos extremos (`peakdocs`).

7. Verificación de consistencia, guía de estudio y conclusiones

7.1. Auditoría programática de los objetos calculados en memoria

Como cierre técnico de la ejecución autocontenida, comprobamos la clase S3 y las dimensiones de cada objeto construido en vivo a lo largo de este cuaderno.

```
# 7. Auditoría de consistencia sobre objetos calculados en memoria ----
objetos_sesion <- list(
  df_clusters         = df_clusters,
  corpus_sento        = corpus_sento,
  lexicons_es         = lexicons_es,
  sentiment_scores    = sentiment_scores,
  objeto_peak_docs    = objeto_peak_docs,
  medidas_sento       = medidas_sento,
  df_measures_long    = df_measures_long,
  objeto_global_index = objeto_global_index,
  objeto_attributions = objeto_attributions,
  panel_consolidado   = panel_consolidado,
  geo_bogota          = geo_bogota
)

descripciones_obj <- c(
  "Asignaciones K-Means (K* = 3) y ancho de silueta por localidad",
  "Corpus textual con 26 covariables binarias (19 loc. + 3 clústeres + 4 temas)",
  "Diccionarios combinados (nrc_es + crimen_es) y modificadores de valencia",
  "Puntajes de polaridad documental (proportionalPol)",
  "Catálogo de noticias extremas globales y locales (peakdocs)",
  "Objeto S3 con 364 series mensuales ponderadas",
  "Panel largo de series mensuales con etiquetas legibles",
  "Índice global distrital y fechas críticas (peakdates)",
  "Modelo Elastic Net (BIC, h = 1) y descomposición de atribuciones",
  "Panel consolidado anual Localidad x Año (delitos, población y prensa)",
  "Capa vectorial sf de las 19 localidades urbanas"
)

dimensiones_obj <- vapply(objetos_sesion, function(obj) {
  if (inherits(obj, "sento_measures")) {
    paste(nrow(obj$measures), "x", ncol(obj$measures) - 1, "series")
  } else if (inherits(obj, "sento_corpus")) {
    paste(quanteda::ndoc(obj), "docs")
  } else if (inherits(obj, "sento_lexicons")) {
    paste(length(obj) - 1, "diccionarios + valencia")
  } else if (is.data.frame(obj)) {
    paste(nrow(obj), "filas x", ncol(obj), "cols")
```

```
  } else if (is.list(obj)) {
    paste(length(obj), "componentes")
  } else {
    as.character(length(obj))
  }
}, character(1))

clases_obj <- vapply(objetos_sesion, function(obj) {
  paste(class(obj), collapse = ", ")
}, character(1))

tabla_auditoria <- data.frame(
  Objeto      = names(objetos_sesion),
  Componente  = descripciones_obj,
  `Clase S3`  = clases_obj,
  Dimensión   = dimensiones_obj,
  Estado      = "Verificado (✓)",
  check.names = FALSE,
  stringsAsFactors = FALSE
)

knitr::kable(tabla_auditoria, row.names = FALSE, align = c("l", "l", "l", "r", "c"))
```

Tabla 7: Auditoría programática de los objetos analíticos generados en memoria durante la compilación

Objeto	Componente	Clase S3	Dimensión	Estado
df_clusters	Asignaciones K-Means (K* = 3) y ancho de silueta por localidad	tbl_df, tbl, data.frame	19 filas x 11 cols	Verificado (✓)
corpus_sento	Corpus textual con 26 covariables binarias (19 loc. + 3 clústeres + 4 temas)	sento_corpus, corpus, character	3916 docs	Verificado (✓)
lexicons_es	Diccionarios combinados (nrc_es + crimen_es) y modificadores de valencia	sento_lexicons, list	2 diccionarios + valencia	Verificado (✓)
sentiment_scores	Puntajes de polaridad documental (proportionalPol)	sentiment, data.table, data.frame	3916 filas x 55 cols	Verificado (✓)
objeto_peak_docs	Catálogo de noticias extremas globales y locales (peakdocs)	list	5 componentes	Verificado (✓)
medidas_sento	Objeto S3 con 364 series mensuales ponderadas	sento_measures	52 x 364 series	Verificado (✓)
df_measures_long	Panel largo de series mensuales con etiquetas legibles	tbl_df, tbl, data.frame	18928 filas x 9 cols	Verificado (✓)
objeto_global_index	Índice global distrital y fechas críticas (peakdates)	list	4 componentes	Verificado (✓)
objeto_attributions	Modelo Elastic Net (BIC, h = 1) y descomposición de atribuciones	list	8 componentes	Verificado (✓)
panel_consolidado	Panel consolidado anual Localidad x Año (delitos, población y prensa)	tbl_df, tbl, data.frame	95 filas x 20 cols	Verificado (✓)

Tabla 7: Auditoría programática de los objetos analíticos generados en memoria durante la compilación

Objeto	Componente	Clase S3	Dimensión	Estado
geo_bogota	Capa vectorial sf de las 19 localidades urbanas	sf, data.frame	19 filas x 149 cols	Verificado (✓)

7.2. Preguntas de estudio para sustentación

Puntos de repaso metodológico

1. **¿Cómo se conectan K-Means y `sentometrics`?** `04_clustering_kmeans.R` segmenta las 19 localidades en $K^* = 3$ perfiles delictivos según sus tasas estandarizadas. Esas asignaciones se transforman en tres indicadores binarios (`c_centro`, `c_comercial`, `c_residencial`) dentro de `sento_corpus()`, permitiendo construir series mensuales de sentimiento por clúster y medir su aporte predictivo en `attributions()`.
2. **¿Por qué combinar `nrc_es` y `crimen_es` con `valenceIn`?** Un diccionario general traducido no captura términos locales como *"fleteo"*, *"cosquilleo"* o *"escopolamina"*, ni distingue el vocabulario de seguridad pública. Al sumar `crimen_es` y los modificadores de valencia ($t \in \{1, 2, 3, 4\}$), frases con negaciones (*"sin capturas"*) o intensificadores (*"brutal atraco"*) reciben el signo y la magnitud adecuados.
3. **¿Por qué dividir por $N_{\text{pol}}(d_i)$ (`proportionalPol`)?** En nuestro corpus conviven notas cortas de alrededor de 20 palabras con crónicas de más de 500 palabras. Normalizar solo entre palabras con carga polar evita que el texto descriptivo neutro diluya el tono de los reportajes largos y mantiene comparables ambos formatos.
4. **¿Cómo responde rápido la aplicación Shiny?** Todo el cómputo pesado se ejecuta previamente en `scripts/master.R` y se empaqueta en `datos_consolidados_shiny.rds`. Al abrirse, `app/app.R` lee ese archivo único y actualiza mapas y gráficos con la respuesta en memoria.

7.3. Conclusiones empíricas

La articulación de registros policiales oficiales, minería de texto y modelado regularizado deja tres hallazgos principales:

1. **Especialización territorial del hurto:** la partición en $K^* = 3$ clústeres (silueta promedio 0.5416) muestra dinámicas urbanas diferenciadas. El núcleo céntrico e institucional concentra niveles muy elevados de hurto a personas (hasta 7,615 casos por 100.000 habitantes en La Candelaria) debido a su población flotante diaria; el corredor comercial de Los Mártires y Antonio Nariño encabeza el hurto a personas (8,390 en Los Mártires) y el hurto de motocicletas (178 y 128 por 100.000 habitantes); y las doce localidades periféricas registran tasas relativas menores pero concentran el mayor número absoluto de residentes afectados.
2. **Medición contextual del tono periodístico:** combinar `nrc_es` con `crimen_es` y modificadores de valencia evitó distorsiones por negaciones y amplificadores, y la extracción de `peakdocs()` permitió aislar los episodios informativos de mayor alarma en transporte masivo y homicidios.
3. **Capacidad explicativa y asimetría espacial:** Elastic Net retuvo 46 de las 364 series de sentimiento y explicó el 87.53 % de la varianza mensual de la intensidad delictiva ($h = 1$). Al mismo tiempo, los

mapas revelan que la cobertura periodística se concentra en localidades populosas de la periferia sur y occidental (Ciudad Bolívar, Bosa, Kennedy), mientras que las tasas per cápita más altas ocurren en el centro histórico.

7.4. Limitaciones de la investigación

La lectura de estos resultados debe considerar tres límites del diseño empírico:

1. **Subregistro y cifra negra:** las cifras de la SDSCJ contabilizan únicamente los delitos denunciados formalmente. En zonas con menor confianza institucional o en hurtos de menor cuantía, el subregistro tiende a ser mayor, de modo que las tasas reflejan tanto incidencia real como propensión a denunciar.
2. **Sesgo editorial en fuentes digitales:** Google News indexa portales con criterios propios de noticiabilidad, priorizando incidentes visibles o localidades con mayor audiencia potencial frente a hechos cotidianos en sectores menos cubiertos.
3. **Agregación por localidad:** trabajar a escala de localidad por disponibilidad de proyecciones poblacionales oculta diferencias internas dentro de territorios de más de un millón de habitantes como Suba o Kennedy, donde coexisten barrios residenciales tranquilos y corredores comerciales de alta congestión.

7.5. Implicaciones de política pública

Los resultados orientan dos decisiones concretas para la planeación de la seguridad urbana:

1. **Intervenciones diferenciadas por modalidad:** los corredores céntricos requieren patrullaje peatonal, control en estaciones de transporte masivo e iluminación en horas pico; el eje de Los Mártires y Antonio Nariño exige control a mercados de autopartes y talleres mecánicos; y las localidades residenciales masivas demandan fortalecimiento de frentes locales de seguridad y prevención comunitaria.
2. **Uso complementario de cifras policiales y monitoreo mediático:** orientar la asignación operativa de recursos únicamente por la presión de la agenda noticiosa puede sobre-atender zonas de alta exposición en prensa mientras descuida territorios con alta victimización absoluta o alto riesgo relativo por habitante.