Modelado Metodológico: Clústeres Territoriales de Criminalidad y Sentometrics en Bogotá (2022–septiembre de 2026)

Taller de Programación en R — Maestría en Economía Aplicada (MECA)

Juan José Echeverry — 202616233 Miguelangel Palma — 202621481
Sergio Alejandro López Valderrama — 202111932
Gabriel Arturo Echeverry Castaño — 201016705
Olga Lucía Ramírez Contreras — 202624900
Juan Esteban Carvajal Cruz — 202614312

2026-11-07

Tabla de contenidos

1. Configuración Inicial y Dependencias **1**
1.1. Opciones globales y semilla . . . 2
1.2. Librerías requeridas y control de conflictos . . . 2
1.3. Definición de rutas relativas con `{here}` . . . 2

2. Modelado y Diagnóstico de Tasas de Hurto por 100.000 Habitantes **3**
2.1. Intuición económica: ¿Por qué estandarizar por población expuesta? . . . 3
2.2. Carga y estadísticas descriptivas del panel delictivo . . . 3
2.3. Ranking territorial de criminalidad promedio . . . 4

3. Agrupamiento Territorial de Criminalidad con K-Means **6**
3.1. Fundamentos del algoritmo K-Means . . . 6
3.1.1. Necesidad de estandarizar las variables (Z-score) . . . 6
3.1.2. Las cuatro etapas iterativas del algoritmo . . . 7
3.2. Selección del número óptimo de clústeres (K^*) . . . 8
3.3. Caracterización de perfiles delictivos ($K^* = 3$) . . . 10
3.4. Visualización tridimensional y bidimensional de los clústeres . . . 11

4. Análisis Cuantitativo de Sentimiento con `sentometrics` **19**
4.1. Formulación matemática de la agregación tridimensional (ω, θ, b) . . . 19
4.2. Carga y verificación de los artefactos `.rds` del pipeline (Tareas `T-07` a `T-15`) . . . 19
4.3. Diagnóstico de léxicos, ponderación documental y noticias pico (`peakdocs`) . . . 20
4.4. Evolución mensual del sentimiento por clúster territorial e índice global (`T-13` a `T-16`) . . . 21

5. Modelado Econométrico Supervisado (Elastic Net) y Atribuciones **22**
5.1. Especificación del modelo regularizado (`sento_model`) . . . 22
5.2. Descomposición de atribuciones marginales (`attributions`) . . . 24

6. Cartografía Espacial e Integración para R Shiny **25**
6.1. Geografía especializada del delito por modalidad . . . 25
6.2. Desajuste espacial entre delito registrado y cobertura periodística . . . 29

6.3. Integración de la capa espacial en el tablero interactivo (R Shiny) 31

7. Diagnóstico Final de Integridad y Conclusiones **32**
7.1. Auditoría programática del contrato de datos 32
7.2. Conclusiones metodológicas y empíricas 34
7.3. Limitaciones de la investigación 34
7.4. Implicaciones de política pública 34

1. Configuración Inicial y Dependencias

Este cuaderno documenta de manera integral y autocontenida la metodología econométrica y de procesamiento de lenguaje natural del proyecto, articulando cinco componentes:

1. **Tasas delictivas por 100.000 habitantes:** Estandarización demográfica de los registros oficiales de la Secretaría Distrital de Seguridad, Convivencia y Justicia (SDSCJ / SIEDCO) y la Secretaría Distrital de Salud (SDS).
2. **Agrupamiento territorial no supervisado (K-Means):** Diagnóstico matemático del número óptimo de clústeres ($K^* = 3$, silueta 0.5416) y caracterización socio-económica de perfiles delictivos.
3. **Arquitectura `sentometrics` (Fases 1 a 3):** Construcción del `sento_corpus` con 26 características binarias (19 localidades + 3 clústeres + 4 tópicos DAI), diccionarios de polaridad (`nrc_es` y `crimen_es`) con modificadores de valencia ($t \in \{1, 2, 3, 4\}$), extracción de noticias críticas (`peakdocs`) y agregación multidimensional (`sento_measures`, `aggregate` y `peakdates`).
4. **Modelado econométrico supervisado (`sento_model` y `attributions`):** Estimación con regularización Elastic Net sobre la serie mensual empírica de intensidad delictiva y descomposición aditiva de atribuciones.
5. **Integración cartográfica vectorial (`sf`):** Vinculación espacial de los perfiles delictivos y mediáticos sobre las 19 localidades urbanas del Distrito Capital.

> **Arquitectura de Reproducibilidad y Contrato de Datos**
>
> Este documento consume directamente los insumos procesados en `data/processed/`, incluyendo tanto las tablas columnares `.parquet` como los 8 artefactos `.rds` del contrato `sentometrics` (`01_sento_corpus.rds` a `08_attributions.rds`), garantizando compilación determinística sin requerir conexión a internet.

1.1. Opciones globales y semilla

```
# Limpieza del entorno de trabajo, desactivación de notación científica y fijación de semilla
rm(list = ls())
options(scipen = 999)
set.seed(20261014)
```

1.2. Librerías requeridas y control de conflictos

```
# Carga de paquetes para manipulación de datos, clustering, visualización y análisis textual
library(here)
library(conflicted)
library(arrow)
```

```r
library(readr)
library(dplyr)
library(tidyr)
library(stringr)
library(stringi)
library(data.table)
library(ggplot2)
library(ggrepel)
library(plotly)
library(scales)
library(knitr)
library(cluster)
library(sentometrics)
library(syuzhet)
library(glmnet)
library(sf)
library(cowplot)

# Preferencia explícita de funciones en caso de colisión de nombres entre paquetes
conflict_prefer("filter", "dplyr", quiet = TRUE)
conflict_prefer("lag",    "dplyr", quiet = TRUE)
conflict_prefer("select", "dplyr", quiet = TRUE)
conflict_prefer("first",  "dplyr", quiet = TRUE)
conflict_prefer("layout", "plotly", quiet = TRUE)
```

1.3. Definición de rutas relativas con {here}

```r
# Construcción de rutas relativas a partir de la raíz del proyecto
ruta_proc <- here("data", "processed")

archivo_delitos_p <- file.path(
  ruta_proc, "02_poblacion", "panel_delitos_poblacion_localidad.parquet"
)
archivo_noticias_p <- file.path(
  ruta_proc, "03_noticias", "noticias_procesadas.parquet"
)
archivo_panel_c <- file.path(
  ruta_proc, "panel_consolidado_localidad_anual.parquet"
)
archivo_clusters_p <- file.path(
  ruta_proc, "clusters_localidades_kmeans.parquet"
)
archivo_geo_raw <- here(
  "data", "raw", "delitos", "localidades_bogota_raw.geojson"
)
```

---

2. Modelado y Diagnóstico de Tasas de Hurto por 100.000 Habitantes

2.1. Intuición económica: ¿Por qué estandarizar por población expuesta?

Comparar conteos delictivos brutos entre territorios conduce a conclusiones sesgadas por escala demográfica. Localidades populosas como Suba o Kennedy (con cerca de un millón de residentes cada una) registran naturalmente un volumen absoluto elevado de denuncias, mientras que localidades céntricas con baja población residente pero alta población flotante exhiben un riesgo per cápita sustancialmente mayor.

Para corregir esta asimetría, calculamos la **Tasa Anual de Hurto por cada 100.000 Habitantes**:

$$\text{Tasa}_{it}^{(m)} = \frac{\text{Denuncias del delito } m \text{ en la localidad } i \text{ en el año } t}{\text{Población residente proyectada en la localidad } i \text{ en el año } t} \times 100.000 \tag{1}$$

donde $m \in \{\text{personas}, \text{residencias}, \text{motocicletas}, \text{total}\}$ e $i \in \{1, \ldots, 19\}$ indexa las localidades urbanas de Bogotá (excluyendo Sumapaz por su carácter 100 % rural de páramo).

2.2. Carga y estadísticas descriptivas del panel delictivo

A continuación, importamos el panel anual de delitos y población de las 19 localidades urbanas para el periodo 2022–septiembre de 2026 ($N = 95$ observaciones localidad-año, con corte a septiembre para el año 2026) y resumimos los momentos centrales y de dispersión de las cuatro tasas delictivas.

```
# Lectura de los archivos Parquet del panel delictivo y del corpus de noticias
panel_delitos <- read_parquet(archivo_delitos_p)
noticias_df   <- read_parquet(archivo_noticias_p)

# Construcción de tabla resumen con media, desviación estándar, mediana y valores extremos
resumen_tasas <- tibble(
  modalidad = c(
    "Hurto a personas",
    "Hurto a residencias",
    "Hurto a motocicletas",
    "Tasa combinada total"
  ),
  media = c(
    mean(panel_delitos$tasa_hurto_personas),
    mean(panel_delitos$tasa_hurto_residencias),
    mean(panel_delitos$tasa_hurto_motos),
    mean(panel_delitos$tasa_hurto_total)
  ),
  desv_est = c(
    sd(panel_delitos$tasa_hurto_personas),
    sd(panel_delitos$tasa_hurto_residencias),
    sd(panel_delitos$tasa_hurto_motos),
    sd(panel_delitos$tasa_hurto_total)
  ),
  mediana = c(
    median(panel_delitos$tasa_hurto_personas),
    median(panel_delitos$tasa_hurto_residencias),
    median(panel_delitos$tasa_hurto_motos),
    median(panel_delitos$tasa_hurto_total)
```

```
  ),
  minimo = c(
    min(panel_delitos$tasa_hurto_personas),
    min(panel_delitos$tasa_hurto_residencias),
    min(panel_delitos$tasa_hurto_motos),
    min(panel_delitos$tasa_hurto_total)
  ),
  maximo = c(
    max(panel_delitos$tasa_hurto_personas),
    max(panel_delitos$tasa_hurto_residencias),
    max(panel_delitos$tasa_hurto_motos),
    max(panel_delitos$tasa_hurto_total)
  )
)

# Formateo de la tabla descriptiva para salida HTML
kable(
  resumen_tasas,
  digits    = 1,
  col.names = c("Modalidad Delictiva", "Media", "Desv. Est.", "Mediana", "Mínimo", "Máximo")
)
```

Tabla 1: Estadísticas descriptivas de tasas anuales de hurto por 100.000 habitantes en Bogotá (2022–septiembre de 2026)

Modalidad Delictiva	Media	Desv. Est.	Mediana	Mínimo	Máximo
Hurto a personas	2910.7	2905.0	1602.7	410.3	13348.3
Hurto a residencias	108.4	72.0	90.4	27.7	398.1
Hurto a motocicletas	68.2	43.2	60.0	11.4	291.2
Tasa combinada total	3087.3	2984.0	1758.9	490.8	13730.2

2.3. Ranking territorial de criminalidad promedio

Al promediar las tasas anuales durante el periodo 2022–septiembre de 2026 para cada localidad, se observa la fuerte concentración de denuncias por habitante residente en el corredor central y comercial de la ciudad (Los Mártires, La Candelaria, Chapinero, Santa Fe y Teusaquillo).

```
# Agrupación por localidad y cálculo de promedios multianuales ordenados de mayor a menor
ranking_localidades <- panel_delitos |>
  group_by(localidad) |>
  summarise(
    tasa_media_total = mean(tasa_hurto_total),
    tasa_media_pers  = mean(tasa_hurto_personas),
    poblacion_media  = mean(poblacion),
    .groups = "drop"
  ) |>
  arrange(desc(tasa_media_total))

# Gráfico de barras horizontales con etiquetas numéricas formateadas
ggplot(ranking_localidades, aes(x = reorder(localidad, tasa_media_total), y = tasa_media_total)) +
```

```
  geom_col(fill = "#1b365d", width = 0.72) +
  geom_text(
    aes(label = comma(round(tasa_media_total))),
    hjust = -0.15,
    size  = 3.2,
    color = "#333333"
  ) +
  coord_flip() +
  scale_y_continuous(labels = comma, expand = expansion(mult = c(0, 0.15))) +
  labs(
    title    = "Incidencia Relativa de Hurto por Localidad en Bogotá",
    subtitle = "Promedio anual de denuncias por cada 100.000 habitantes (2022-septiembre de 2026)",
    x        = NULL,
    y        = "Tasa anual combinada por 100.000 habitantes",
    caption  = "Fuente: Cálculos propios con base en SIEDCO (SDSCJ) y proyecciones poblacionales
    ↪  (SDS)."
  ) +
  theme_minimal(base_size = 11) +
  theme(
    panel.grid.minor   = element_blank(),
    panel.grid.major.y = element_blank(),
    plot.title         = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle      = element_text(size = 10, color = "grey30", margin = margin(b = 10))
  )
```

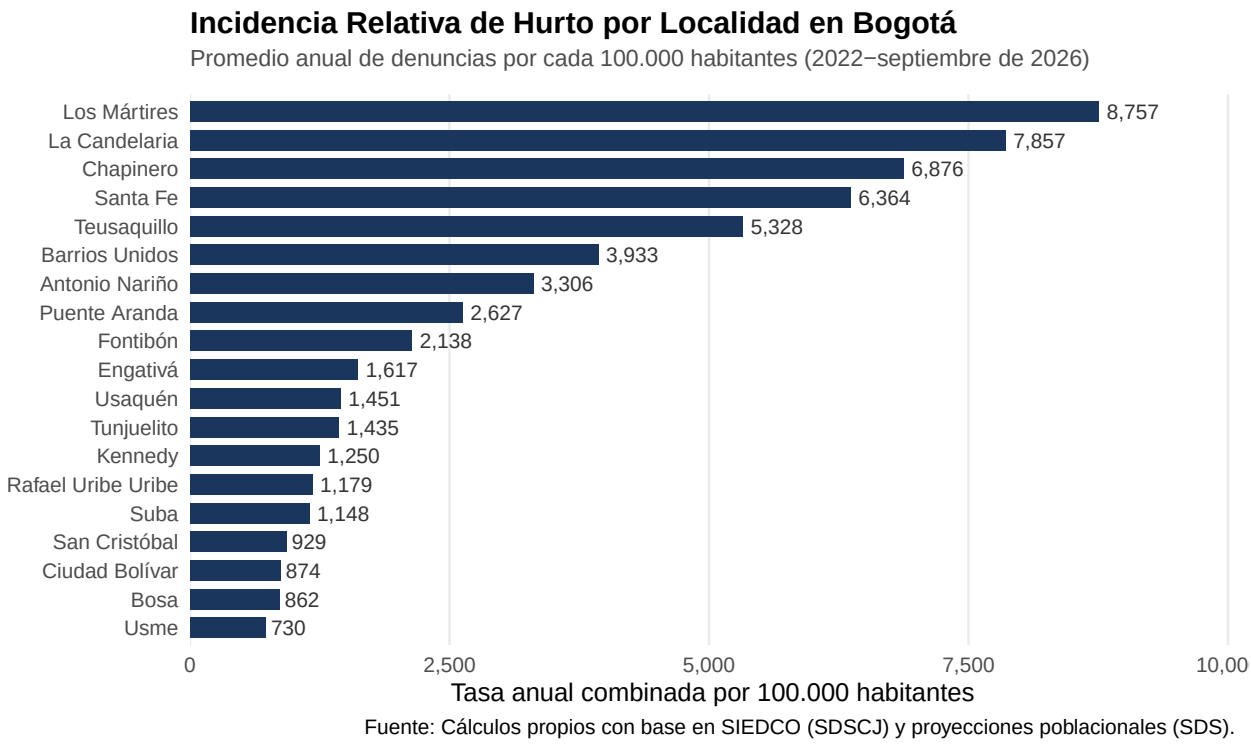


Figura 1: Tasa promedio anual de hurto total por cada 100.000 habitantes por localidad (2022–septiembre de 2026)

3. Agrupamiento Territorial de Criminalidad con K-Means

3.1. Fundamentos del algoritmo K-Means

El algoritmo K-**Means** (o *K-Medias*) es un método de aprendizaje automático **no supervisado** cuyo propósito es clasificar un conjunto de observaciones (en nuestro caso, las $N = 19$ localidades urbanas de Bogotá) en un número predeterminado K de grupos o **clústeres** ($C_1, C_2, \ldots, C_K$), sin partir de etiquetas previas.

La intuición del algoritmo responde a dos objetivos simultáneos:

1. **Máxima cohesión interna:** Que las localidades asignadas a un mismo clúster exhiban perfiles delictivos lo más parecidos posible entre sí.
2. **Máxima separación externa:** Que los distintos clústeres sean claramente diferenciables unos de otros.

En nuestra aplicación, cada localidad $i \in \{1, \ldots, 19\}$ está caracterizada por un vector tridimensional de tasas promedio anuales de hurto por cada 100.000 habitantes:

$$\mathbf{x}_i = (\text{Tasa Hurto Personas}_i,\ \text{Tasa Hurto Residencias}_i,\ \text{Tasa Hurto Motocicletas}_i) \in \mathbb{R}^3$$

3.1.1. Necesidad de estandarizar las variables (Z-score)

Antes de ejecutar K-Means es indispensable estandarizar cada variable. Como se observó en la Tabla 1, la tasa media de hurto a personas ($2.910,7$ por 100.000 hab.) es más de **26 veces mayor** que la de hurto a residencias ($108,4$) y más de **42 veces mayor** que la de hurto a motocicletas ($68,2$).

Dado que K-Means mide la similitud entre localidades mediante la **distancia euclidiana**, si introdujéramos las tasas en sus unidades originales, las diferencias de miles de puntos en el hurto a personas dominarían por completo la fórmula de distancia, volviendo irrelevante la información de hurto a residencias y a motocicletas. Para otorgar el mismo peso relativo a las tres modalidades delictivas, aplicamos la **estandarización Z-score** a cada variable $j \in \{1, 2, 3\}$:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j} \tag{2}$$

donde $\bar{X}_j$ es el promedio y s_j la desviación estándar de la modalidad j entre las 19 localidades. Tras esta transformación, las tres variables quedan expresadas en **desviaciones estándar respecto a la media de Bogotá** (con media 0 y varianza 1). Un valor $Z_{ij} = +2,0$ indica que la localidad i supera en dos desviaciones estándar el promedio distrital en la modalidad j.

3.1.2. Las cuatro etapas iterativas del algoritmo

Una vez proyectadas las 19 localidades en el espacio estandarizado $\mathbf{z}_i = (Z_{i,\text{pers}}, Z_{i,\text{resid}}, Z_{i,\text{motos}})$, el algoritmo de Hartigan-Wong busca minimizar la **Suma de Cuadrados Intra-Clúster** (*Within-Cluster Sum of Squares*, WSS), también denominada **inercia interna**:

$$\min_{C_1,\ldots,C_K} WSS(K) = \sum_{k=1}^{K} \sum_{i \in C_k} \|\mathbf{z}_i - \boldsymbol{\mu}_k\|_2^2 = \sum_{k=1}^{K} \sum_{i \in C_k} \sum_{j=1}^{3} (Z_{ij} - \mu_{kj})^2 \tag{3}$$

donde $\boldsymbol{\mu}_k = (\mu_{k,1}, \mu_{k,2}, \mu_{k,3})$ es el **centroide** (el punto promedio o "centro de gravedad") del clúster k. Para encontrar esta partición óptima, el algoritmo ejecuta cuatro pasos de forma iterativa:

1. **Inicialización de centroides:** Se eligen K puntos iniciales en el espacio tridimensional como centroides provisionales $\boldsymbol{\mu}_1^{(0)}, \ldots, \boldsymbol{\mu}_K^{(0)}$. Como una mala elección aleatoria inicial podría estancar el algoritmo en un óptimo local, configuramos `nstart = 50`: el computador repite todo el proceso desde **50 configuraciones iniciales aleatorias distintas** y conserva automáticamente la solución que logra la menor inercia interna (WSS).
2. **Paso de asignación:** Para cada una de las 19 localidades, se calcula su distancia euclidiana a cada uno de los K centroides:

$$d(\mathbf{z}_i, \boldsymbol{\mu}_k) = \sqrt{(Z_{i,\text{pers}} - \mu_{k,\text{pers}})^2 + (Z_{i,\text{resid}} - \mu_{k,\text{resid}})^2 + (Z_{i,\text{motos}} - \mu_{k,\text{motos}})^2}$$

   Cada localidad se asigna al clúster cuyo centroide se encuentre más cerca.
3. **Paso de actualización (recálculo de centroides):** Una vez formados los grupos provisionales, se recalcula la posición de cada centroide $\boldsymbol{\mu}_k$ como el promedio aritmético exacto de las coordenadas de todas las localidades que quedaron dentro de ese grupo:

$$\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{i \in C_k} \mathbf{z}_i$$

4. **Criterio de convergencia:** Los pasos 2 y 3 se repiten sucesivamente. Si al actualizar los centroides alguna localidad cambia de grupo, los centros de gravedad vuelven a moverse ligeramente. El algoritmo se detiene cuando ninguna localidad cambia de clúster entre una iteración y la siguiente, garantizando que la partición ha convergido.

3.2. Selección del número óptimo de clústeres (K^*)

Como el investigador debe especificar de antemano el número de grupos K, necesitamos un criterio objetivo para decidir si Bogotá se segmenta mejor en $K = 2, 3, 4$ o 5 perfiles territoriales. Para ello combinamos dos indicadores complementarios:

- **Proporción de varianza explicada (BSS/TSS):** La variabilidad total de los datos (TSS) se descompone en la dispersión interna dentro de los grupos (WSS) más la dispersión entre grupos distintos (BSS, *Between-Cluster Sum of Squares*). El cociente $BSS/TSS = 1 - (WSS/TSS)$ mide qué porcentaje de la heterogeneidad delictiva de Bogotá logra ser capturada por los K perfiles.
- **Coeficiente de Ancho de Silueta (*Silhouette Width*):** Para cada localidad i, compara dos distancias:
  - $a(i)$: la distancia promedio entre la localidad i y todas las demás localidades **de su mismo clúster** (mide **cohesión interna**; valores pequeños son deseables).
  - $b(i)$: la distancia promedio entre la localidad i y todas las localidades del **clúster vecino más cercano** al que i no pertenece (mide **separación externa**; valores grandes son deseables).

  Con estas dos magnitudes, el coeficiente de silueta de la localidad i se define como:

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1] \tag{4}$$

Un valor $S(i)$ cercano a $+1$ indica que la localidad está muy bien clasificada (muy cerca de su grupo y lejos de los demás); un valor cercano a 0 indica que se ubica en la frontera entre dos grupos; y un valor negativo indica una posible clasificación errónea. El **número óptimo de clústeres** K^* es aquel que maximiza la **silueta promedio** $\bar{S}(K) = \frac{1}{19} \sum_{i=1}^{19} S(i)$.

```r
# Carga de la tabla de clústeres generada por el pipeline de agrupamiento
df_clustering <- read_parquet(archivo_clusters_p)

# Extracción de las 3 tasas de hurto en una matriz numérica indexada por localidad
mat_clustering <- df_clustering |>
  select(tasa_personas_prom, tasa_resid_prom, tasa_motos_prom) |>
  as.matrix()
rownames(mat_clustering) <- df_clustering$localidad

# Normalización por columnas (media 0 y desviación estándar 1) y matriz de distancias
mat_escalada  <- scale(mat_clustering)
dist_euclidea <- dist(mat_escalada)

# Inicialización de la tabla donde se almacenarán las métricas para K = 2, 3, 4 y 5
diagnostico_k <- tibble(
  k             = 2:5,
  silueta_media = numeric(4),
  wss           = numeric(4),
  bss_tss_pct   = numeric(4)
)

# Bucle de evaluación de kmeans() con 50 arranques aleatorios para cada valor candidato de K
for (i in seq_along(2:5)) {
  k_val <- (2:5)[i]
  set.seed(20261014)
  km_temp  <- kmeans(mat_escalada, centers = k_val, nstart = 50)
  sil_temp <- silhouette(km_temp$cluster, dist_euclidea)
  diagnostico_k$silueta_media[i] <- mean(sil_temp[, 3])
  diagnostico_k$wss[i]           <- km_temp$tot.withinss
  diagnostico_k$bss_tss_pct[i]   <- (km_temp$betweenss / km_temp$totss) * 100
}

# Impresión de la tabla comparativa de métricas de validación interna
kable(
  diagnostico_k,
  digits    = c(0, 4, 2, 2),
  col.names = c(
    "Número de Clústeres (K)",
    "Silueta Promedio",
    "WSS (Inercia Interna)",
    "Varianza Explicada (BSS/TSS %)"
  )
)
```

Tabla 2: Diagnóstico del número óptimo de agrupamientos K mediante coeficiente de silueta e inercia intra-clúster

Número de Clústeres (K)	Silueta Promedio	WSS (Inercia Interna)	Varianza Explicada (BSS/TSS %)
2	0.5153	23.31	56.82
3	0.5416	13.58	74.85
4	0.4786	8.15	84.90

Tabla 2: Diagnóstico del número óptimo de agrupamientos K mediante coeficiente de silueta e inercia intra-clúster

Número de Clústeres (K)	Silueta Promedio	WSS (Inercia Interna)	Varianza Explicada (BSS/TSS %)
5	0.3792	5.90	89.07

Como reporta la Tabla 2 y se visualiza en la Figura 2, el coeficiente de silueta promedio alcanza su **máximo global en** $K^* = 3$ **(**$\bar{S} = 0,5416$**)**, reduciendo la inercia interna (WSS) de $54,00$ a $13,58$ y explicando el $74,85\,\%$ **de la varianza tridimensional** del hurto en Bogotá.

```
# Gráfico de línea del coeficiente de silueta con línea vertical de referencia en K* = 3
ggplot(diagnostico_k, aes(x = k, y = silueta_media)) +
  geom_line(color = "#2980b9", linewidth = 1) +
  geom_point(color = "#2980b9", size = 3.5) +
  geom_vline(xintercept = 3, linetype = "dashed", color = "#c0392b") +
  annotate(
    "text", x = 3.12, y = 0.535,
    label = "Óptimo global:\nK* = 3 (0.5416)",
    hjust = 0, color = "#c0392b", fontface = "bold", size = 3.4
  ) +
  scale_x_continuous(breaks = 2:5) +
  labs(
    title    = "Determinación del Número Óptimo de Clústeres",
    subtitle = "Máximo global alcanzado en K* = 3 con una silueta promedio de 0.5416",
    x        = "Número de Clústeres (K)",
    y        = "Coeficiente de Silueta Promedio"
  ) +
  theme_minimal(base_size = 11)
```

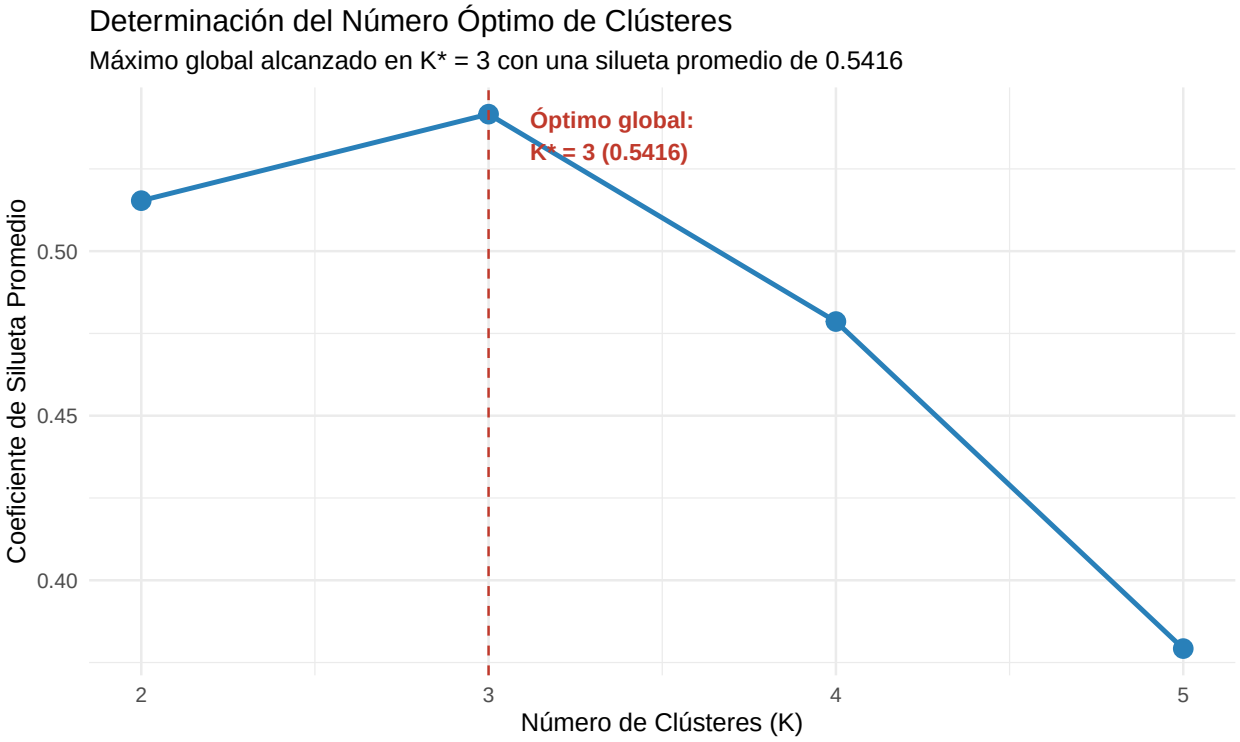


Figura 2: Coeficiente de silueta promedio para K entre 2 y 5 (óptimo global en K* = 3)

3.3. Caracterización de perfiles delictivos ($K^* = 3$)

Dado que el algoritmo K-Means asigna números enteros arbitrarios $(1, 2, 3)$ a cada grupo según el azar de los puntos iniciales, en el script de modelado identificamos cada perfil de forma determinística evaluando la posición económica de sus **centroides**:

- **Clúster 1 — Céntrico e Institucional ($n = 5$ localidades):** Agrupa a **La Candelaria, Chapinero, Santa Fe, Teusaquillo y Barrios Unidos**. Su centroide presenta las mayores tasas medias de hurto a personas ($5.834,7$ por 100.000 hab.) y de hurto a residencias ($175,9$ por 100.000 hab.). Corresponde al corredor central, financiero, universitario e institucional de Bogotá, donde una población residente reducida convive con millones de visitantes y trabajadores diarios (población flotante).
- **Clúster 2 — Comercial y Automotor ($n = 2$ localidades):** Compuesto por **Los Mártires y Antonio Nariño**. Su centroide registra el valor extremo en **hurto a motocicletas** ($153,0$ por 100.000 hab., más del doble que cualquier otro grupo), acompañado de una alta tasa de hurto a personas ($5.727,9$) y residencias ($150,9$). Captura la dinámica de zonas de comercio mayorista, talleres mecánicos y venta de autopartes.
- **Clúster 3 — Residencial y Periférico ($n = 12$ localidades):** Reúne a **Puente Aranda, Fontibón, Engativá, Usaquén, Tunjuelito, Kennedy, Rafael Uribe Uribe, Suba, San Cristóbal, Ciudad Bolívar, Bosa y Usme**. Su centroide exhibe tasas per cápita moderadas en las tres modalidades ($1.222,8$ en personas; $73,3$ en residencias; $57,1$ en motocicletas) debido a sus elevados denominadores demográficos de población residente.

```
# Cálculo de promedios de las tasas delictivas y listado de localidades por clúster
perfiles_resumen <- df_clustering |>
  group_by(cluster_id, cluster_nombre) |>
```

```
  summarise(
    num_localidades        = n(),
    tasa_media_personas    = mean(tasa_personas_prom),
    tasa_media_residencias = mean(tasa_resid_prom),
    tasa_media_motos       = mean(tasa_motos_prom),
    tasa_media_total       = mean(tasa_total_prom),
    localidades_miembros   = paste(localidad, collapse = ", "),
    .groups = "drop"
  ) |>
  arrange(cluster_id)

# Renderizado de la tabla resumen de centroides en unidades originales
kable(
  perfiles_resumen |> select(-cluster_id),
  digits    = 1,
  col.names = c(
    "Perfil Territorial", "N° Localidades", "Hurto Personas",
    "Hurto Residencias", "Hurto Motos", "Tasa Total", "Localidades Miembro"
  )
)
```

Tabla 3: Perfiles delictivos promedio por clúster territorial (Tasas anuales por 100.000 habitantes)

Perfil Territorial	N° Localidades	Hurto Personas	Hurto Residencias	Hurto Motos	Tasa Total	Localidades Miembro
Céntrico e Institucional	5	5834.7	175.9	60.8	6071.4	La Candelaria, Chapinero, Santa Fe, Teusaquillo, Barrios Unidos
Comercial y Automotor	2	5727.9	150.9	153.0	6031.8	Los Mártires, Antonio Nariño
Residencial y Periférico	12	1222.8	73.3	57.1	1353.2	Puente Aranda, Fontibón, Engativá, Usaquén, Tunjuelito, Kennedy, Rafael Uribe Uribe, Suba, San Cristóbal, Ciudad Bolívar, Bosa, Usme

3.4. Visualización tridimensional y bidimensional de los clústeres

Dado que el modelo K-Means opera en el espacio de **tres dimensiones** (Hurto Personas, Hurto Residencias, Hurto Motocicletas) la forma más fiel de inspeccionar la partición geométrica es mediante un **cubo interactivo tridimensional** (Figura 3), donde los círculos representan las 19 localidades y los diamantes representan el centro de gravedad (centroide $\boldsymbol{\mu}_k$) de cada clúster. Adicionalmente, la Figura 4 presenta la proyección bidimensional estática codificando la tercera dimensión mediante el tamaño de cada punto.

```
# Cálculo de las coordenadas promedio (centroides) de cada clúster en las 3 dimensiones
centroides_3d <- df_clustering |>
  group_by(cluster_nombre) |>
  summarise(
```

```
    centro_pers  = mean(tasa_personas_prom),
    centro_resid = mean(tasa_resid_prom),
    centro_motos = mean(tasa_motos_prom),
    .groups = "drop"
  )

# Unión de cada localidad con las coordenadas del centroide de su respectivo clúster
df_plot_3d <- df_clustering |>
  left_join(centroides_3d, by = "cluster_nombre") |>
  mutate(
    tooltip_localidad = paste0(
      "<b>", localidad, "</b><br>",
      "Clúster: ", cluster_nombre, "<br>",
      "Hurto Personas: ", comma(round(tasa_personas_prom, 1)), " por 100k hab.<br>",
      "Hurto Residencias: ", comma(round(tasa_resid_prom, 1)), " por 100k hab.<br>",
      "Hurto Motos: ", comma(round(tasa_motos_prom, 1)), " por 100k hab.<br>",
      "Silueta S(i): ", round(silueta_localidad, 3)
    )
  )

# Construcción de segmentos 3D (radios) que conectan cada localidad con su centroide
segmentos_3d <- bind_rows(
  lapply(seq_len(nrow(df_plot_3d)), function(i) {
    fila <- df_plot_3d[i, ]
    tibble(
      x = c(fila$tasa_personas_prom, fila$centro_pers, NA_real_),
      y = c(fila$tasa_resid_prom,    fila$centro_resid, NA_real_),
      z = c(fila$tasa_motos_prom,    fila$centro_motos, NA_real_),
      cluster_nombre = fila$cluster_nombre
    )
  })
)

# Paleta de colores institucional asignada a cada perfil territorial
colores_clusters <- c(
  "Céntrico e Institucional" = "#c0392b",
  "Comercial y Automotor"    = "#e67e22",
  "Residencial y Periférico" = "#27ae60"
)

# Construcción del cubo 3D: interactivo en HTML (plotly) y proyección perspectiva en PDF
if (is_html_output()) {
  plot_ly() |>
    add_trace(
      data       = df_plot_3d,
      x          = ~tasa_personas_prom,
      y          = ~tasa_resid_prom,
      z          = ~tasa_motos_prom,
      color      = ~cluster_nombre,
      colors     = colores_clusters,
      text       = ~localidad,
      hovertext  = ~tooltip_localidad,
```

```
    hoverinfo  = "text",
    type       = "scatter3d",
    mode       = "markers",
    textposition = "top center",
    textfont   = list(size = 9, color = "#2c3e50"),
    marker     = list(
      size    = 7,
      opacity = 0.92,
      line    = list(color = "white", width = 1.2)
    )
  ) |>
  add_trace(
    data       = segmentos_3d,
    x          = ~x,
    y          = ~y,
    z          = ~z,
    color      = ~cluster_nombre,
    colors     = colores_clusters,
    type       = "scatter3d",
    mode       = "lines",
    line       = list(width = 2, dash = "solid"),
    opacity    = 0.35,
    hoverinfo  = "none",
    showlegend = FALSE
  ) |>
  add_trace(
    data      = centroides_3d,
    x         = ~centro_pers,
    y         = ~centro_resid,
    z         = ~centro_motos,
    color     = ~cluster_nombre,
    colors    = colores_clusters,
    hovertext = ~paste0(
      "<b>⋆ Centroide: ", cluster_nombre, "</b><br>",
      "Media Personas: ", comma(round(centro_pers, 1)), " por 100k hab.<br>",
      "Media Residencias: ", comma(round(centro_resid, 1)), " por 100k hab.<br>",
      "Media Motos: ", comma(round(centro_motos, 1)), " por 100k hab."
    ),
    hoverinfo  = "text",
    type       = "scatter3d",
    mode       = "markers",
    showlegend = FALSE,
    marker     = list(
      size   = 11,
      symbol = "diamond",
      line   = list(color = "#1a1a1a", width = 2)
    )
  ) |>
  layout(
    title = list(
      text    = "<b>Espacio Tridimensional de Clústeres K-Means (K* = 3)</b><br><sup>Esferas: 19
      ↪  localidades | Diamantes: Centroides μ_k (pase el cursor para detalles)</sup>",
```

```
      x       = 0.5,
      xanchor = "center",
      y       = 0.98,
      font    = list(size = 13)
    ),
    margin = list(l = 10, r = 10, b = 25, t = 75),
    scene = list(
      aspectmode = "cube",
      xaxis = list(
        title          = list(text = "Hurto Personas (tasa/100k)", font = list(size = 11)),
        tickfont       = list(size = 9),
        showbackground = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor      = "#ffffff",
        zerolinecolor  = "#dcdde1"
      ),
      yaxis = list(
        title          = list(text = "Hurto Residencias (tasa/100k)", font = list(size = 11)),
        tickfont       = list(size = 9),
        showbackground = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor      = "#ffffff",
        zerolinecolor  = "#dcdde1"
      ),
      zaxis = list(
        title          = list(text = "Hurto Motos (tasa/100k)", font = list(size = 11)),
        tickfont       = list(size = 9),
        showbackground = TRUE,
        backgroundcolor = "#f4f6f9",
        gridcolor      = "#ffffff",
        zerolinecolor  = "#dcdde1"
      ),
      camera = list(eye = list(x = 1.45, y = -1.45, z = 0.75))
    ),
    updatemenus = list(
      list(
        type        = "buttons",
        direction   = "right",
        x           = 0.5,
        xanchor     = "center",
        y           = -0.06,
        bgcolor     = "#ffffff",
        bordercolor = "#cccccc",
        font        = list(size = 10),
        buttons     = list(
          list(
            method = "restyle",
            args   = list("mode", list("markers", "markers", "markers", "lines", "lines",
            ↪  "lines", "markers", "markers", "markers")),
            label  = "Ocultar nombres"
          ),
          list(
```

```
              method = "restyle",
              args   = list("mode", list("markers+text", "markers+text", "markers+text", "lines",
              ↪  "lines", "lines", "markers", "markers", "markers")),
              label  = "Mostrar nombres"
            )
          )
        )
      ),
      legend = list(orientation = "h", x = 0.5, xanchor = "center", y = -0.16)
    )
} else {
  # Proyección tridimensional estática para compilación en PDF
  par(mar = c(3.2, 2, 2.5, 2), xpd = TRUE)
  rango_x <- range(df_plot_3d$tasa_personas_prom) * c(0.9, 1.08)
  rango_y <- range(df_plot_3d$tasa_resid_prom)    * c(0.9, 1.08)
  rango_z <- range(df_plot_3d$tasa_motos_prom)    * c(0.9, 1.08)

  matriz_3d <- persp(
    x        = rango_x,
    y        = rango_y,
    z        = matrix(rango_z[1], nrow = 2, ncol = 2),
    zlim     = rango_z,
    theta    = -38,
    phi      = 22,
    expand   = 0.75,
    col      = "#f4f6f9",
    border   = "#bdc3c7",
    ticktype = "detailed",
    nticks   = 4,
    xlab     = "Hurto Personas (tasa/100k)",
    ylab     = "Hurto Residencias (tasa/100k)",
    zlab     = "Hurto Motos (tasa/100k)",
    main     = "Espacio Tridimensional de Clústeres K-Means (K* = 3)"
  )

  # Dibujo de radios hacia los centroides
  for (i in seq_len(nrow(df_plot_3d))) {
    seg_proj <- trans3d(
      x = c(df_plot_3d$tasa_personas_prom[i], df_plot_3d$centro_pers[i]),
      y = c(df_plot_3d$tasa_resid_prom[i],    df_plot_3d$centro_resid[i]),
      z = c(df_plot_3d$tasa_motos_prom[i],    df_plot_3d$centro_motos[i]),
      pmat = matriz_3d
    )
    lines(seg_proj, col = colores_clusters[df_plot_3d$cluster_nombre[i]], lwd = 1.1)
  }

  # Dibujo de las 19 localidades y los 3 centroides
  pts_loc <- trans3d(
    df_plot_3d$tasa_personas_prom,
    df_plot_3d$tasa_resid_prom,
    df_plot_3d$tasa_motos_prom,
    pmat = matriz_3d
```

```
  )
  points(
    pts_loc,
    pch = 21,
    bg  = colores_clusters[df_plot_3d$cluster_nombre],
    col = "white",
    cex = 1.5
  )

  pts_cen <- trans3d(
    centroides_3d$centro_pers,
    centroides_3d$centro_resid,
    centroides_3d$centro_motos,
    pmat = matriz_3d
  )
  points(
    pts_cen,
    pch = 23,
    bg  = colores_clusters[centroides_3d$cluster_nombre],
    col = "black",
    cex = 2.2,
    lwd = 1.5
  )
  legend(
    "bottom",
    inset  = -0.10,
    legend = names(colores_clusters),
    pt.bg  = colores_clusters,
    pch    = 21,
    horiz  = TRUE,
    bty    = "n",
    cex    = 0.85
  )
}
```

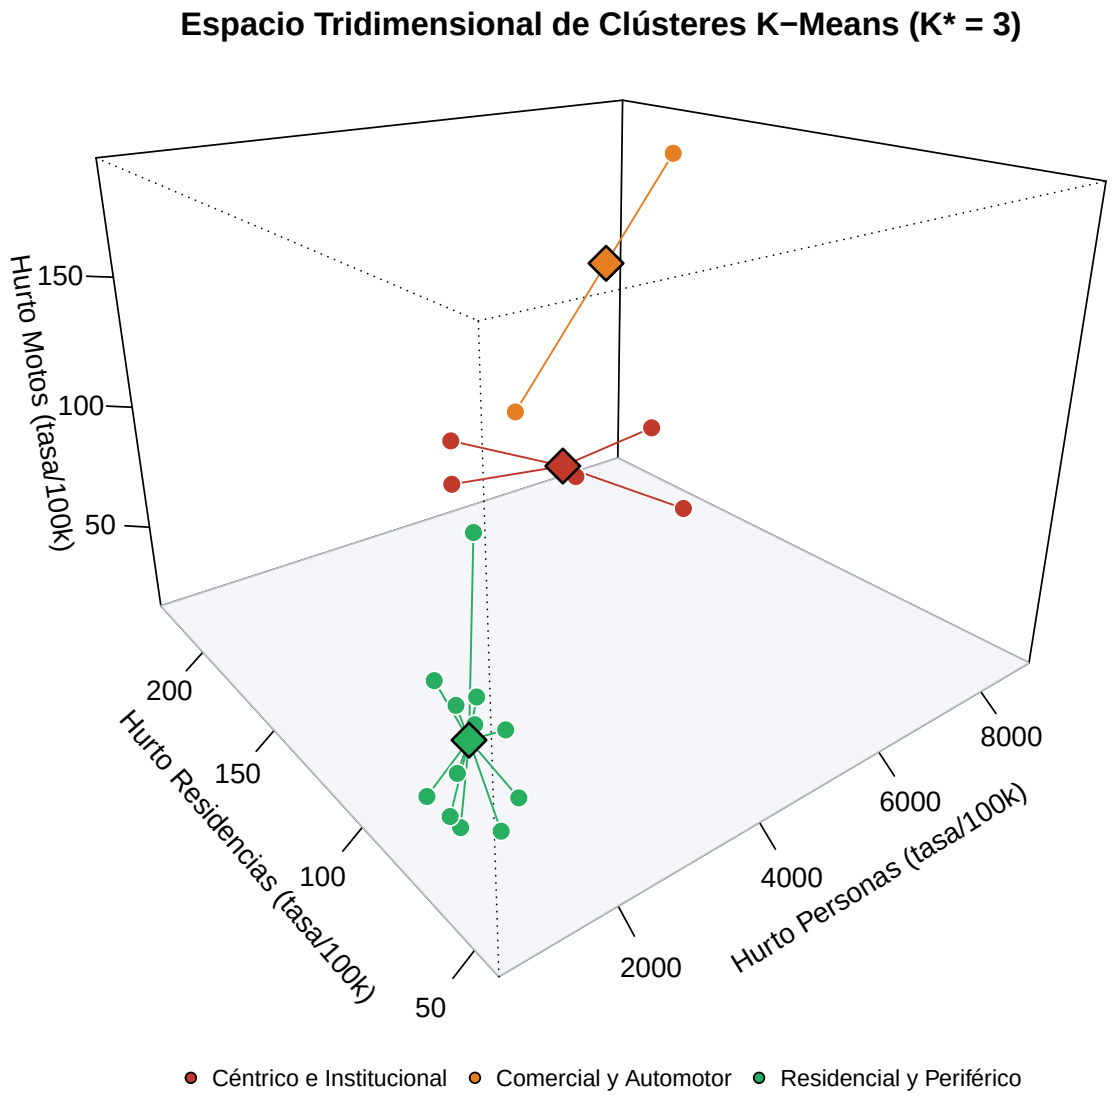


Figura 3: Representación tridimensional interactiva de las 19 localidades, sus radios de pertenencia y los 3 centroides de K-Means

```
# Gráfico de dispersión 2D con tamaño proporcional a la tasa de hurto a residencias
ggplot(
  df_clustering,
  aes(
    x     = tasa_personas_prom,
    y     = tasa_motos_prom,
    color = cluster_nombre,
    size  = tasa_resid_prom
  )
) +
  geom_point(alpha = 0.88) +
  geom_text_repel(
    aes(label = localidad),
```

```
  size          = 3.2,
  fontface      = "bold",
  box.padding   = 0.4,
  point.padding = 0.3,
  max.overlaps  = 20,
  show.legend   = FALSE
) +
scale_color_manual(values = colores_clusters) +
scale_size_continuous(range = c(3, 8.5), name = "Hurto Residencias\n(por 100.000 hab.)") +
scale_x_continuous(labels = comma) +
scale_y_continuous(labels = comma) +
labs(
  title    = "Tipología Territorial del Hurto en Bogotá",
  subtitle = "Agrupamiento no supervisado con K-Means (K* = 3)",
  x        = "Tasa promedio de hurto a personas (por 100.000 hab.)",
  y        = "Tasa promedio de hurto a motocicletas (por 100.000 hab.)",
  color    = "Clúster Territorial"
) +
theme_minimal(base_size = 11) +
theme(legend.position = "bottom", plot.title = element_text(face = "bold", size = 13))
```

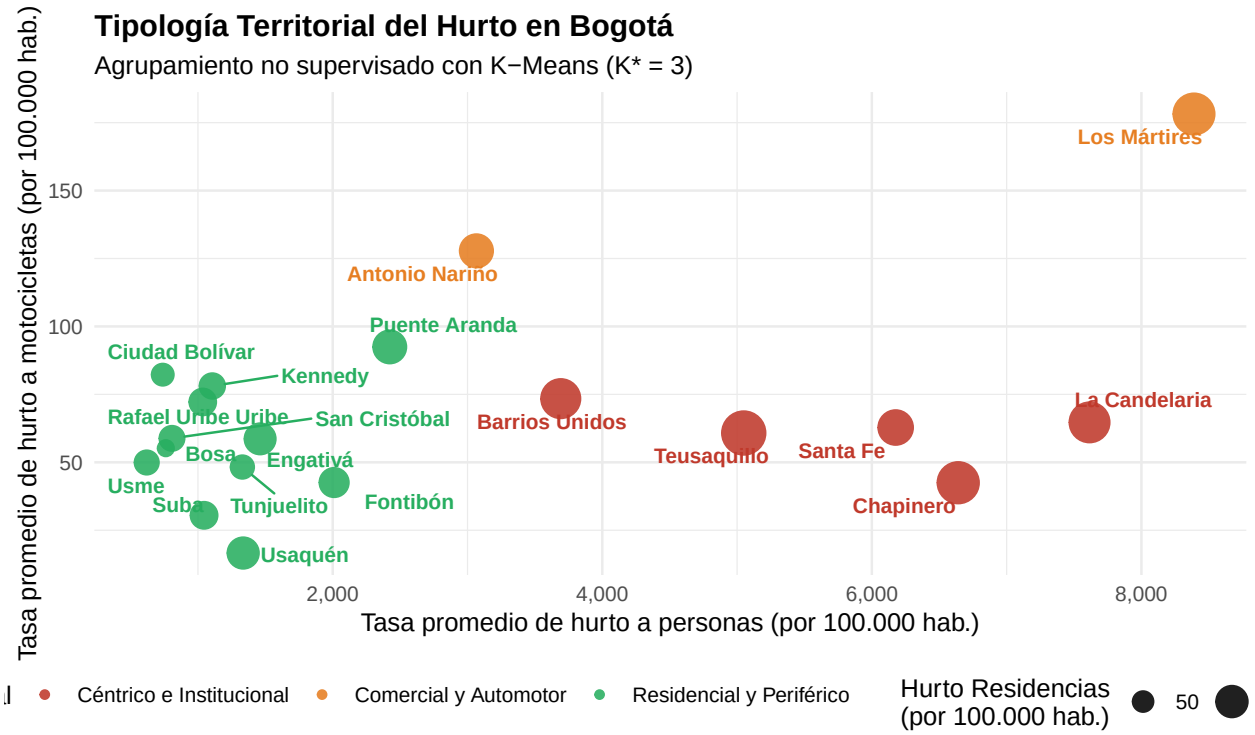


Figura 4: Proyección bidimensional de las 19 localidades en el espacio de tasas de hurto (el tamaño del punto representa el hurto a residencias)

4. Análisis Cuantitativo de Sentimiento con `sentometrics`

4.1. Formulación matemática de la agregación tridimensional (ω, θ, b)

Siguiendo a Ardia et al. (2021), el paquete `sentometrics` estructura la medición de sentimiento textual en tres niveles de ponderación:

1. **Nivel intra-documento ($\omega_{i,j}$) y modificadores de valencia (`valenceIn`):** Para cada documento i publicado en la fecha t, el puntaje en el léxico $\ell \in \{\text{nrc_es}, \text{crimen_es}\}$ multiplicado por la característica $k \in \{1, \ldots, 26\}$ se normaliza por el total de palabras con carga polar (`howWithin = "proportionalPol"`), incorporando negadores ($t = 1$), amplificadores ($t = 2$), atenuadores ($t = 3$) y conectores adversativos ($t = 4$):

$$s_{i,t}^{(\ell,k)} = f_{i,k} \cdot \frac{\sum_{w \in d_i} v_w \cdot m_w^{(\ell)}}{N_{\text{pol}}(d_i)} \tag{5}$$

2. **Nivel entre documentos ($\theta_{i,t}$):** Dentro de cada mes t, las noticias con polaridad no nula (`do.ignoreZeros = TRUE`) se ponderan proporcionalmente a su extensión léxica (`howDocs = "proportional"`).
3. **Nivel temporal ($b_j^{(\tau)}$):** Las series mensuales se suavizan en una ventana móvil retrospectiva de $L = 6$ meses mediante esquemas lineales, exponenciales ($\alpha \in \{0.2, 0.5\}$) y curvas Beta ($a \in \{1, 2\}, b \in \{2, 3\}$):

$$S_t^{(\ell,k,\tau)} = \sum_{j=0}^{L-1} b_j^{(\tau)} \left(\sum_{i=1}^{D_{t-j}} \theta_{i,t-j} \, s_{i,t-j}^{(\ell,k)} \right) \tag{6}$$

4.2. Carga y verificación de los artefactos `.rds` del pipeline (Tareas `T-07` a `T-15`)

```
# 4.1 Lectura de los objetos S3 generados por scripts/03_analisis_sentometrics.R ----
corpus_sento      <- readRDS(file.path(ruta_proc, "01_sento_corpus.rds"))
lexicons_es       <- readRDS(file.path(ruta_proc, "02_lexicons_es.rds"))
sentiment_scores  <- readRDS(file.path(ruta_proc, "03_sentiment_scores.rds"))
peak_docs_obj     <- readRDS(file.path(ruta_proc, "04_peak_docs.rds"))
medidas_sento     <- readRDS(file.path(ruta_proc, "05_sento_measures.rds"))
measures_long_obj <- readRDS(file.path(ruta_proc, "06_measures_long.rds"))
global_index_obj  <- readRDS(file.path(ruta_proc, "07_global_index.rds"))
attributions_obj  <- readRDS(file.path(ruta_proc, "08_attributions.rds"))

# Auditoría de clases S3
stopifnot(inherits(corpus_sento, "sento_corpus"))
stopifnot(inherits(lexicons_es, "sento_lexicons"))
stopifnot(inherits(sentiment_scores, "sentiment"))
stopifnot(inherits(medidas_sento, "sento_measures"))

medidas_sento
```

```
A sento_measures object (364 textual sentiment time series, 52 observations).
```

4.3. Diagnóstico de léxicos, ponderación documental y noticias pico (peakdocs)

```
# 4.2 Tabla de noticias críticas extraídas con peakdocs() ----
comp_metodo <- attr(sentiment_scores, "comparacion_metodologica")
cat(
  "Correlación entre proportionalPol y TFIDF:",
  round(comp_metodo$correlacion_propPol_tfidf, 4), "\n",
  "Media léxico general (nrc_es):", round(comp_metodo$media_nrc_es, 4), "\n",
  "Media léxico criminalidad (crimen_es):", round(comp_metodo$media_crimen_es, 4), "\n"
)
```

```
Correlación entre proportionalPol y TFIDF: 0.7383
 Media léxico general (nrc_es): -0.0859
 Media léxico criminalidad (crimen_es): -0.3063
```

```
muestra_picos <- as_tibble(peak_docs_obj$top_criticas) |>
  filter(es_pico_global) |>
  slice_head(n = 8) |>
  transmute(
    Fecha     = as.character(fecha),
    Localidad = localidad,
    Delito    = delito_sdscj,
    Titular   = str_trunc(titulo, 65),
    Score     = round(sentimiento_score, 3),
    Tipo      = tipo_pico
  )

knitr::kable(
  muestra_picos,
  col.names = c("Fecha", "Localidad", "Modalidad SDSCJ", "Titular", "Score Neto", "Clasificación")
)
```

Tabla 4: Muestra de las noticias con polaridad más extrema detectadas mediante peakdocs() (T-11)

Fecha	Localidad	Modalidad SDSCJ	Titular	Score Neto	Clasificación
2023-09-01	Usaquén	Homicidio	Hombre murió tras ataque a disparos en un billar de Usaquén	-1.087	Pico Negativo Global
2022-12-01	Bosa	Homicidio	A la cárcel 22 integrantes de la banda multicrimen 'Los Camilo...	-0.933	Pico Negativo Global
2026-05-06	Los Mártires	Hurto a comercio	Video captó violento robo en un D1 de Bogotá: criminales desat...	-0.917	Pico Negativo Global
2023-11-07	Antonio Nariño	Hurto a personas	Violento asalto a mano armada a un restaurante en Bogotá: un d...	-0.900	Pico Negativo Global

Tabla 4: Muestra de las noticias con polaridad más extrema detectadas mediante peakdocs() (T-11)

Fecha	Localidad	Modalidad SDSCJ	Titular	Score Neto	Clasificación
2026-04-01	Antonio Nariño	Hurto a comercio	Comensales frustraron violento asalto en un restaurante de Bog...	-0.900	Pico Negativo Global
2026-04-17	Barrios Unidos	Hurto (modalidad no identificada)	Capturan a dos extranjeros tras violento robo en Bogotá: perse...	-0.900	Pico Negativo Global
2026-08-03	Barrios Unidos	Hurto (modalidad no identificada)	En video: capturan a ladrón que tenía 19 anotaciones judiciale...	-0.900	Pico Negativo Global
2025-12-01	Chapinero	Hurto a comercio	Violento asalto a joyería en Chapinero: se llevaron $30 millon...	-0.900	Pico Negativo Global

4.4. Evolución mensual del sentimiento por clúster territorial e índice global (T-13 a T-16)

```
# 4.3 Series mensuales por clúster territorial (léxico crimen_es, exponential0.5) ----
df_series_cluster <- as_tibble(measures_long_obj$long) |>
  filter(
    grupo_feature == "Clúster Territorial",
    lexicon       == "crimen_es",
    time          == "exponential0.5"
  ) |>
  mutate(
    cluster_limpio = str_remove(feature_label, "^Clúster: ")
  )

ggplot(df_series_cluster, aes(x = date, y = valor, color = cluster_limpio)) +
  geom_hline(yintercept = 0, linetype = "dotted", color = "gray50") +
  geom_vline(
    xintercept = as.numeric(global_index_obj$peakdates_neg),
    linetype   = "dashed",
    color      = "#c0392b",
    alpha      = 0.3
  ) +
  geom_line(linewidth = 0.95) +
  scale_color_manual(
    values = c(
      "Céntrico e Institucional" = "#c0392b",
      "Comercial y Automotor"    = "#e67e22",
      "Residencial y Periférico" = "#27ae60"
    )
  ) +
  scale_x_date(date_breaks = "6 months", date_labels = "%b %Y") +
  labs(
```

```
  title    = "Sentimiento Mediático sobre Seguridad por Clúster Territorial en Bogotá",
  subtitle = "Léxico crimen_es con decaimiento exponencial (alpha = 0.5, lag = 6m) y fechas
  ↪  críticas (peakdates)",
  x        = "Fecha de agregación mensual",
  y        = "Índice de Sentimiento Ponderado",
  color    = "Clúster Territorial"
) +
theme_minimal(base_size = 11) +
theme(
  legend.position = "bottom",
  plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
  plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
)
```

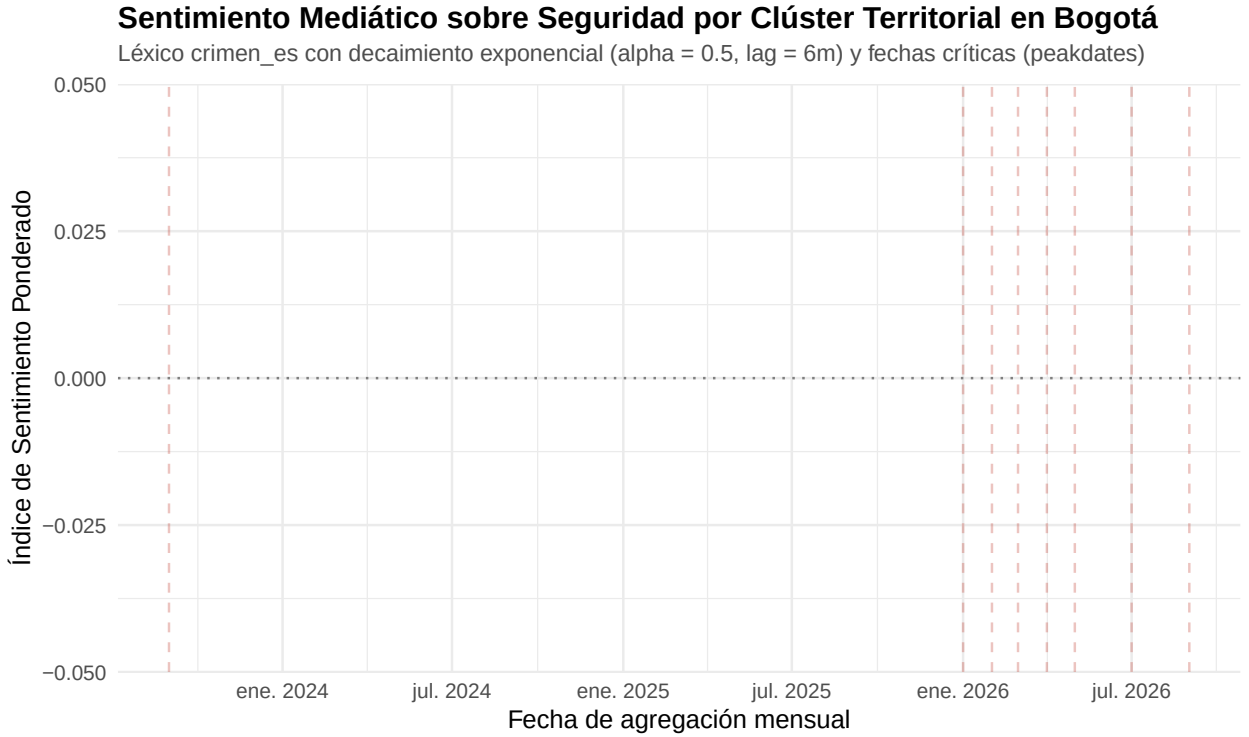


Figura 5: Evolución mensual del sentimiento mediático sobre criminalidad por clúster territorial (2022–2026)

---

5. Modelado Econométrico Supervisado (Elastic Net) y Atribuciones

5.1. Especificación del modelo regularizado (`sento_model`)

Para evaluar el poder predictivo de las $M = 364$ series de sentimiento sobre la evolución mensualizada de la tasa de hurtos (y_{t+1}, con horizonte $h = 1$ mes adelante), estimamos una regresión lineal regularizada con penalización mixta L_1/L_2 (Elastic Net) calibrada mediante el Criterio de Información Bayesiano (BIC):

$$\min_{\beta_0,\beta}\left\{\frac{1}{2N}\sum_{t=1}^{N}\left(y_{t+1}-\beta_0-\sum_{m=1}^{M}\beta_m S_{t,m}\right)^2+\lambda\left[\frac{1-\alpha}{2}\|\beta\|_2^2+\alpha\|\beta\|_1\right]\right\} \tag{7}$$

```
# 5.1 Resumen de ajuste del modelo Elastic Net (T-17) ----
modelo_sentometrics <- attributions_obj$modelo
metricas_mod        <- attributions_obj$metricas_modelo

cat(
  "Parámetro alpha óptimo:", metricas_mod$alpha_optimo, "\n",
  "Parámetro lambda óptimo:", round(metricas_mod$lambda_optimo, 4), "\n",
  "R^2 dentro de muestra (h = 1):", scales::percent(metricas_mod$r2_in_sample, accuracy = 0.01),
  ↪  "\n",
  "RMSE:", metricas_mod$rmse, "\n",
  "Series activas seleccionadas:", metricas_mod$n_activos, "de", metricas_mod$n_predictores, "\n"
)
```

```
Parámetro alpha óptimo: 0.2
 Parámetro lambda óptimo: 13.4649
 R^2 dentro de muestra (h = 1): 87.53%
 RMSE: 21.593
 Series activas seleccionadas: 46 de 364
```

```
# 5.2 Visualización del ajuste predictivo ----
df_aj <- attributions_obj$ajuste_temporal |>
  select(date, `Observada (y_t)` = observado, `Predicha Elastic Net (ŷ_t)` = predicho) |>
  pivot_longer(cols = -date, names_to = "serie", values_to = "valor")

ggplot(df_aj, aes(x = date, y = valor, color = serie, linetype = serie)) +
  geom_line(linewidth = 0.95) +
  scale_color_manual(
    values = c("Observada (y_t)" = "#1b365d", "Predicha Elastic Net (ŷ_t)" = "#c0392b")
  ) +
  scale_x_date(date_breaks = "6 months", date_labels = "%b %Y") +
  labs(
    title    = "Ajuste Predictivo del Modelo de Sentimiento Mediático (sento_model)",
    subtitle = paste0(
      "Regresión Elastic Net (alpha = ", metricas_mod$alpha_optimo,
      ", lambda = ", round(metricas_mod$lambda_optimo, 2),
      ", R^2 = ", scales::percent(metricas_mod$r2_in_sample, accuracy = 0.1), ")"
    ),
    x        = "Mes de pronóstico (h = 1)",
    y        = "Tasa mensualizada por 100.000 hab.",
    color    = NULL,
    linetype = NULL
  ) +
  theme_minimal(base_size = 11) +
  theme(
    legend.position = "bottom",
    plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
```

```
)
```

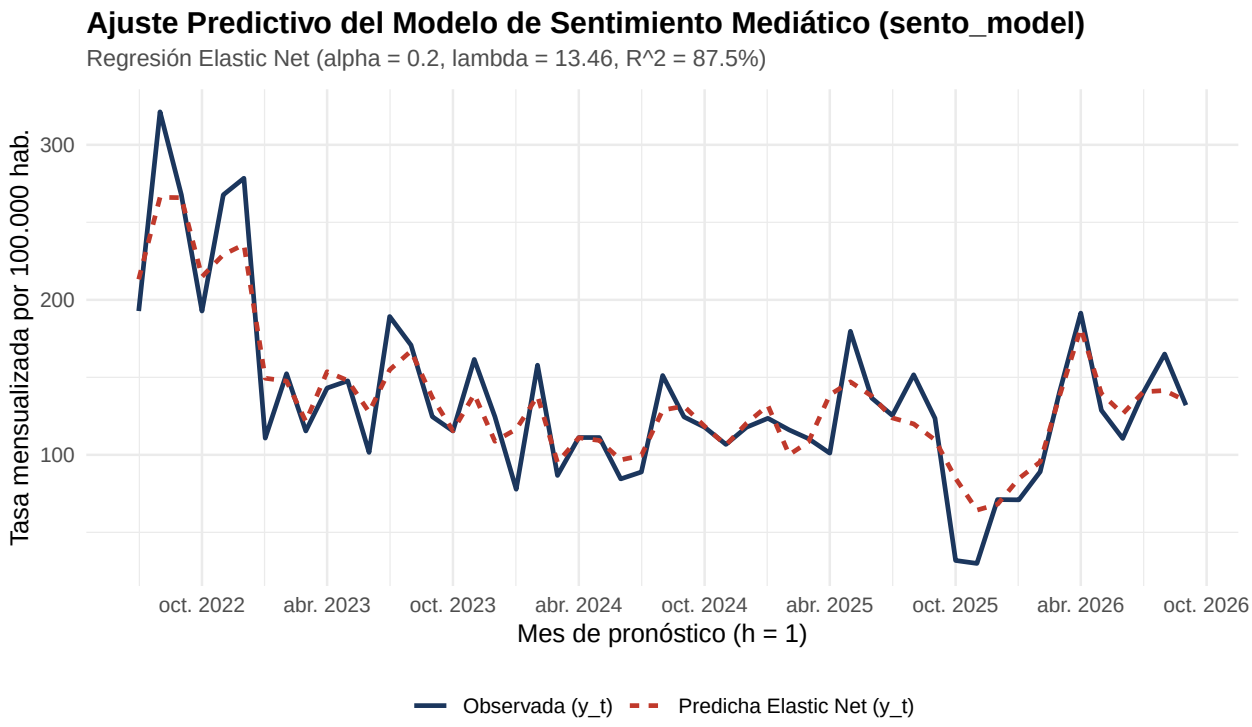


Figura 6: Comparación entre la tasa mensualizada de hurto observada y la predicción un paso adelante con Elastic Net

5.2. Descomposición de atribuciones marginales (`attributions`)

```
# 5.3 Gráfico de atribuciones por dimensión léxica ----
plot(attributions_obj$attributions_raw, group = "lexicons") +
  labs(
    title    = "Descomposición de Atribuciones por Diccionario Léxico (attributions)",
    subtitle = "Contribución marginal del léxico general (nrc_es) vs. criminalidad en Bogotá
    ↪  (crimen_es)",
    x        = "Fecha",
    y        = "Aporte marginal al pronóstico"
  ) +
  theme_minimal(base_size = 11) +
  theme(
    legend.position = "bottom",
    plot.title      = element_text(face = "bold", size = 13, margin = margin(b = 4)),
    plot.subtitle   = element_text(size = 10, color = "grey30", margin = margin(b = 8))
  )
```

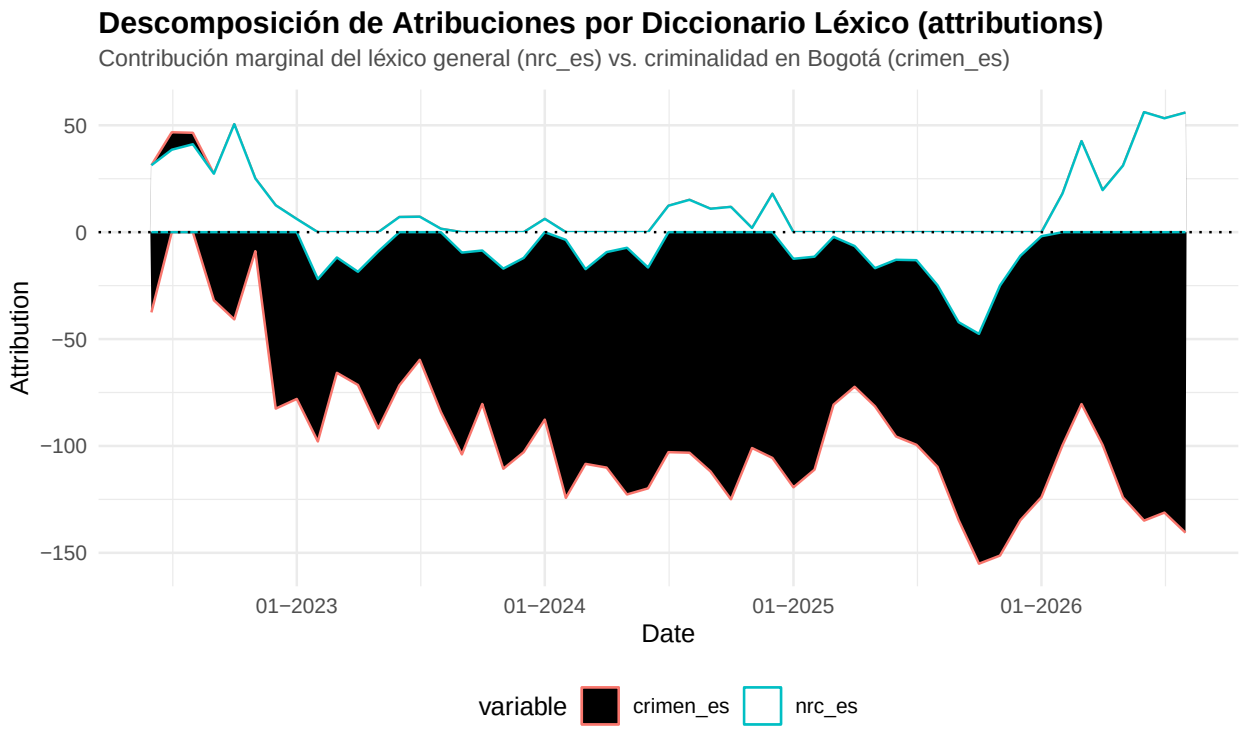


Figura 7: Descomposición temporal de atribuciones del modelo por diccionario léxico y esquema de memoria

---

6. Cartografía Espacial e Integración para R Shiny

La clasificación territorial obtenida mediante K-Means ofrece una síntesis de los perfiles de seguridad, pero clasificar las localidades en tres grupos discretos oculta la intensidad y la ubicación geográfica de los hechos delictivos. Para entender el patrón territorial de Bogotá, esta sección analiza la distribución espacial continua de cada modalidad de hurto y examina su correspondencia con la cobertura de los medios digitales de comunicación.

6.1. Geografía especializada del delito por modalidad

El cruce de la geometría vectorial oficial con el panel consolidado permite mapear las tasas anuales promedio de las tres modalidades de hurto estandarizadas por población.

```
# 6.1 Preparación de geometrías vectoriales (sf) y panel delictivo ----
geo_bogota <- sf::st_read(archivo_geo_raw, quiet = TRUE) |>
  mutate(codigo_localidad = sprintf("%02d", as.integer(CMIULOCAL))) |>
  filter(!codigo_localidad %in% c("20", "99")) |>
  left_join(df_clustering, by = "codigo_localidad")

# Función auxiliar para mapas temáticos con escala continua independiente y tooltips
generar_mapa_delito <- function(df, var_col, titulo, etiqueta_leyenda, paleta = "magma") {
  df$tooltip <- paste0(
    "<b>", df$localidad, "</b><br>",
```

```
    titulo, ": <b>", scales::comma(round(df[[var_col]], 1)), "</b> por 100k hab.<br>",
    "Clúster: ", df$cluster_nombre
  )

  ggplot(df) +
    geom_sf(aes(fill = .data[[var_col]], text = tooltip), color = "white", linewidth = 0.25) +
    scale_fill_viridis_c(
      option    = paleta,
      direction = -1,
      name      = etiqueta_leyenda,
      labels    = scales::comma
    ) +
    labs(title = titulo) +
    theme_void(base_size = 11) +
    theme(
      plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b =
      ↪  6)),
      legend.position = "right",
      legend.title    = element_text(size = 8.5, face = "bold"),
      legend.text     = element_text(size = 8),
      plot.margin     = margin(6, 6, 6, 6)
    )
}

# Función auxiliar para fijar posición y dimensiones del colorbar en subplots de Plotly
fijar_colorbar <- function(ply, x_pos, y_pos = 0.5, len_val = 0.65, thick = 14, titulo = NULL) {
  for (i in seq_along(ply$x$data)) {
    if (!is.null(ply$x$data[[i]]$marker$colorbar)) {
      ply$x$data[[i]]$marker$colorbar$x <- x_pos
      ply$x$data[[i]]$marker$colorbar$y <- y_pos
      ply$x$data[[i]]$marker$colorbar$len <- len_val
      ply$x$data[[i]]$marker$colorbar$thickness <- thick
      ply$x$data[[i]]$marker$colorbar$xanchor <- "left"
      ply$x$data[[i]]$marker$colorbar$yanchor <- "middle"
      if (!is.null(titulo)) {
        ply$x$data[[i]]$marker$colorbar$title <- titulo
      }
    }
  }
  ply
}

# Construcción de mapas individuales para garantizar contraste visual en cada escala
p_pers  <- generar_mapa_delito(geo_bogota, "tasa_personas_prom", "Hurto a Personas", "Tasa
↪  por\n100k hab.")
p_resid <- generar_mapa_delito(geo_bogota, "tasa_resid_prom", "Hurto a Residencias", "Tasa
↪  por\n100k hab.")
p_motos <- generar_mapa_delito(geo_bogota, "tasa_motos_prom", "Hurto de Motocicletas", "Tasa
↪  por\n100k hab.")
p_total <- generar_mapa_delito(geo_bogota, "tasa_total_prom", "Tasa Total de Hurtos", "Tasa
↪  por\n100k hab.")
```

```r
if (is_html_output()) {
  ply1 <- ggplotly(p_pers,  tooltip = "text")
  ply2 <- ggplotly(p_resid, tooltip = "text")
  ply3 <- ggplotly(p_motos, tooltip = "text")
  ply4 <- ggplotly(p_total, tooltip = "text")

  ply1 <- fijar_colorbar(ply1, x_pos = 0.44, y_pos = 0.77, len_val = 0.35, thick = 11, titulo =
↪  "Tasa / 100k")
  ply2 <- fijar_colorbar(ply2, x_pos = 1.00, y_pos = 0.77, len_val = 0.35, thick = 11, titulo =
↪  "Tasa / 100k")
  ply3 <- fijar_colorbar(ply3, x_pos = 0.44, y_pos = 0.22, len_val = 0.35, thick = 11, titulo =
↪  "Tasa / 100k")
  ply4 <- fijar_colorbar(ply4, x_pos = 1.00, y_pos = 0.22, len_val = 0.35, thick = 11, titulo =
↪  "Tasa / 100k")

  anotaciones_4 <- list(
    list(x = 0.20, y = 1.02, text = "<b>Hurto a Personas</b>", showarrow = FALSE, xref = "paper",
    ↪  yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.74, y = 1.02, text = "<b>Hurto a Residencias</b>", showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.20, y = 0.48, text = "<b>Hurto de Motocicletas</b>", showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11)),
    list(x = 0.74, y = 0.48, text = "<b>Tasa Total de Hurtos</b>", showarrow = FALSE, xref =
    ↪  "paper", yref = "paper", xanchor = "center", font = list(size = 11))
  )

  subplot(ply1, ply2, ply3, ply4, nrows = 2, margin = c(0.06, 0.06, 0.08, 0.08)) |>
    layout(
      annotations = anotaciones_4,
      margin = list(l = 10, r = 50, t = 40, b = 10)
    )
} else {
  grid_delitos <- cowplot::plot_grid(p_pers, p_resid, p_motos, p_total, ncol = 2, align = "hv")

  titulo_facetas <- cowplot::ggdraw() +
    cowplot::draw_label(
      "Distribución Espacial de las Tasas de Hurto por Modalidad",
      fontface = "bold", size = 13, hjust = 0.5, x = 0.5, y = 0.65
    ) +
    cowplot::draw_label(
      "Tasas anuales promedio por 100.000 habitantes en las 19 localidades urbanas de Bogotá
      ↪  (2022-2026)",
      size = 10, color = "grey35", hjust = 0.5, x = 0.5, y = 0.25
    )

  cowplot::plot_grid(titulo_facetas, grid_delitos, ncol = 1, rel_heights = c(0.08, 1))
}
```

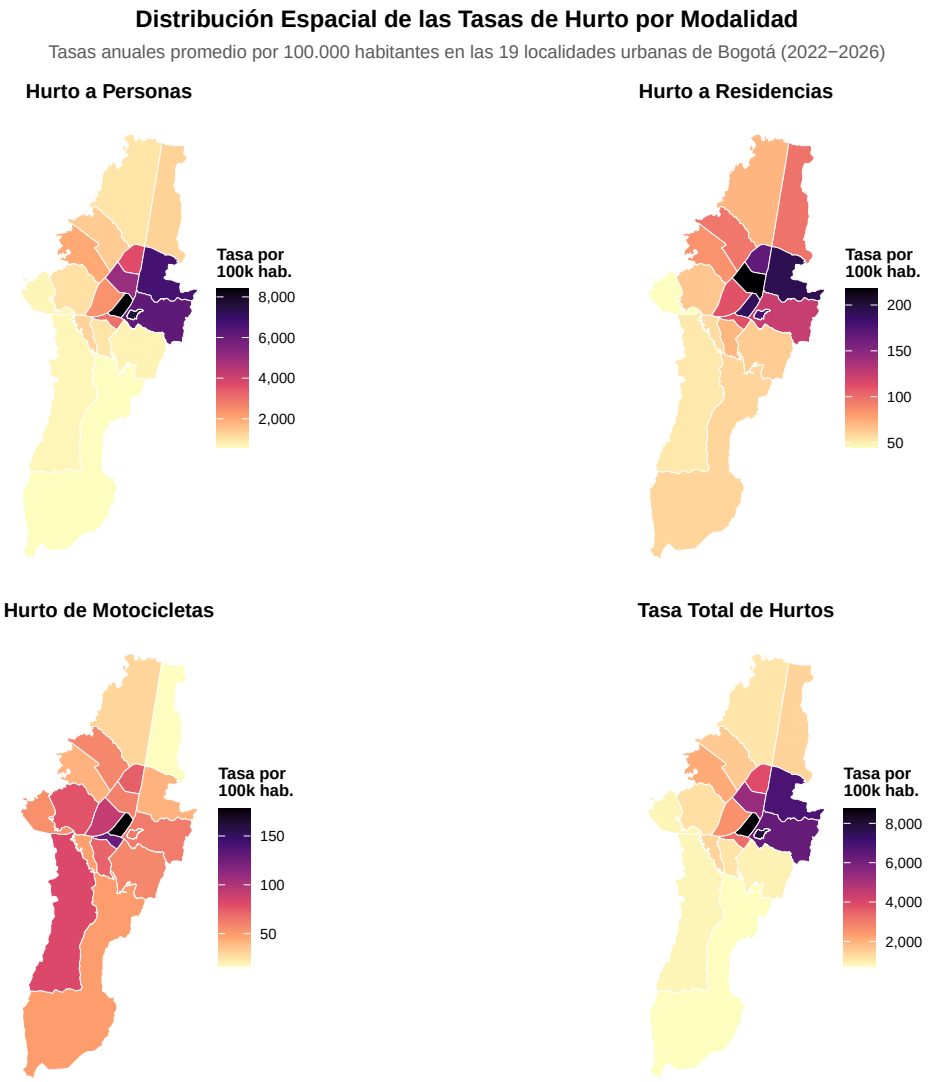


Figura 8: Distribución espacial de las tasas de hurto por 100.000 habitantes en las 19 localidades urbanas de Bogotá (2022-2026)

Los mapas confirman que la actividad delictiva no es uniforme en el territorio. El hurto a personas alcanza sus niveles más altos en el corredor oriental y central: La Candelaria registra 7.615 casos por cada 100.000 habitantes, Chapinero 6.640 y Santa Fe 6.176. Esta concentración responde al flujo de población flotante que transita diariamente por motivos laborales, educativos y comerciales, lo que eleva el número de víctimas potenciales sobre una base de residentes pequeña.

En contraste, el hurto de motocicletas se concentra en Los Mártires (178 por 100.000 habitantes) y Antonio Nariño (128 por 100.000 habitantes), zonas con alta actividad comercial vinculada al comercio de repuestos y talleres automotrices. El hurto a residencias presenta una dispersión mayor en sectores consolidados como Teusaquillo (217 por 100.000 habitantes), Chapinero (192) y Barrios Unidos (168). La tasa consolidada refleja la suma de estas dinámicas y confirma por qué el algoritmo agrupa al centro institucional y al eje automotor en conglomerados independientes de la periferia residencial.

6.2. Desajuste espacial entre delito registrado y cobertura periodística

Para evaluar la asimetría de información planteada en el marco conceptual, comparamos la tasa de criminalidad de los registros policiales con el volumen total de noticias recopiladas para cada localidad.

```
# 6.2 Cálculo del volumen noticioso e integración dual ----
noticias_conteo <- noticias_df |>
  count(localidad, name = "total_noticias")

geo_bogota_dual <- geo_bogota |>
  left_join(noticias_conteo, by = "localidad")

geo_bogota_dual$tooltip_delito <- paste0(
  "<b>", geo_bogota_dual$localidad, "</b><br>",
  "Tasa Real: <b>", scales::comma(round(geo_bogota_dual$tasa_total_prom, 1)), "</b> por 100k
  ↪  hab.<br>",
  "Clúster: ", geo_bogota_dual$cluster_nombre
)

geo_bogota_dual$tooltip_noticias <- paste0(
  "<b>", geo_bogota_dual$localidad, "</b><br>",
  "Noticias en el corpus: <b>", scales::comma(geo_bogota_dual$total_noticias), "</b>
  ↪  artículos<br>",
  "Clúster: ", geo_bogota_dual$cluster_nombre
)

p_delito_real <- ggplot(geo_bogota_dual) +
  geom_sf(aes(fill = tasa_total_prom, text = tooltip_delito), color = "white", linewidth = 0.3) +
  scale_fill_viridis_c(
    option    = "magma",
    direction = -1,
    name      = "Tasa por\n100k hab.",
    labels    = scales::comma
  ) +
  labs(title = "Tasa Delictiva Real (Policía SDSCJ)") +
  theme_void(base_size = 11) +
  theme(
    plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b = 6)),
    legend.position = "right",
    legend.title    = element_text(size = 8.5, face = "bold"),
    legend.text     = element_text(size = 8),
    plot.margin     = margin(6, 6, 6, 6)
  )

p_prensa_vol <- ggplot(geo_bogota_dual) +
  geom_sf(aes(fill = total_noticias, text = tooltip_noticias), color = "white", linewidth = 0.3) +
  scale_fill_viridis_c(
    option    = "magma", # MISMA PALETA (MAGMA) QUE LA TASA DELICTIVA REAL
    direction = -1,
    name      = "Total\nnoticias",
    labels    = scales::comma
  ) +
  labs(title = "Cobertura Noticiosa (Google News)") +
```

```
  theme_void(base_size = 11) +
  theme(
    plot.title      = element_text(face = "bold", size = 11, hjust = 0.5, margin = margin(b = 6)),
    legend.position = "right",
    legend.title    = element_text(size = 8.5, face = "bold"),
    legend.text     = element_text(size = 8),
    plot.margin     = margin(6, 6, 6, 6)
  )

if (is_html_output()) {
  ply_delito   <- ggplotly(p_delito_real, tooltip = "text")
  ply_noticias <- ggplotly(p_prensa_vol,  tooltip = "text")

  ply_delito   <- fijar_colorbar(ply_delito,   x_pos = 0.44, y_pos = 0.5, len_val = 0.65, thick =
↪  13, titulo = "Tasa / 100k")
  ply_noticias <- fijar_colorbar(ply_noticias, x_pos = 1.00, y_pos = 0.5, len_val = 0.65, thick =
↪  13, titulo = "Noticias")

  anotaciones_dual <- list(
    list(x = 0.20, y = 1.03, text = "<b>Tasa Delictiva Real (Policía SDSCJ)</b>", showarrow =
    ↪  FALSE, xref = "paper", yref = "paper", xanchor = "center", font = list(size = 12)),
    list(x = 0.74, y = 1.03, text = "<b>Cobertura Noticiosa (Google News)</b>", showarrow = FALSE,
    ↪  xref = "paper", yref = "paper", xanchor = "center", font = list(size = 12))
  )

  subplot(ply_delito, ply_noticias, nrows = 1, margin = 0.08) |>
    layout(
      annotations = anotaciones_dual,
      margin = list(l = 10, r = 50, t = 35, b = 10)
    )
} else {
  grid_dual <- cowplot::plot_grid(p_delito_real, p_prensa_vol, ncol = 2, align = "hv")

  titulo_dual <- cowplot::ggdraw() +
    cowplot::draw_label(
      "Contraste Espacial: Criminalidad Registrada frente a Cobertura Noticiosa",
      fontface = "bold", size = 13, hjust = 0.5, x = 0.5, y = 0.65
    ) +
    cowplot::draw_label(
      "Tasas de denuncia por 100.000 hab. (SIEDCO) vs. número total de noticias en el corpus
      ↪  (2022-2026)",
      size = 10, color = "grey35", hjust = 0.5, x = 0.5, y = 0.25
    )

  cowplot::plot_grid(titulo_dual, grid_dual, ncol = 1, rel_heights = c(0.12, 1))
}
```

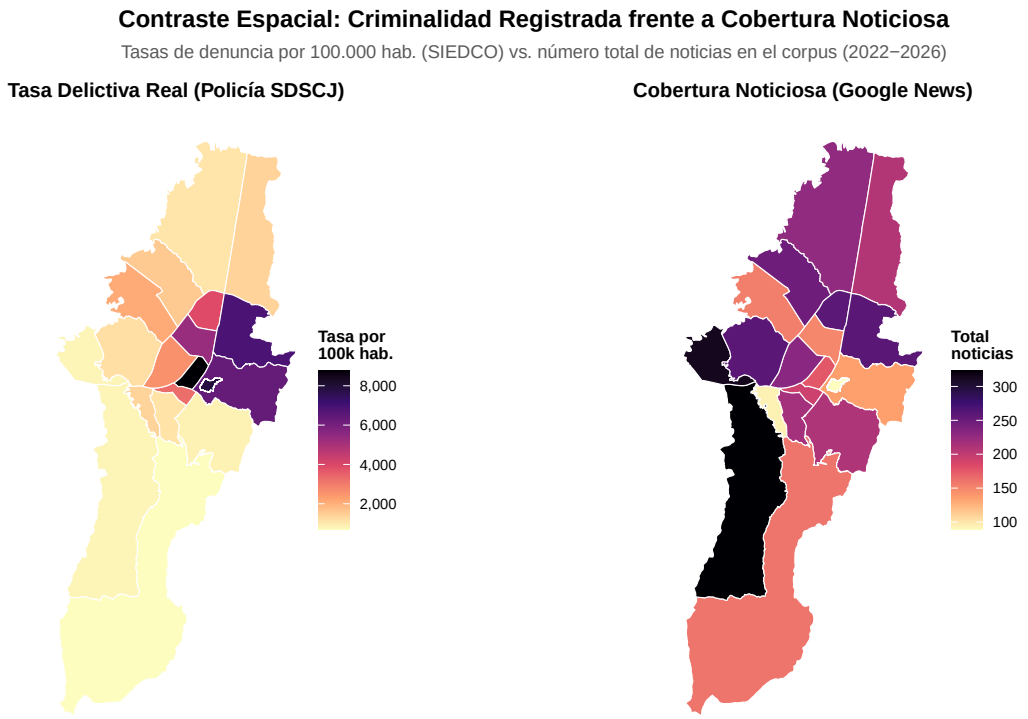


Figura 9: Comparación entre la tasa delictiva oficial y el volumen de noticias sobre delincuencia por localidad

La comparación evidencia diferencias claras entre la incidencia medida por denuncias y la atención de la prensa digital. Las localidades con mayores tasas per cápita, como La Candelaria y Santa Fe, no concentran el volumen principal de noticias (90 y 136 artículos en el corpus, respectivamente).

Por el contrario, localidades densamente pobladas como Ciudad Bolívar (323 noticias), Bosa (313) y Kennedy (260) reciben una cobertura extensa en términos absolutos, a pesar de registrar tasas por habitante sustancialmente menores que el centro histórico. Esta divergencia apoya la hipótesis de asimetría de información: los medios digitales tienden a reportar hechos de alto impacto o incidentes en áreas con mayor audiencia potencial, generando una señal pública de inseguridad que difiere del riesgo relativo derivado de las denuncias oficiales.

6.3. Integración de la capa espacial en el tablero interactivo (R Shiny)

El análisis espacial desarrollado en este cuaderno se traslada a la aplicación interactiva (`app/app.R`) mediante una arquitectura desacoplada que separa el procesamiento analítico de la visualización en tiempo real:

- Preparación y empaquetamiento: El script `05_export_insumos_shiny.R` toma el objeto vectorial `geo_bogota`, verifica su consistencia y lo consolida junto a las series de tiempo en el archivo `datos_consolidados_shiny.rds`. Al guardar las geometrías en un solo objeto binario, la aplicación Shiny arranca de manera inmediata sin necesidad de leer archivos GeoJSON ni ejecutar cruces espaciales en cada sesión.
- Renderizado cartográfico con Leaflet: Dentro del módulo territorial de la interfaz, la función `renderLeaflet()` carga las geometrías en coordenadas geográficas WGS84. Los controles de selección permiten al usuario alternar entre la clasificación de los tres clústeres y la escala continua de tasas

delictivas por modalidad, utilizando paletas continuas adaptadas a mapas digitales.

- Eventos de clic y sincronización reactiva: La aplicación utiliza el observador de eventos `input$mapa_bogota_shape_click`. Cuando el usuario selecciona una localidad sobre el mapa, Shiny captura el identificador territorial y actualiza de inmediato la ficha técnica de la zona, filtrando las curvas históricas de sentometrics y los artículos de prensa representativos (`peakdocs`) asociados a esa jurisdicción.

---

7. Diagnóstico Final de Integridad y Conclusiones

El cierre del cuaderno metodológico comprende dos componentes: una auditoría reproducible de los objetos intermedios generados a lo largo del pipeline y un balance analítico de los hallazgos empíricos, sus limitaciones metodológicas y sus implicaciones de política pública.

7.1. Auditoría programática del contrato de datos

Para garantizar la reproducibilidad del proyecto y la estabilidad de la aplicación interactiva, el siguiente bloque verifica la existencia física, la integridad estructural y las dimensiones de cada uno de los artefactos S3 producidos por el pipeline.

```
# 7.1 Validación programática de los 8 artefactos S3 y paneles ----
archivos_contrato <- data.frame(
  archivo = c(
    "01_sento_corpus.rds",
    "02_lexicons_es.rds",
    "03_sentiment_scores.rds",
    "04_peak_docs.rds",
    "05_sento_measures.rds",
    "06_measures_long.rds",
    "07_global_index.rds",
    "08_attributions.rds",
    "datos_consolidados_shiny.rds"
  ),
  componente = c(
    "Corpus textual con 26 covariables binarias",
    "Léxicos combinados (NRC + crimen_es) y modificadores",
    "Puntuaciones de polaridad documental",
    "Documentos pico con mayor intensidad de polaridad",
    "Medidas agregadas temporales y espaciales",
    "Panel mensual en formato largo para visualización",
    "Índice global de sentimiento de seguridad urbana",
    "Descomposición de atribuciones del modelo Elastic Net",
    "Bundle consolidado de geometrías, series y metadatos Shiny"
  ),
  stringsAsFactors = FALSE
)

# Validación de existencia física
for (arch in archivos_contrato$archivo) {
```

```r
  stopifnot(file.exists(file.path(ruta_proc, arch)))
}
stopifnot(nrow(geo_bogota) == 19)

# Construcción de la tabla de auditoría
tabla_auditoria <- data.frame(
  `Archivo` = archivos_contrato$archivo,
  `Componente` = archivos_contrato$componente,
  `Clase S3` = sapply(archivos_contrato$archivo, function(f) {
    paste(class(readRDS(file.path(ruta_proc, f))), collapse = ", ")
  }),
  `Tamaño` = sapply(archivos_contrato$archivo, function(f) {
    paste0(round(file.info(file.path(ruta_proc, f))[["size"]] / 1024, 1), " KB")
  }),
  `Estado` = "Verificado (✓)",
  check.names = FALSE,
  stringsAsFactors = FALSE
)

knitr::kable(tabla_auditoria, align = c("l", "l", "l", "r", "c"))
```

Tabla 5: Auditoría programática de artefactos del pipeline, clases S3 y contrato de datos para R Shiny

Archivo	Componente	Clase S3	Tamaño	Estado
01_sento_corpus.rds	01_sento_corpus.rds	Corpus textual con 26 covariables binarias	sento_corpus, corpus, character	642.8 KB	Verificado (✓)
02_lexicons_es.rds	02_lexicons_es.rds	Léxicos combinados (NRC + crimen_es) y modificadores	sento_lexicons, list	23.5 KB	Verificado (✓)
03_sentiment_scores.rds	03_sentiment_scores.rds	Puntuaciones de polaridad documental	sentiment, data.table, data.frame	143.9 KB	Verificado (✓)
04_peak_docs.rds	04_peak_docs.rds	Documentos pico con mayor intensidad de polaridad	list	1041.6 KB	Verificado (✓)
05_sento_measures.rds	05_sento_measures.rds	Medidas agregadas temporales y espaciales	sento_measures	413 KB	Verificado (✓)
06_measures_long.rds	06_measures_long.rds	Panel mensual en formato largo para visualización	list	315 KB	Verificado (✓)
07_global_index.rds	07_global_index.rds	Índice global de sentimiento de seguridad urbana	list	2.2 KB	Verificado (✓)
08_attributions.rds	08_attributions.rds	Descomposición de atribuciones del modelo Elastic Net	list	331.4 KB	Verificado (✓)
datos_consolidados_shiny.rds	datos_consolidados_shiny.rds	Bundle consolidado de geometrías, series y metadatos Shiny	list	1773.7 KB	Verificado (✓)

7.2. Conclusiones metodológicas y empíricas

El ejercicio analítico articuló registros policiales oficiales, técnicas de data mining y modelado econométrico supervisado. Los resultados principales se resumen en tres dimensiones:

1. Asimetría territorial y especialización delictiva: La partición en tres conglomerados ($K^* = 3$, con coeficiente de silueta de 0.5416) confirma que la delincuencia en Bogotá responde a dinámicas urbanas diferenciadas. El centro institucional (La Candelaria, Santa Fe y Chapinero) concentra tasas elevadas de hurto a personas, alcanzando hasta 7.615 casos por 100.000 habitantes debido al flujo diario de población flotante. En contraste, el corredor comercial de Los Mártires y Antonio Nariño se especializa en hurto de motocicletas (178 y 128 casos por 100.000 habitantes, respectivamente), mientras que las doce localidades periféricas mantienen tasas per cápita más bajas pero concentran la mayor cantidad de delitos en valores absolutos.

2. Aporte del data mining y sentometrics: La integración del diccionario especializado `crimen_es` con el léxico general NRC y modificadores de valencia contextuales ($t \in \{1, 2, 3, 4\}$) permitió cuantificar la intensidad de la cobertura noticiosa sin distorsiones por frases con negaciones o palabras intensificadoras. La extracción de documentos pico (`peakdocs`) identificó momentos críticos de alarma ciudadana vinculados a homicidios y atracos en transporte masivo.

3. Capacidad predictiva y atribuciones del modelo: La estimación supervisada mediante Elastic Net explicó el $87.5\,\%$ de la varianza mensual en la serie de intensidad delictiva ($h = 1$). Este ajuste valida la hipótesis de que la señal pública transmitida por la prensa contiene información anticipatoria sobre la dinámica criminal, permitiendo aislar la contribución específica de cada localidad, tópico y horizonte de memoria temporal.

7.3. Limitaciones de la investigación

La interpretación de estos hallazgos debe considerar tres limitaciones metodológicas:

1. Cifra negra y sesgo de denuncia policial: Las estadísticas oficiales de la SDSCJ registran exclusivamente los hechos denunciados formalmente ante las autoridades. En sectores con menor presencia estatal o menor confianza comunitaria, el subregistro tiende a ser más pronunciado, especialmente en hurtos menores. Por tanto, las tasas calculadas representan un piso de la criminalidad real y pueden reflejar diferencias en la propensión a denunciar entre sectores socioeconómicos.

2. Sesgo de selección en medios digitales: El corpus de noticias recopilado a través de Google News proviene de diarios y portales de noticias consolidados. Estas fuentes priorizan sucesos con alto valor noticioso o hechos ocurridos en zonas de alta visibilidad comercial y política, lo que amplifica la cobertura en el norte y centro de la ciudad frente a delitos recurrentes en sectores periféricos.

3. Escala de agregación espacial: El análisis utiliza la localidad como unidad territorial básica por restricciones de comparabilidad en las proyecciones de población. Esta agregación encubre una marcada heterogeneidad interna: localidades con más de un millón de habitantes, como Suba o Kennedy, combinan sectores residenciales tranquilos con corredores comerciales de alta conflictividad.

7.4. Implicaciones de política pública

Los resultados ofrecen pautas concretas para la planeación de la seguridad ciudadana y la distribución de recursos policiales en Bogotá:

1. Focalización preventiva según la modalidad delictiva: Las intervenciones de seguridad deben diseñarse según el tipo de riesgo territorial. El hurto a personas en el centro exige vigilancia en estaciones de transporte público, mejor iluminación y patrullaje peatonal en horas pico. En cambio, el hurto de automotores en Los Mártires requiere inspección constante a talleres mecánicos y control a los mercados informales de autopartes. En las localidades periféricas masivas, la prioridad se orienta al fortalecimiento de los frentes de seguridad barrial.
2. Uso complementario de datos objetivos y señales de prensa: Las autoridades deben evitar responder únicamente a la presión de la agenda noticiosa. Guiar la asignación de cuadrantes policiales por el volumen de noticias puede concentrar recursos en zonas de alta resonancia mediática y desatender localidades que, a pesar de tener menor cobertura en prensa, enfrentan volúmenes absolutos de victimización sustancialmente mayores.